



ΕΘΝΙΚΟ ΜΕΤΣΟΒΙΟ ΠΟΛΥΤΕΧΝΕΙΟ
ΣΧΟΛΗ ΗΛΕΚΤΡΟΛΟΓΩΝ ΜΗΧΑΝΙΚΩΝ ΚΑΙ ΜΗΧΑΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ
ΤΟΜΕΑΣ ΤΕΧΝΟΛΟΓΙΑΣ ΠΛΗΡΟΦΟΡΙΚΗΣ ΚΑΙ ΥΠΟΛΟΓΙΣΤΩΝ
ΕΡΓΑΣΤΗΡΙΟ ΣΥΣΤΗΜΑΤΩΝ ΤΕΧΝΗΤΗΣ ΝΟΗΜΟΣΥΝΗΣ ΚΑΙ ΜΑΘΗΣΗΣ

Retrieval Stability and Deferred Commitment in Multi-Turn Retrieval-Augmented Generation Systems

DIPLOMA THESIS

by

Dimosthenis Athanasiou

Επιβλέπων: Αθανάσιος Βουλόδημος
Επίκουρος Καθηγητής Ε.Μ.Π.

Αθήνα, Ιούλιος 2026



Εθνικό Μετσόβιο Πολυτεχνείο
Σχολή Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών
Τομέας Τεχνολογίας Πληροφορικής και Υπολογιστών
Εργαστήριο Συστημάτων Τεχνητής Νοημοσύνης και Μάθησης

Retrieval Stability and Deferred Commitment in Multi-Turn Retrieval-Augmented Generation Systems

DIPLOMA THESIS

by

Dimosthenis Athanasiou

Επιβλέπων: Αθανάσιος Βουλόδημος
Επίκουρος Καθηγητής Ε.Μ.Π.

Εγκρίθηκε από την τριμελή εξεταστική επιτροπή την 2^η Ιουλίου, 2026.

.....
Αθανάσιος Βουλόδημος
Επίκουρος Καθηγητής Ε.Μ.Π.

.....
Α.-Γ. Σταφυλοπάτης
Ομότιμος Καθηγητής Ε.Μ.Π.

.....
Γεώργιος Στάμου
Καθηγητής Ε.Μ.Π.

Αθήνα, Ιούλιος 2026

.....
ΔΗΜΟΣΘΕΝΗΣ ΑΘΑΝΑΣΙΟΥ
Διπλωματούχος Ηλεκτρολόγος Μηχανικός
και Μηχανικός Υπολογιστών Ε.Μ.Π.

Copyright © – All rights reserved Dimosthenis Athanasiou, 2026.

Με επιφύλαξη παντός δικαιώματος.

Απαγορεύεται η αντιγραφή, αποθήκευση και διανομή της παρούσας εργασίας, εξ ολοκλήρου ή τμήματος αυτής, για εμπορικό σκοπό. Επιτρέπεται η ανατύπωση, αποθήκευση και διανομή για σκοπό μη κερδοσκοπικό, εκπαιδευτικής ή ερευνητικής φύσης, υπό την προϋπόθεση να αναφέρεται η πηγή προέλευσης και να διατηρείται το παρόν μήνυμα. Ερωτήματα που αφορούν τη χρήση της εργασίας για κερδοσκοπικό σκοπό πρέπει να απευθύνονται προς τον συγγραφέα.

Οι απόψεις και τα συμπεράσματα που περιέχονται σε αυτό το έγγραφο εκφράζουν τον συγγραφέα και δεν πρέπει να ερμηνευθεί ότι αντιπροσωπεύουν τις επίσημες θέσεις του Εθνικού Μετσόβιου Πολυτεχνείου.

Περίληψη

Η Ανάκτηση-Επαυξημένη Παραγωγή (Retrieval-Augmented Generation, RAG) έχει αναδειχθεί ως ένα θεμελιώδες παράδειγμα για την αγκύρωση των απαντήσεων των Μεγάλων Γλωσσικών Μοντέλων (MGΜ) σε εξωτερικές, επαληθεύσιμες πηγές γνώσης. Παρά την αξιολογήσιμη πρόοδο που έχει επιτευχθεί σε μονότροφα σενάρια RAG, το πολύτροφο συνομιλιακό πλαίσιο — όπου το σύστημα πρέπει να παράγει ακριβείς και αξιόπιστες απαντήσεις στο πλαίσιο εκτεταμένου διαλόγου — παραμένει σημαντικά δυσκολότερο και σχετικά αδύναμα μελετημένο. Στις πολύτροφες αλληλεπιδράσεις, η ποιότητα ανάκτησης υποβαθμίζεται διαδοχικά λόγω μη αυτοτελών ερωτημάτων, αναφορών αντωνυμιών και σωληρής μεταφοράς θέματος, ενώ η ποιότητα παραγωγής επιδεινώνεται περαιτέρω από σωρευτικά σφάλματα, αναπάντητες ερωτήσεις και την αυξανόμενη πολυπλοκότητα του συνομιλιακού πλαισίου.

Η παρούσα διπλωματική εργασία παρουσιάζει μια ενιαία, σταθεροποιημένη αρχιτεκτονική για πολύτροφο RAG, η οποία αναπτύχθηκε και αξιολογήθηκε στο σύνολο δεδομένων αναφοράς MTRAG στο πλαίσιο της κοινής εργασίας SemEval-2026 Task 8. Το σύστημα αντιμετωπίζει και τις τρεις υποεργασίες: ανάκτηση αποσπασμάτων (Task A), παραγωγή απαντήσεων με δοθέντα αποσπάσματα αναφοράς (Task B) και ολοκληρωμένο RAG από άκρο σε άκρο (Task C). Η κεντρική αρχή σχεδιασμού είναι η σταθερότητα ανάκτησης μέσω ποικιλότητας ερωτημάτων: αντί να βασιστούμε σε ετερογενή σύνολα ανακτητών, εκδίδουμε πέντε συμπληρωματικές αναδιατυπώσεις ερωτημάτων βασισμένες σε MGΜ — Ελάχιστη, Corpus-Ειδική, Υποθετική Ενσωμάτωση Εγγράφου (HyDE), Αλυσίδα Σκέψης (CoT) και Λέξεις-Κλειδιά Άγκυρας — σε έναν μοναδικό αραιό ανακτητή ευθυγραμμισμένο με το σώμα κειμένων (ELSER v1), και συγκεντρώνουμε τις κατατεταγμένες λίστες μέσω ενός ιεραρχικού σχήματος Εμφωλευμένης Αντίστροφης Σύντηξης Κατατάξεων (Nested Reciprocal Rank Fusion, RRF).

Για την παραγωγή απαντήσεων, υιοθετούμε έναν πρακτορο-κεντρικό αγωγό πολλαπλών σταδίων που αποσυνθέτει την αγκυρωμένη παραγωγή σε πέντε διαδοχικά στάδια: προκαταρκτικό έλεγχο απαντησιμότητας, εξαγωγή αποδεικτικών εκτάσεων, δημιουργία δύο υποψήφιων απαντήσεων, επιλογή μέσω κριτών και τελική μικροδιόρθωση. Μια συνάρτηση διαμόρφωσης εκχύλισης 4-γραμμικών επιβάλλει συμβιβασμό μεταξύ πιστότητας και φυσικότητας, τιμωρώντας τόσο απαντήσεις επιρρεπείς σε ψευδαισθήσεις (hallucination) όσο και υπερβολικά κυριολεκτικές αντιγραφές. Ο αγωγός ολοκληρωμένου RAG ενσωματώνει επιπλέον μια πύλη απαντησιμότητας πολλαπλών κριτών με ψηφοφορία σταθμισμένη ως προς την εμπιστοσύνη.

Μελέτες αφαίρεσης στοιχείων στο development set δείχνουν ότι: (i) η ποικιλότητα ερωτημάτων πάνω σε έναν μοναδικό ανακτητή υπερτερεί της σύνθεσης ετερογενών ανακτητών, με βάση τις επίσημες κρίσεις συνάφειας του benchmark. (ii) η εξαγωγή αποδεικτικών εκτάσεων πριν την παραγωγή βελτιώνει την πιστότητα. (iii) η βαθμονόμηση της απαντησιμότητας γίνεται ο καθοριστικός παράγοντας της ολοκληρωμένης απόδοσης όταν αυξάνεται το ποσοστό των μη απαντήσιμων ερωτημάτων, ενώ τα σφάλματα ανάκτησης στις κορυφαίες θέσεις παραμένουν σημαντική δεύτερη πηγή αποτυχιών. Το σύστημά μας κατατάχθηκε 1ο στο Task A (nDCG@5: 0.5776, +20.5% έναντι της ισχυρότερης γραμμής βάσης), 2ο στο Task B (Αρμονικός Μέσος: 0.7698) και 11ο στο Task C (Αρμονικός Μέσος: 0.5409) στον επίσημο πίνακα κατάταξης SemEval-2026, μεταξύ 38, 26 και 29 συμμετοχών αντίστοιχα.

Λέξεις-κλειδιά — Ανάκτηση-Επαυξημένη Παραγωγή, Πολύτροφη Συνομιλία, Αναδιατύπωση Ερωτημάτων, Αντίστροφη Σύντηξη Κατατάξεων, Πρακτορο-Κεντρική Παραγωγή, Ανίχνευση Απαντησιμότητας, Μεγάλα Γλωσσικά Μοντέλα, Ανάκτηση Πληροφοριών, SemEval-2026.

Abstract

Retrieval-Augmented Generation (RAG) has emerged as a foundational paradigm for grounding Large Language Model (LLM) responses in external, verifiable knowledge sources. While considerable progress has been made in single-turn RAG settings, the multi-turn conversational scenario — where a system must generate accurate, faithful responses across an extended dialogue — remains significantly more challenging and comparatively understudied. In multi-turn interactions, retrieval quality degrades across turns due to non-standalone queries, pronoun coreferences, and implicit topic carryover, while generation quality is further compromised by error accumulation, unanswerable questions, and the growing complexity of conversational context.

This thesis presents a unified, stability-oriented architecture for multi-turn RAG, developed and evaluated on the MTRAG benchmark as part of the SemEval-2026 Task 8 shared task. The system addresses all three subtasks: passage retrieval (Task A), reference-grounded response generation (Task B), and end-to-end RAG (Task C). The central design principle is retrieval stability through query diversity: rather than relying on heterogeneous retriever ensembles, we issue five complementary LLM-based query reformulations — Minimal, Corpus-Specific, Hypothetical Document Embedding (HyDE), Chain-of-Thought (CoT), and Anchor-Keyword — to a single corpus-aligned sparse retriever (ELSER v1), and aggregate the resulting ranked lists via a hierarchical Nested Reciprocal Rank Fusion (RRF) scheme.

For response generation, we adopt an agentic, multi-stage pipeline that decomposes grounded generation into five sequential stages: answerability triage, evidence span extraction, dual-candidate drafting, judge-based selection, and a final micro-adjustment pass. A 4-gram extractiveness shaping function enforces a faithfulness-naturalness trade-off, penalizing both hallucination-prone under-extractive responses and robotic over-extractive ones. The end-to-end RAG pipeline further incorporates a multi-judge answerability gate with confidence-weighted voting to handle the critical challenge of unanswerable turns.

Ablation studies on the development set indicate that: (i) query diversity over a single corpus-aligned retriever outperforms heterogeneous retriever ensembling under the benchmark’s official relevance judgments; (ii) evidence extraction before generation improves faithfulness; (iii) answerability calibration becomes the decisive factor in end-to-end performance when the share of unanswerable requests rises, while top-rank retrieval errors remain a substantial second source of failure. Our system ranked 1st in Task A (nDCG@5: 0.5776, +20.5% over the strongest baseline), 2nd in Task B (Harmonic Mean: 0.7698), and 11th in Task C (Harmonic Mean: 0.5409) on the official SemEval-2026 leaderboard, among 38, 26, and 29 participating systems respectively.

Keywords — Retrieval-Augmented Generation, Multi-Turn Conversation, Query Rewriting, Reciprocal Rank Fusion, Agentic Generation, Answerability Detection, Large Language Models, Information Retrieval, SemEval-2026.

Ευχαριστίες

Θα ήθελα να εκφράσω τις θερμές μου ευχαριστίες προς τον επιβλέποντα καθηγητή μου, κ. Αθανάσιο Βουλόδημο, για την ευκαιρία που μου παρείχε να εκπονήσω τη διπλωματική μου εργασία στο Εργαστήριο Συστημάτων Τεχνητής Νοημοσύνης και Μάθησης.

Ιδιαίτερη ευγνωμοσύνη οφείλω στη Μαρία Λυμπεραίου και τον Γιώργο Φιλανδριανό για την άριστη συνεργασία, τη συνεχή υποστήριξη και τις πολύτιμες κατευθύνσεις τους, καθώς και για την ενθάρρυνση και τον ενθουσιασμό που επέδειξαν σε κάθε στάδιο της εργασίας· η συμβολή τους υπήρξε καθοριστική για την ολοκλήρωσή της.

Τέλος, θα ήθελα να ευχαριστήσω τους γονείς μου για την αδιάκοπη στήριξή τους, καθώς και τους συμφοιτητές και φίλους μου, οι οποίοι συνέβαλαν, ο καθένας με τον τρόπο του, στο να γίνουν τα χρόνια των σπουδών μου δημιουργικά και ουσιαστικά.

Δημοσθένης Αθανασίου, Ιούλιος 2026

Contents

Contents	11
List of Figures	14
List of Tables	15
1 Εκτεταμένη Περίληψη στα Ελληνικά	21
1.1 Εισαγωγή	22
1.2 Θεωρητικό Υπόβαθρο	23
1.2.1 Μεγάλα Γλωσσικά Μοντέλα	23
1.2.2 Μέθοδοι Ανάκτησης Πληροφορίας	24
1.2.3 Αναδιατύπωση Ερωτημάτων και Σύντηξη	25
1.2.4 Πολύστροφη Συνομιλιακή RAG	26
1.2.5 Αξιολόγηση Συστημάτων RAG	26
1.2.6 Σύνοψη Θεωρητικού Υποβάθρου	27
1.3 Ορισμός Προβλήματος	27
1.3.1 Τυπική Διατύπωση Πολύστροφου RAG	27
1.3.2 Το Πρόβλημα της Απαντησιμότητας (Answerability Gate)	28
1.3.3 Διατύπωση ως Πρόβλημα Ενιαίας Βελτιστοποίησης	28
1.3.4 Ιδιαιτερότητες του Πολύστροφου Περιβάλλοντος	29
1.3.5 Κεντρική Υπόθεση Εργασίας	29
1.3.6 Συσχέτιση με το Benchmark MTRAGEval	29
1.3.7 Ερευνητικά Ερωτήματα	29
1.4 Προτεινόμενο Σύστημα	30
1.4.1 Επισκόπηση Αρχιτεκτονικής	30
1.4.2 Αγωγός Ανάκτησης Πολλαπλών Στρατηγικών (Task A)	30
1.4.3 Πολυσταδιακός Αγωγός Παραγωγής (Task B)	31
1.4.4 Ολοκληρωμένο Σύστημα RAG (Task C)	33
1.4.5 Σχεδιαστικές Επιλογές και Συνεισφορά	33
1.5 Πειραματικά Αποτελέσματα	34
1.5.1 Πειραματική Διάταξη	34
1.5.2 Αποτελέσματα Ανάκτησης — Task A	35
1.5.3 Αποτελέσματα Τεκμηριωμένης Παραγωγής — Task B	36
1.5.4 Η Απαντησιμότητα ως Καθοριστικός Παράγοντας — Task C	37
1.5.5 Επίσημα Αποτελέσματα Leaderboard	38
1.6 Συμπεράσματα και Μελλοντική Εργασία	38
1.6.1 Σύνοψη Συνεισφορών	38
1.6.2 Απαντήσεις στα Ερευνητικά Ερωτήματα	39
1.6.3 Περιορισμοί του Συστήματος	40
1.6.4 Μελλοντικές Ερευνητικές Κατευθύνσεις	40
1.6.5 Τελικό Συμπέρασμα	41
2 Introduction	43

2.1	Motivation	43
2.2	The Multi-Turn RAG Problem	43
2.3	Thesis Statement and Contributions	44
2.4	Thesis Structure	45
3	Background and Related Work	47
3.1	Information Retrieval Paradigms and Neural Representation	47
3.1.1	Lexical and Probabilistic Retrieval: The BM25 Framework	47
3.1.2	Dense Retrieval and Contrastive Embedding Vector Spaces	48
3.1.3	Learned Sparse Representations and Vocabulary Expansion	48
3.1.4	Hypothetical Document Embeddings: Bridging the Query-Passage Gap	48
3.2	Unsupervised Rank Aggregation and Rank Decay Theory	49
3.2.1	Reciprocal Rank Fusion (RRF)	49
3.2.2	Weighted and Nested Rank Aggregation Foundations	49
3.3	Multi-Turn Dialogic Modeling and Structural Failure Cascades	50
3.3.1	Conversational Dependencies: Anaphora, Ellipsis, and Topic Drift	50
3.3.2	The Error Cascade Phenomenon	50
3.3.3	Conversational Search: Rewriting, Robustness, and Benchmark Design	51
3.4	Agentic Generative Pipelines and Multi-Judge Systems	51
3.4.1	Context Bottlenecks via Evidence Span Extraction	51
3.4.2	The LLM-as-a-Judge Evaluation and Selection Paradigm	51
3.4.3	Retrieval-Augmented Generation Beyond Single-Pass Fusion	52
3.5	Related Work	52
4	Problem Definition and Task Specifications	55
4.1	Formal Mathematical Formulation	55
4.1.1	Task A: Multi-Turn Passage Retrieval Specification	55
4.1.2	Task B: Reference-Grounded Response Generation Specification	56
4.1.3	Task C: End-to-End Retrieval-Augmented Generation Specification	56
4.1.4	A Unified Optimization Perspective	56
4.2	MTRAGEval Benchmark and Corpus Analysis	57
4.2.1	Heterogeneous Domain Characterization	57
4.2.2	Question Type and Answerability Distributions	58
4.2.3	Non-Standalone Query Phenomena	58
4.3	Key Architectural Challenges	59
4.4	Research Questions and Hypotheses	59
4.5	Formal Evaluation Methodology	60
4.6	Scope and Constraints	61
4.6.1	In Scope	61
4.6.2	Out of Scope	62
5	The AILS-NTUA System Architecture	63
5.1	Architectural Overview and System Principles	63
5.2	The Multi-Strategy Retrieval Pipeline (Task A)	64
5.2.1	The Five-Pronged Query Rewriting Engine	64
5.2.2	Validating the Necessity of LLM-Based Rewriting	65
5.2.3	First-Stage Learned Sparse Search and Cross-Encoder Reranking	66
5.2.4	The Nested Reciprocal Rank Fusion (Nested RRF) Algorithm	66
5.2.5	Conversation History Window Ablation	67
5.3	The Multi-Stage Agentic Generation Pipeline (Task B)	68
5.3.1	Question-Type-Specific Generation Targets	71
5.4	The Unified End-to-End System and Answerability Gate (Task C)	72
5.5	Implementation Details	73
5.6	Summary of Architectural Design Choices	74
5.7	Complete Prompt Templates	75
5.7.1	Query Rewriting Prompts	75

5.7.1.1	Minimal Reformulation	75
5.7.1.2	Corpus-Specific Reformulation	75
5.7.1.3	Chain-of-Thought (CoT) Reformulation	76
5.7.1.4	Hypothetical Document Embedding (HyDE)	76
5.7.1.5	Anchor-Keyword Targeting	76
5.7.2	Generation Pipeline Prompts	77
5.7.2.1	Stage 0: Conversational and No-Context Triage	77
5.7.2.2	Stage 2: Evidence Span Extraction	77
5.7.2.3	Stage 3: Dual-Candidate Generation	78
5.7.2.4	Stage 4: Judge Modules	78
5.7.2.5	Stage 5: Micro-Adjustment	79
5.7.3	Task C Answerability Judge Prompt	79
6	Experimental Evaluation and Discussion	81
6.1	Experimental Setup and Baseline Benchmarking	81
6.1.1	Model Configuration Overview	81
6.1.2	Hyperparameter Configuration	81
6.2	Task A Retrieval Ablations and the Ensemble Paradox	81
6.2.1	Retriever Family Comparison	81
6.2.2	Incremental Value of Query Rewriting Strategies	83
6.2.3	The Role of Reranking: Complementary, Not Substitutive	83
6.2.4	Deconstructing the Retriever Ensemble Paradox	84
6.2.5	Passage-Informed Rewriting: A Negative Result	85
6.2.6	Turn-Depth Stability	85
6.2.7	Rewriting Model Selection	86
6.2.8	Standalone vs. Non-Standalone Query Performance	87
6.2.8.1	Per-Domain Turn-Depth Degradation	87
6.3	Task B Generation Ablations and Component Contribution	88
6.3.1	Pipeline Component Ablation	88
6.3.2	Extractiveness Band Calibration	89
6.3.3	Model Routing	89
6.3.4	Fixed Pipeline Settings	89
6.4	Task C: Answerability Calibration as the Decisive Factor	89
6.4.1	The Precision–Recall Trade-off in Answerability Detection	90
6.4.2	Error Analysis: Retrieval and Cross-Turn Dependency	90
6.4.3	Threshold Sensitivity and the Task C Ablation	91
6.5	Official Competition Leaderboard Results	91
6.6	Synthesis: Answering the Research Questions	92
7	Conclusion and Future Work	93
7.1	Summary of Technical Contributions	93
7.2	Answers to the Research Questions	94
7.3	System Limitations	95
7.4	Avenues for Future Work	95
7.5	Concluding Remarks	96
	Bibliography	97

List of Figures

1.4.1 Αγωγός ανάκτησης Task A: πέντε συμπληρωματικές αναδιατυπώσεις προωθούνται ανεξάρτητα στον ανακτητή ELSER v1, ακολουθεί υβριδική επαναβαθμολόγηση και τελικά ιεραρχική σύντηξη (Nested RRF).	31
1.4.2 Αγωγός παραγωγής Task B: αλυσίδα πέντε σταδίων που αναβάλλει τη δέσμευση στην τελική απάντηση μέχρι τη συμφωνία πολλαπλών κριτών.	32
1.4.3 Ενοποιημένος αγωγός Task C: η εξαγωγή spans και η σύνταξη προσχεδίων εκτελούνται στα ανακτημένα αποσπάσματα· στη συνέχεια μια πύλη τριών κριτών είτε επιτρέπει στη στροφή να ολοκληρώσει τα υπόλοιπα στάδια του Task B είτε αντικαθιστά το προσχέδιο με τυποποιημένη άρνηση.	33
4.2.1 Distribution of non-standalone phenomena in the development set’s non-first turns ($N=732$, multi-label: a single turn may exhibit more than one phenomenon simultaneously).	59
5.1.1 High-level composition of the three functional modules of AILS-NTUA. Task A (retrieval) and Task B (reference-grounded generation) are each evaluated independently in their standalone configurations; Task C composes both: span extraction and dual-candidate drafting run first, because the answer-level judge of the Multi-Layer Answerability Gate (Sec. 5.4, Fig. 5.4.1) inspects a drafted answer; the gate then either lets the turn finish the remaining Task B stages or replaces the draft with a calibrated refusal.	64
5.2.1 Task A retrieval pipeline: five complementary reformulations are issued independently to ELSER v1, followed by hybrid cross-encoder reranking and hierarchical Nested RRF fusion.	68
5.3.1 The extractiveness shaping function $\phi(r_4)$: an asymmetric penalty/reward profile over the fraction of 4-grams shared between a candidate answer and its extracted evidence spans, calibrated so that the ideal band $[0.28, 0.38]$ matches the empirical overlap of human reference answers (36.2%).	70
5.3.2 Task B generation pipeline: a five-stage chain that defers commitment to the final response until multiple candidates have been drafted, evidence-checked, and judged.	71
5.4.1 Task C end-to-end pipeline: span extraction and drafting run on the retrieved passages, after which a three-judge, confidence-weighted gate with dissenter override either lets the turn finish the remaining Task B stages (judge-based selection and micro-adjustment) or replaces the draft with a calibrated refusal.	73
6.2.1 Recall@5 by turn index, unaugmented ELSER baseline (dashed) vs. final system (solid), overall and per domain (shaded bands: ± 1 standard error across conversations). Overall: Turn 1 0.879 and Turns 6+ 0.428 for the baseline; Turn 1 0.890 and Turns 6+ 0.540 for the final system.	86
6.2.2 SA vs. Non-SA Recall@5 per domain for the ELSER baseline and the final system (values from Table 6.9). Within each group the bars are, from left to right: ELSER SA (dark blue), ELSER Non-SA (light blue), final SA (dark orange), final Non-SA (light orange). The rewriting gain is concentrated on non-standalone queries; standalone performance is nearly unchanged.	88

List of Tables

1.1	Συγκριτική επισκόπηση παραδειγμάτων ανάκτησης. Οι τιμές Recall@5 στη στήλη MTRAG προέρχονται από την αξιολόγηση χωρίς αναδιατύπωση ερωτήματος (777 ερωτήματα development set) και αιτιολογούν την επιλογή του ELSER v1 ως βάσης ανάκτησης του προτεινόμενου συστήματος.	25
1.2	Σύγκριση development και test set στο MTRAGEval. Η σχεδόν τριπλάσια αύξηση του ποσοστού μη απαντήσιμων στροφών στο test set αποτελεί την κύρια πηγή της κατανομικής μετατόπισης που αναλύεται στην Ενότητα 1.5.5. Στο test set, 377 στροφές διαθέτουν κρίσεις συνάφειας για το Task A και 97 είναι μη απαντήσιμες· η κατηγορία των υπόλοιπων 33 στροφών (6.5%) δεν μπόρεσε να ανακτηθεί από τα διαθέσιμα αρχεία.	29
1.3	Στατιστικά δομικής ετερογένειας του corpus MTRAG ανά θεματικό πεδίο.	34
1.4	Σωρευτική ανάλυση συνεισφοράς (ablation) των πέντε στρατηγικών αναδιατύπωσης ερωτήματος στο development set. Οι γραμμές είναι σωρευτικές, οπότε κάθε αύξηση εξαρτάται από τη σειρά προσθήκης· ο πίνακας δεν απομονώνει τη συνεισφορά του reranker ή της ιεραρχικής σύντηξης.	35
1.5	Το παράδοξο σύνθεσης ανακτητών: η προσθήκη εναλλακτικών ανακτητών βελτιώνει το $R@100$ αλλά υποβαθμίζει συστηματικά το $R@5$	36
1.6	Ανάλυση συνεισφοράς (ablation) του αγωγού παραγωγής Task B στο development set.	36
1.7	Μετρικές ανίχνευσης απαντησιμότητας στο development set (832 στροφές: 777 απαντήσιμες ή μερικώς απαντήσιμες και 55 μη απαντήσιμες· εξαιρούνται οι 10 συνομιλιακές στροφές). Καμία διαμόρφωση που αξιολογήθηκε δεν ξεπερνά το 25% $F1$ στις μη απαντήσιμες στροφές του πλήρους development set.	37
1.8	Κύρια αιτία σε 50 περιπτώσεις αποτυχίας του Task C που εξετάστηκαν χειροκίνητα (development set, ένας σχολιαστής). Οι αιτίες που σχετίζονται με την ανάκτηση αντιστοιχούν στο 72%.	38
1.9	Επίσημα αποτελέσματα του AILS-NTUA στο test set του SemEval-2026 Task 8.	38
2.1	Representative multi-turn RAG failure modes from the MTRAG benchmark [22], reproduced in condensed form. Each row illustrates a distinct structural challenge addressed by this thesis: non-standalone queries (Section 5.2), unanswerability under topical-but-irrelevant evidence (Section 5.4), and partial evidence coverage (Section 5.3).	44
3.1	Positioning of the AILS-NTUA system relative to representative prior work discussed in this chapter.	53
4.1	Principal notation.	56
4.2	MTRAG corpus structural heterogeneity and domain statistics.	57
4.3	Top-3 question types per domain (development set). Coverage indicates the percentage of domain turns matching one of the three listed types; FiQA’s lower coverage reflects its markedly more diverse question distribution.	58
4.4	Answerability distribution per domain (development set, 842 turns). The distribution is broadly uniform across domains at development time—a property that, as shown in Section 6.4, does <i>not</i> hold on the held-out test set.	58

4.5	Development vs. test set comparison. The near-tripling of the unanswerable rate, combined with the predominance of non-first turns (91.7% of test turns), makes the test set substantially harder along both the retrieval and answerability-calibration axes. Development: 777 answerable or partially answerable, 55 unanswerable, and 10 conversational turns. Test: 377 turns with Task A relevance judgments (answerable or partially answerable) and 97 unanswerable turns. [†] The category of the remaining 33 test turns could not be recovered from our records.	60
5.1	Configuration of the five query rewriting strategies. The amount of assistant-turn context supplied is tuned per strategy: Anchor-Keyword requires minimal context since it operates primarily on the current utterance, while reasoning-heavy strategies (Minimal, CoT, HyDE) benefit from a wider historical window.	65
5.2	Rewriting method necessity check, development set. FlanT5 falls <i>below</i> the unaugmented baseline, confirming that poorly calibrated rewriting actively harms retrieval; every LLM-based strategy improves over both the baseline and the annotator-replica prompt.	65
5.3	Representative reformulations of a non-standalone Cloud-domain query. Each strategy resolves the underspecified reference to <i>the pricing</i> differently, illustrating the complementary failure-mode coverage that motivates fusing all five under Nested RRF (Section 5.2.4) rather than selecting a single “best” strategy.	66
5.4	Nested RRF parameters tuned per corpus on the development set. Formal, terminology-stable domains (Govt, Cloud) weight the conservative Minimal strategy most heavily; FiQA, with the widest vocabulary gap, allocates the largest share to the exploratory weak-consensus group.	67
5.5	Conversation history window ablation (Minimal rewriting, development set). Recall@5 saturates after 4–6 user turns; assistant turns contribute negligible aggregate benefit beyond one turn. This sweep was a separate run: under the same window, the Minimal strategy scores $R@5=0.527$ in the strategy ablations (Table 6.4), and the 0.006 difference could not be fully reconciled.	69
5.6	Role-based model routing across the Task B generation pipeline, with estimated per-call costs at nominal API pricing (estimates, not measured invoices). The per-turn total ranges from about \$0.010, when only the always-executed stages run, to about \$0.012 when all conditional stages fire.	71
5.7	Question-type rules, style hints, and length targets. Rules are evaluated top-to-bottom; the first pattern match wins. The 90-word base target was calibrated against the development-set reference-answer mean length (90.9 words).	72
5.8	Summary of the architectural design choices developed in this chapter, mapped to the failure modes they address and to the sections that report the corresponding evidence.	74
6.1	Core system hyperparameters, tuned on the development set and frozen for test-set evaluation. Section 6.4 discusses how this dev-only calibration may contribute to the Task C performance gap.	82
6.2	Retriever comparison, 777 development-set queries, no query rewriting. ELSER v1 exceeds Cohere Embed v4 by +8.6 $R@5$ points; see the text for the pooling-bias caveat.	82
6.3	Per-retriever recall after each retriever is independently optimized with the full rewriting and reranking pipeline. ELSER dominates at $R@5/R@10$ even under this controlled comparison.	82
6.4	Incremental ablation of query rewriting strategies on the development set. Rows are cumulative. The largest single increment comes from Minimal rewriting (+0.044 $R@5$), followed by Corpus-Specific expansion (+0.031).	83
6.5	Standalone reranking degrades performance; weighted RRF fusion with the sparse retriever yields complementary gains.	83
6.6	The ensemble paradox: as the single-retriever pipeline matures through query rewriting, the marginal value of retriever ensembling reverses from positive to negative at $R@5$, even as it remains positive at $R@100$. Unique gold documents contributed by alternative retrievers settle at an average rank of 39.5 after fusion (between 27.5 and 54.2 depending on the retriever)—below the top-10 cutoff used for Task A scoring.	84

6.7	Classical PRF vs. Passage-Informed Rewriting (PIR), development set. PRF collapses due to query drift; PIR tracks but never exceeds the quality of its seed signal, indicating that its achievable gain is bounded by the coverage already present after the first retrieval stage. . . .	85
6.8	Rewriting model comparison across strategy types (development set). GPT-4o’s advantage is concentrated on the open-ended HyDE strategy, at a $15\times$ cost premium; on schema-constrained strategies (Minimal, Corpus-Specific) DeepSeek-V3.2 is within 0.014 R@5 of GPT-4o (no significance test was performed).	87
6.9	Recall@5 for standalone (SA) vs. non-standalone (Non-SA) queries, baseline vs. final system. Rewriting improves Non-SA queries by +12.4 pp overall vs. only +1.1 pp for SA queries. . . .	87
6.10	Task B generation pipeline component contribution ablation, development set.	89
6.11	Extractiveness band sensitivity, development set. Deviation from [0.28, 0.38] in either direction degrades HM.	89
6.12	Answerability detection on the development set ($N=832$ turns: 777 answerable or partially answerable and 55 unanswerable; the 10 conversational turns are excluded). Intervals are 95% Wilson score intervals. No gate configuration we evaluated exceeds 25% Unanswerable F1 on the full development set.	90
6.13	Primary root cause in 50 manually inspected Task C failures (development set, single annotator). Retrieval-related causes account for 72% of the inspected failures.	90
6.14	Answerability confidence threshold sweep, development set. $\tau=0.70$ maximizes HM, but is calibrated against a development-set unanswerable rate roughly one-third of the test-set rate.	91
6.15	Task C ablation, development set. Rows change one setting at a time. The largest increment comes from adding a gate (+0.043 HM); the single-to-multi-judge and top-5-to-top-3 changes contribute +0.025 and +0.024. Top-1 underperforms top-3.	91
6.16	Official test set results. “Top Baseline” refers to the strongest non-participant system released by the organizers.	91
6.17	Evidence for each research question and its main limitation.	92

Κεφάλαιο 1

Εκτεταμένη Περίληψη στα Ελληνικά

1.1 Εισαγωγή

Τα Μεγάλα Γλωσσικά Μοντέλα (MGFM - Large Language Models) ορίζονται ως παραμετρικά μοντέλα πιθανοτικής γλώσσας μεγάλης κλίμακας, βασισμένα στην αρχιτεκτονική Transformer. Τα μοντέλα αυτά εκπαιδεύονται μέσω αντικειμενικών συναρτήσεων αυτο-επίβλεψης για την εκτίμηση της κατανομής πιθανότητας εκτεταμένων ακολουθιών φυσικής γλώσσας. Μέσα από αυτή τη διαδικασία εκμάθησης σε ετερογενή σώματα κειμένου (corpora), τα MGFM αναπτύσσουν αναδυόμενες γνωστικές ικανότητες (emergent abilities), οι οποίες τους επιτρέπουν να παράγουν συνεκτικό λόγο, να επιλύουν σύνθετα προβλήματα μέσω πολυβηματικού συλλογισμού (chain-of-thought reasoning) και να εξάγουν σημασιολογικά πλούσιες αναπαραστάσεις.

Παρά τη δομική τους επάρκεια, τα MGFM περιορίζονται εγγενώς από τη στατικότητα της παραμετρικής τους γνώσης, η οποία κρυσταλλώνεται κατά τη φάση της προεκπαίδευσης. Η επικαιροποίηση αυτής της γνώσης ή η ενσωμάτωση εξειδικευμένων πληροφοριών απαιτεί υπολογιστικά δαπανηρές διαδικασίες επανεκπαίδευσης ή λεπτομερούς ρύθμισης (fine-tuning). Επιπλέον, οι παραγόμενες αποκρίσεις στερούνται ενός εγγενούς μηχανισμού ανιχνευσιμότητας (traceability) και επαλήθευσης από εξωτερικές πηγές. Το γεγονός αυτό οδηγεί συχνά στην εκδήλωση ανυπόστατων πραγματολογικών σφαλμάτων, γνωστών ως ψευδαισθήσεις (hallucinations), περιορίζοντας την αξιοπιστία των μοντέλων σε πεδία υψηλής κρισιμότητας.

Ως απάντηση στις αδυναμίες αυτές, η Ανάκτηση-Επαυξημένη Παραγωγή (Retrieval-Augmented Generation - RAG) εισάγει ένα υβριδικό παραδειγματικό πλαίσιο, το οποίο συζευγνύει την παραμετρική μνήμη του γλωσσικού μοντέλου με μη παραμετρικά, εξωτερικά αποθετήρια γνώσης. Ένα τυπικό σύστημα RAG αποτελείται από δύο βασικές συνιστώσες: έναν ανακτητή (retriever), ο οποίος χαρτογραφεί ένα ερώτημα χρήστη στα πιο σχετικά αποσπάσματα κειμένου ενός σώματος εγγράφων, και έναν παραγωγό (generator), ο οποίος συνθέτει την τελική απόκριση λαμβάνοντας υπόψη τα ανακτηθέντα συμφραζόμενα. Η αρχιτεκτονική αυτή ενισχύει την πραγματολογική ακρίβεια, επιτρέπει τη δυναμική προσαρμογή σε μεταβαλλόμενα δεδομένα και προσφέρει τη δυνατότητα παράθεσης πηγών.

Ωστόσο, η τρέχουσα βιβλιογραφία εστιάζει κατά κύριο λόγο σε σενάρια μονοστροφικής αλληλεπίδρασης (single-turn RAG), όπου κάθε ερώτημα αντιμετωπίζεται ως απομονωμένο και ανεξάρτητο. Η υπόθεση αυτή αποκλίνει από τα πραγματικά περιβάλλοντα χρήσης, τα οποία είναι εγγενώς διαλογικά και πολύστροφα (multi-turn). Στα συστήματα Πολύστροφου RAG (Multi-Turn RAG), οι διαδοχικές ερωτήσεις χαρακτηρίζονται από έντονες διαλογικές εξαρτήσεις, όπως η χρήση αντωνυμιών χωρίς ρητό υποκείμενο (coreference resolution) και η αποσπασματική διατύπωση ερωτημάτων. Η παράλειψη αυτών των εξαρτήσεων προκαλεί μετατόπιση των συμφραζομένων (context drift), έντονη αστάθεια στην ανάκτηση και σωρευτική διάδοση σφαλμάτων (error cascade) κατά την εξέλιξη του διαλόγου.

Στην παρούσα διπλωματική εργασία, το πρόβλημα του Πολύστροφου RAG προσεγγίζεται υπό το πρίσμα της *σταθερότητας ανάκτησης συμφραζομένων* (context-aware retrieval stability). Υποστηρίζουμε ότι οι μικρές αποκλίσεις κατά την αναδιατύπωση των ερωτημάτων, σε συνδυασμό με το χάσμα λεξιλογίου (vocabulary gap) μεταξύ των στροφών, προκαλούν απότομη υποβάθμιση της ποιότητας των ανακτηθέντων εγγράφων μετά την πρώτη στροφή. Για την επίλυση αυτής της πρόκλησης, σχεδιάστηκε και υλοποιήθηκε μια ενοποιημένη αρχιτεκτονική που διαχωρίζει λειτουργικά τις εξής κρίσιμες διεργασίες:

- (α) Την αναπαράσταση και εμπλουτισμό του διαλογικού ιστορικού.
- (β) Την ανακάλυψη και δυναμική σύνθεση αποδεικτικών στοιχείων μέσω πολλαπλών στρατηγικών.
- (γ) Τη λήψη απόφασης για την τελική παραγωγή μέσω ελεγχόμενων πυλών απαντησιμότητας (answerability gates).

Η σταθεροποίηση του μηχανισμού ανάκτησης επιτυγχάνεται μέσω μιας προσέγγισης *ποικιλότητας ερωτημάτων έναντι ποικιλότητας ανακτητών* (query-diversity-over-retriever-diversity). Αντί της χρήσης ετερογενών ανακτητών, το σύστημα εκδίδει πέντε συμπληρωματικές αναδιατυπώσεις ερωτήματος βασισμένες σε MGFM προς έναν ενιαίο, ευθυγραμμισμένο με το σώμα κειμένου (corpus-aligned) αραιό ανακτητή (sparse retriever). Η σύνθεση των αποτελεσμάτων πραγματοποιείται μέσω ενός νέου αλγορίθμου Ιεραρχικής Συγχώνευσης Αντίστροφης Κατάταξης (Nested Reciprocal Rank Fusion - Nested RRF), ο οποίος συγκεντρώνει πρώτα τις πιο διερευνητικές στρατηγικές σε μια ενδιάμεση κατάταξη και στη συνέχεια τη συνδυάζει με τις πιο συντηρητικές. Παράλληλα, ο μηχανισμός παραγωγής βασίζεται σε μια στρατηγική *καθυστερημένης δέσμευσης* (deferred commitment), η οποία αποσυνθέτει τη διαδικασία σε εξαγωγή αποσπασμάτων (evidence span extraction),

διαμόρφωση εναλλακτικών απαντήσεων και τελική επιλογή κατόπιν συμφωνίας ενός συστήματος πολλαπλών κριτών (multi-judge selection).

Η προτεινόμενη αρχιτεκτονική αξιολογήθηκε στο πλαίσιο του διεθνούς διαγωνισμού SemEval-2026 Task 8 (MTRAGEval), ο οποίος εξετάζει τρεις διασυνδεδεμένες εργασίες: την ανάκτηση αποσπασμάτων (Task A), την παραγωγή απάντησης με βάση δεδομένες πηγές (Task B) και την end-to-end υλοποίηση συστήματος RAG (Task C). Το αναπτυχθέν σύστημα, με την ονομασία **AILS-NTUA**, πέτυχε υψηλές επιδόσεις στις δύο πρώτες εργασίες και κατέλαβε την **1η θέση στο Task A** (nDCG@5: 0,5776, βελτίωση +20,5% έναντι της ισχυρότερης γραμμής βάσης, μεταξύ 38 συμμετοχών) και τη **2η θέση στο Task B** (Αρμονικός Μέσος - HM: 0,7698, μεταξύ 26 συστημάτων). Στο πιο απαιτητικό end-to-end σενάριο (**Task C**), το σύστημα κατατάχθηκε 11ο μεταξύ 29 συμμετοχών (HM: 0,5409), μόλις οριακά πάνω από την ισχυρότερη γραμμή βάσης των διοργανωτών (0,5366). Όπως αναλύεται στην Ενότητα 1.5, καθοριστικός παράγοντας της υστέρησης είναι η βαθμονόμηση της πύλης απαντησιμότητας: η πύλη βαθμονομήθηκε στο development set, ενώ το ποσοστό των μη απαντήσιμων ερωτημάτων στο test set είναι περίπου τριπλάσιο. Συμβάλλουν επίσης τα σφάλματα ανάκτησης στις κορυφαίες θέσεις, αφού στο Task C ο generator λαμβάνει μόνο τα τρία πρώτα αποσπάσματα που ανακτά το ίδιο το σύστημα.

Τα κύρια ερευνητικά ευρήματα της εργασίας συνοψίζονται στα ακόλουθα:

1. Η εισαγωγή στοχευμένης ποικιλότητας ερωτημάτων (query diversity) σε έναν κατάλληλα ευθυγραμμισμένο ανακτητή υπερτερεί, στο development set και με βάση τις επίσημες κρίσεις συνάφειας του benchmark, της σύνθεσης πολλών διαφορετικών μοντέλων ανάκτησης, καθώς περιορίζει το vocabulary gap χωρίς να εισάγει τον θόρυβο της σύντηξης ετερογενών κατατάξεων.
2. Οι μηχανισμοί επαναβαθμολόγησης (cross-encoders) λειτουργούν βέλτιστα ως συμπληρωματικά φίλτρα διύλισης και δεν μπορούν να υποκαταστήσουν την ανάγκη για ένα σταθερό αρχικό στάδιο ανάκτησης.
3. Η χρήση MFM για την περαιτέρω επαναβαθμολόγηση των αποτελεσμάτων παρουσιάζει φαινόμενα κορεσμού (saturation) όταν η ποιότητα της αρχικής ανάκτησης είναι ήδη υψηλή, αυξάνοντας παράλληλα το υπολογιστικό κόστος χωρίς αξιολογικό όφελος.
4. Καθοριστικός παράγοντας της end-to-end απόδοσης (Task C) υπό την κατανομή του test set είναι η βαθμονόμηση της πύλης απαντησιμότητας (answerability gate), ενώ τα σφάλματα ανάκτησης στις κορυφαίες θέσεις παραμένουν σημαντικά. Η πύλη επιβαρύνεται από την τάση των μοντέλων να αποδέχονται αδύναμες αποδείξεις (acceptance bias) και γίνεται κρίσιμη όταν αυξάνεται το ποσοστό των μη απαντήσιμων ερωτημάτων.

Σχέση με δημοσιευμένη εργασία και προσωπική συνεισφορά. Το σύστημα αναπτύχθηκε στην ομάδα AILS-NTUA και δημοσιεύτηκε ως άρθρο περιγραφής συστήματος στο SemEval-2026 [5]. η παρούσα διπλωματική βασίζεται σε αυτό και επεκτείνει την ανάλυσή του. Ο συγγραφέας σχεδίασε και υλοποίησε τις συνιστώσες ανάκτησης, παραγωγής και απαντησιμότητας, εκτέλεσε όλα τα πειράματα και τις αναλύσεις και έγραψε τη διπλωματική. η Μ. Λυμπεραίου και ο Γ. Φιλανδριανός προσέφεραν ερευνητική καθοδήγηση και ανατροφοδότηση, ενώ οι Α. Βουλόδημος και Γ. Στάμου επόπτευαν την εργασία.

1.2 Θεωρητικό Υπόβαθρο

Η παρούσα ενότητα παρουσιάζει τις θεμελιώδεις θεωρητικές έννοιες και το μαθηματικό υπόβαθρο που υποστηρίζουν τη σχεδίαση συστημάτων Ανάκτησης-Επαυξημένης Παραγωγής (Retrieval-Augmented Generation - RAG) σε πολύστροφα (multi-turn) διαλογικά περιβάλλοντα. Συγκεκριμένα, αναλύεται η στοχαστική φύση των Μεγάλων Γλωσσικών Μοντέλων, το υβριδικό παραδειγματικό πλαίσιο της αρχιτεκτονικής RAG, οι σύγχρονες μέθοδοι νευρωνικής ανάκτησης πληροφορίας, οι τεχνικές αναδιατύπωσης ερωτημάτων μέσω συλλογιστικής, καθώς και οι προκλήσεις της συνομιλιακής αναζήτησης και οι μεθοδολογίες πολυδιάστατης αξιολόγησής τους.

1.2.1 Μεγάλα Γλωσσικά Μοντέλα

Τα Μεγάλα Γλωσσικά Μοντέλα (MFM - Large Language Models) αποτελούν αυτο-παλινδρομικά (autoregressive) στοχαστικά μοντέλα γλώσσας, βασισμένα στην αρχιτεκτονική Transformer και ειδικότερα στον μηχανισμό της αυτο-προσοχής (self-attention). Τα μοντέλα αυτά εκπαιδεύονται μέσω μεγιστοποίησης

της λογαριθμικής πιθανότητας του επόμενου συμβόλου (next-token prediction) πάνω σε εκτεταμένα σώματα κειμένου, μια διαδικασία που τυπικά μοντελοποιείται ως:

$$P(X) = \prod_{t=1}^T P(x_t | x_1, x_2, \dots, x_{t-1}) = \prod_{t=1}^T P(x_t | x_{<t}) \quad (1.2.1)$$

Η εκθετική κλιμάκωση (scaling laws) του αριθμού των παραμέτρων, του όγκου των δεδομένων εκπαίδευσης και της υπολογιστικής ισχύος οδηγεί στην εμφάνιση αναδυόμενων ικανοτήτων (emergent abilities). Οι σημαντικότερες από αυτές περιλαμβάνουν:

- **Μάθηση εντός πλαισίου (In-Context Learning - ICL):** Η ικανότητα εκτέλεσης νέων εργασιών κατά τη φάση της εξαγωγής συμπερασμάτων (inference) αποκλειστικά μέσω της παροχής παραδειγμάτων στην προτροπή (prompt), χωρίς τροποποίηση των βαρών του δικτύου.
- **Συμμόρφωση με οδηγίες (Instruction Following):** Η ευθυγράμμιση του μοντέλου με τις προθέσεις του χρήστη μέσω εκπαίδευσης εποπτευόμενης λεπτομερούς ρύθμισης (Supervised Fine-Tuning - SFT) και ενισχυτικής μάθησης από ανθρώπινη ανάδραση (RLHF).
- **Πολυβηματικός Συλλογισμός (Chain-of-Thought Reasoning):** Η ικανότητα αποδόμησης σύνθετων προβλημάτων σε διαδοχικά, λογικά ενδιάμεσα βήματα συλλογιστικής πριν από την παραγωγή της τελικής απόκρισης. Στο Κεφάλαιο 5 αξιοποιούμε άμεσα αυτή την αρχή στη σχεδίαση της στρατηγικής Chain-of-Thought αναδιατύπωσης ερωτήματος (Ενότητα 5.2.1) και στην πολυσταδιακή διαδικασία παραγωγής απάντησης (Ενότητα 5.3).

Παρά την υψηλή τους αναπαραστατική ικανότητα, τα MFM παρουσιάζουν δομικούς περιορισμούς:

- **Στατικότητα γνώσης (Knowledge Cutoff):** Η ενσωματωμένη γνώση παραμένει χρονικά και πραγματολογικά περιορισμένη στο σημείο ολοκλήρωσης της προεκπαίδευσης.
- **Έλλειψη εγγενούς ανιχνευσιμότητας (Traceability):** Τα μοντέλα λειτουργούν ως "μαύρα κουτιά" (black boxes), αδυνατώντας να παρέχουν ρητές παραπομπές ή αποδείξεις για την ορθότητα των ισχυρισμών τους.
- **Πραγματολογικές Ψευδαισθήσεις (Hallucinations):** Η τάση παραγωγής κειμένου που είναι συντακτικά και υφολογικά άρτιο, αλλά πραγματολογικά εσφαλμένο ή ανυπόστατο, λόγω της φύσης τους ως προσεγγιστές κατανομών πιθανότητας.

Οι περιορισμοί αυτοί επιβάλλουν τη μετάβαση από αμιγώς παραμετρικά συστήματα σε υβριδικές αρχιτεκτονικές που ενσωματώνουν εξωτερικές, δυναμικές πηγές γνώσης.

1.2.2 Μέθοδοι Ανάκτησης Πληροφορίας

Οι σύγχρονες αρχιτεκτονικές ανάκτησης πληροφορίας κατηγοριοποιούνται με βάση τον τρόπο αναπαράστασης του κειμένου:

- **Λεξιλογικοί Ανακτητές (Sparse Retrievers):** Βασίζονται στην ακριβή αντιστοίχιση όρων (exact keyword matching) χρησιμοποιώντας στατιστικές συχνότητες εμφάνισης. Ο αλγόριθμος BM25 αποτελεί το τυπικό βιομηχανικό πρότυπο, βαθμολογώντας τη συνάφεια ενός εγγράφου d με βάση τον όρο t ως συνάρτηση της συχνότητας του όρου εντός του εγγράφου (term frequency) και της αντίστροφης συχνότητας εμφάνισης στο σώμα κειμένου (inverse document frequency). Παρά την υψηλή ακρίβεια σε τεχνικούς όρους και σειριακούς αριθμούς, το BM25 περιορίζεται θεμελιωδώς από το πρόβλημα της ασυμφωνίας λεξιλογίου (vocabulary mismatch): αν το ερώτημα χρησιμοποιεί παραφράσεις ή συνώνυμα που δεν συμπίπτουν λεξιλογικά με το κείμενο-στόχο, η τομή $q \cap d$ μηδενίζεται.
- **Πυκνοί Ανακτητές (Dense Retrievers):** Χρησιμοποιούν βαθιά νευρωνικά δίκτυα (π.χ. αρχιτεκτονικές Dual-Encoder) εκπαιδευμένα μέσω αντιπαραθετικής μάθησης (contrastive learning) για τη χαρτογράφηση ερωτημάτων και εγγράφων σε έναν κοινό, χαμηλής διάστασης διανυσματικό χώρο $\mathbb{R}^d$. Η βαθμολογία συνάφειας υπολογίζεται μέσω του εσωτερικού γινομένου ή της συνημίτονου ομοιότητας των αντίστοιχων embeddings: $S(q, d) = \langle \mathbf{E}_Q(q), \mathbf{E}_D(d) \rangle$. Παρότι αποτελεσματικοί σε

αφηρημένη σημασιολογική ταύτιση και διαγλωσσικές παραφράσεις, εισάγουν συχνά σημασιολογικό θόρυβο σε πολύστροφα περιβάλλοντα, υπεργενικεύοντας τεχνικά tokens.

- **Μαθητοί Αραιοί Ανακτητές (Learned Sparse Retrievers):** Αποτελούν μια σύγχρονη υβριδική προσέγγιση (π.χ. SPLADE, ELSER) που ενοποιεί τα πλεονεκτήματα λεξιλογικής ακρίβειας και σημασιολογικής γενίκευσης. Χρησιμοποιούν ένα γλωσσικό μοντέλο για να προβλέψουν και να επεκτείνουν το λεξιλόγιο ενός εγγράφου (term expansion) στον αρχικό χώρο των high-dimensional tokens, επιλύοντας το πρόβλημα της συνωνυμίας χωρίς να χάνουν την ακρίβεια της αραιής αναπαράστασης. Η βαθμολογία ορίζεται ως:

$$S(q, d) = \sum_{t \in q \cap d} w_q(t) \cdot w_d(t) \quad (1.2.2)$$

όπου τα βάρη $w(t)$ είναι μαθημένες μη αρνητικές τιμές που αντανακλούν τη σημασιολογική βαρύτητα του όρου εντός του συγκεκριμένου corpus.

Ο Πίνακας 1.1 συνοψίζει τα τρία αυτά παραδείγματα ως προς τα κρίσιμα χαρακτηριστικά τους για το πολύστροφο σενάριο. Η παρούσα εργασία βασίζεται σε έναν corpus-aligned learned sparse ανακτητή (**ELSER v1**), ο οποίος, όπως αναλύεται διεξοδικά στην Ενότητα 1.5, υπερτερεί εμπειρικά τόσο του BM25 όσο και των ισχυρότερων εμπορικών dense ανακτητών (π.χ. Cohere Embed v4) στο benchmark MTRAG, με το πλεονέκτημα να αποδίδεται εν μέρει στη μείωση του vocabulary gap χωρίς τον σημασιολογικό θόρυβο των πυκνών embeddings (με την επιφύλαξη της μεροληψίας των κρίσεων συνάφειας, Ενότητα 1.5).

Χαρακτηριστικό	Sparse (BM25)	Dense	Learned Sparse (ELSER v1)
Αναπαράσταση	Λεξιλογική, αραιή	Νευρωνική, πυκνή ($\mathbb{R}^d$)	Λεξιλογική, αραιή με term expansion
Χειρισμός συνωνύμων	Όχι	Ναι	Ναι (μέσω επέκτασης όρων)
Ακρίβεια σε IDs/κωδικούς	Υψηλή	Χαμηλή	Υψηλή
Ερμηνευσιμότητα	Πλήρης	Περιορισμένη	Υψηλή
Ευθυγράμμιση με corpus	—	Γενικού σκοπού	Corpus-aligned
Επίδοση στο MTRAG (R@5)	0.153	0.397 (καλύτερο dense)	0.483

Πίνακας 1.1: Συγκριτική επισκόπηση παραδειγμάτων ανάκτησης. Οι τιμές Recall@5 στη στήλη MTRAG προέρχονται από την αξιολόγηση χωρίς αναδιατύπωση ερωτήματος (777 ερωτήματα development set) και αιτιολογούν την επιλογή του ELSER v1 ως βάσης ανάκτησης του προτεινόμενου συστήματος.

1.2.3 Αναδιατύπωση Ερωτημάτων και Σύντηξη

Σε δυναμικά διαλογικά περιβάλλοντα, τα ερωτήματα των χρηστών είναι συχνά ελλιπή ή εξαρτώνται άμεσα από το ιστορικό. Η Αναδιατύπωση Ερωτημάτων (Query Reformulation) μέσω MFM μετασχηματίζει ένα εξαρτημένο ερώτημα σε μια αυτοτελή (context-independent) μορφή. Οι κυριότερες στρατηγικές περιλαμβάνουν:

- **HyDE (Hypothetical Document Embeddings):** Παραγωγή μιας υποθετικής απάντησης (zero-shot) από το MFM, η οποία στη συνέχεια χρησιμοποιείται ως διευρυμένο ερώτημα για την ανάκτηση, στοχεύοντας στην ευθυγράμμιση στον χώρο των απαντήσεων.
- **Chain-of-Thought (CoT) Reformulation:** Παραγωγή ενδιάμεσων βημάτων ανάλυσης της πληροφοριακής ανάγκης πριν την τελική εξαγωγή των όρων αναζήτησης.
- **Keyword Extraction & Anchor Targeting:** Εστίαση στην εξαγωγή ονοματοποιημένων οντοτήτων και λέξεων-κλειδιών που λειτουργούν ως άγκυρες (anchors) στο συγκεκριμένο σώμα κειμένου.

Όταν εκδίδονται πολλαπλές, συμπληρωματικές αναδιατυπώσεις ερωτήματος, απαιτείται ένας μηχανισμός σύντηξης για τη συγχώνευση των επιμέρους κατατάξεων. Η Σύντηξη Αντίστροφης Κατάταξης (Reciprocal Rank Fusion - RRF) αποτελεί μια ανθεκτική μέθοδο (unsupervised rank aggregation) που ορίζεται ως:

$$\text{RRF_Score}(d \in \mathcal{D}) = \sum_{m \in \mathcal{M}} \frac{1}{k + r_m(d)} \quad (1.2.3)$$

όπου $\mathcal{M}$ είναι το σύνολο των παραχθέντων λιστών κατάταξης, $r_m(d)$ είναι η θέση (rank) του εγγράφου d στη λίστα m , και k είναι μια σταθερά εξομάλυνσης (smoothing constant, τυπικά $k = 60$). Η RRF εξασφαλίζει ότι έγγραφα που κατατάσσονται ψηλά σε πολλαπλές στρατηγικές ευνοούνται, χωρίς να επηρεάζονται από τις αποκλίσεις στις απόλυτες τιμές των σκορ των διαφορετικών μοντέλων. Ωστόσο, η επίπεδη (flat) εκδοχή της RRF αντιμετωπίζει όλες τις στρατηγικές αναδιατύπωσης ως ισοδύναμες, κάτι που μπορεί να είναι προβληματικό όταν ορισμένες (π.χ. HyDE, CoT) αναμένεται να είναι λιγότερο σταθερές ανά στροφή από άλλες (π.χ. Minimal, Corpus-Specific). Μια ιεραρχική παραλλαγή της RRF που αντιμετωπίζει αυτή την ανομοιογένεια παρουσιάζεται στην Ενότητα 1.4.2.

1.2.4 Πολύστροφη Συνομιλιακή RAG

Σε αντίθεση με το μονοστροφικό RAG, η Πολύστροφη Συνομιλιακή RAG (Multi-Turn Conversational RAG) εισάγει τη διάσταση του χρόνου και της διαλογικής εξάρτησης. Το κύριο πρόβλημα εντοπίζεται στη διατήρηση της *σταθερότητας ανάκτησης συμφραζομένων* (context-aware retrieval stability). Καθώς ο διάλογος εξελίσσεται, τα ερωτήματα εμφανίζουν:

- **Επίλυση Αναφορών (Coreference Resolution):** Χρήση αντωνυμιών ή δεικτικών εκφράσεων που αναφέρονται σε οντότητες προηγούμενων στροφών.
- **Ελλειπτικότητα (Ellipsis):** Παράλειψη ολόκληρων συντακτικών δομών ή υποκειμένων που θεωρούνται γνωστά από τα συμφραζόμενα.
- **Μετατόπιση Θεματικού Πλαισίου (Topic Switching):** Απότομες αλλαγές στη ροή της συζήτησης.

Η μη επιτυχής διαχείριση αυτών των φαινομένων οδηγεί σε *σωρευτική διάδοση σφαλμάτων* (error cascading): ένα αποτυχημένο βήμα ανάκτησης στη στροφή t εισάγει θόρυβο στη γεννήτρια, η οποία παράγει μια εσφαλμένη απάντηση, η οποία με τη σειρά της μολύνει το ιστορικό του διαλόγου, προκαλώντας ακόμα μεγαλύτερη απόκλιση (context drift) στη στροφή $t + 1$. Ο μηχανισμός αυτός προϋποθέτει ότι το ιστορικό περιέχει τις προηγούμενες απαντήσεις του ίδιου του συστήματος, όπως σε έναν πραγματικό βοηθό. το MTRAGEval, αντίθετα, παρέχει σε κάθε στροφή το ιστορικό αναφοράς, οπότε η αξιολόγησή μας δεν τον ενεργοποιεί. Στο MTRAG benchmark παρατηρούμε πάντως απότομη πτώση της απόδοσης ανάκτησης μετά την πρώτη στροφή (Ενότητα 1.5.2).

1.2.5 Αξιολόγηση Συστημάτων RAG

Η αξιολόγηση σε πολύστροφα περιβάλλοντα RAG επιβάλλει τη χρήση ενός πολυδιάστατου πλαισίου μετρικών που εξετάζει ανεξάρτητα την ανάκτηση και την παραγωγή. Οι βασικοί άξονες περιλαμβάνουν:

- **Μετρικές Ανάκτησης εγγράφων:** Το Recall@k (ικανότητα εντοπισμού όλων των σχετικών εγγράφων) και το Normalized Discounted Cumulative Gain (nDCG@k), το οποίο λαμβάνει υπόψη τη σχετική θέση και τη διαβαθμισμένη συνάφεια των ανακτηθέντων αποσπασμάτων.
- **Μετρικές Πιστότητας και Παραγωγής:** Το αναφορικά αλγοριθμικό σκορ RB_{alg} (σύνθεση BERT-Recall, BERT-K-Precision και ROUGE-L έναντι της ανθρώπινα επιμελημένης αναφοράς) και το χωρίς αναφορά μετρικό πιστότητας RL_F (πλαίσιο RAGAS), που αποτιμά αν οι ισχυρισμοί της απάντησης θεμελιώνονται στα ανακτηθέντα αποσπάσματα.
- **Αξιολόγηση μέσω MFM (LLM-as-a-Judge):** Το αναφορικό σκορ RB_{llm} , ένας διάμεσος-συγκεντρωμένος αξιολογητής πολλαπλών MFM που εκτιμά Πιστότητα (Faithfulness), Καταλληλότητα (Appropriateness) και Πληρότητα (Completeness) της απάντησης.

Στο πλαίσιο του MTRAGEval (SemEval-2026 Task 8), η end-to-end απόδοση του συστήματος συντίθεται μέσω του Αρμονικού Μέσου (Harmonic Mean - HM) των επιμέρους αυτών διαστάσεων:

$$HM = \frac{3}{\frac{1}{RB_{alg}} + \frac{1}{RL_F} + \frac{1}{RB_{llm}}} \quad (1.2.4)$$

Η χρήση του αρμονικού μέσου τιμωρεί αυστηρά συστήματα που παρουσιάζουν ασυμμετρία στην απόδοσή τους (π.χ. υψηλό F1 αλλά χαμηλό Faithfulness λόγω ψευδαισθήσεων), επιβάλλοντας την ισορροπημένη

βελτιστοποίηση όλων των συνιστωσών. Σημειώνεται επιπλέον ότι η αξιολόγηση εξαρτάται κρίσιμα από έναν αυτοματοποιημένο ταξινομητή «Δεν Γνωρίζω» (IDK classifier): σωστές αρνήσεις απάντησης σε μη απαντήσιμες στροφές λαμβάνουν τέλει σκορ (1.0) σε όλους τους άξονες, ενώ εσφαλμένες αρνήσεις ή εσφαλμένες αποδοχές μηδενίζονται — καθιστώντας την πύλη απαντησιμότητας υψηλού ρίσκου συνιστώσα του συστήματος, όπως αναλύεται στην Ενότητα 1.5.4.

1.2.6 Σύνοψη Θεωρητικού Υποβάθρου

Συνοψίζοντας, η διασταύρωση των Μεγάλων Γλωσσικών Μοντέλων με τις τεχνικές Νευρωνικής Ανάκτησης Πληροφορίας δημιουργεί ισχυρά υβριδικά συστήματα RAG, η σταθερότητα των οποίων δοκιμάζεται σε πολύστροφα σενάρια διαλόγου. Ο περιορισμός της αστάθειας της ανάκτησης μεταξύ στροφών —και, σε έναν πραγματικό βοηθό, της σωρευτικής διάδοσης σφαλμάτων— απαιτεί τον αυστηρό έλεγχο της ποιότητας των ερωτημάτων μέσω πολλαπλών στρατηγικών αναδιτύπωσης, τη χρήση εύρωστων αλγορίθμων σύντηξης κατατάξεων και την εισαγωγή πυλών απαντησιμότητας. Η παρούσα εργασία βασίζεται πάνω σε αυτές τις αρχές για τη διασφάλιση της σταθερότητας της ανάκτησης και της πιστότητας των παραγόμενων αποκρίσεων.

1.3 Ορισμός Προβλήματος

Η παρούσα ενότητα εξειδικεύει τον τυπικό μαθηματικό ορισμό του Πολύστροφου RAG και αναλύει τις δομικές προκλήσεις που αυτό συνεπάγεται. Το πρόβλημα προσεγγίζεται ως μια σύνθετη διαδικασία διαδοχικής λήψης αποφάσεων υπό συνθήκες στοχαστικής αβεβαιότητας, η οποία απαιτεί τη σύζευξη δυναμικής ανάκτησης πληροφορίας, παραγωγής φυσικής γλώσσας υπό περιορισμούς (constrained generation) και στοχευμένης εκτίμησης απαντησιμότητας (answerability estimation).

1.3.1 Τυπική Διατύπωση Πολύστροφου RAG

Έστω ένας διάλογος εξελισσόμενος σε διαδοχικές στροφές (turns) $i = 1, 2, \dots, t$. Ορίζουμε το διαλογικό ιστορικό H_t μέχρι τη χρονική στιγμή t ως την ακολουθία των προηγούμενων αλληλεπιδράσεων:

$$H_t = \left((u_1, \mathcal{D}_1, y_1), (u_2, \mathcal{D}_2, y_2), \dots, (u_{t-1}, \mathcal{D}_{t-1}, y_{t-1}) \right) \quad (1.3.1)$$

όπου u_i αντιπροσωπεύει το εκφώνημα (utterance) του χρήστη, $\mathcal{D}_i \subset \mathcal{D}$ το σύνολο των εγγράφων που ανακτήθηκαν και y_i την απόκριση της στροφής i . Στο MTRAGEval το ιστορικό αυτό είναι το ιστορικό αναφοράς (reference history) και όχι οι απαντήσεις του ίδιου του συστήματος. Στην τρέχουσα στροφή t , ο χρήστης εισάγει ένα νέο, ενδεχομένως μη αυτοτελές ερώτημα $q_t \equiv u_t$.

Με δεδομένο ένα στατικό, καθολικό σώμα γνώσης (knowledge corpus) $\mathcal{D}$, η αρχιτεκτονική Πολύστροφου RAG αποσυντίθεται σε τρεις διασυνδεδεμένες συναρτήσεις, οι οποίες αντιστοιχούν απευθείας στις προδιαγραφές του MTRAGEval:

1. Συνάρτηση Ανάκτησης Συμφραζομένων (Task A): Ο μηχανισμός ανάκτησης $\mathcal{R}$ αναλαμβάνει τη χαρτογράφηση του τρέχοντος ερωτήματος και του ιστορικού σε ένα βέλτιστο, διατεταγμένο υποσύνολο k σχετικών αποσπασμάτων (κατά τις προδιαγραφές του διαγωνισμού, $k = 10$):

$$\mathcal{R}(q_t, H_t, \mathcal{D}) \rightarrow \mathcal{D}_t = \{d_1, d_2, \dots, d_k\} \subset \mathcal{D}, \quad k = 10 \quad (1.3.2)$$

2. Συνάρτηση Τεκμηριωμένης Παραγωγής (Task B): Με δεδομένο ένα χρυσό (ground-truth) σύνολο αναφοράς αποδείξεων $\mathcal{D}_t^*$, ο μηχανισμός παραγωγής $\mathcal{G}$ συνθέτει μια πραγματολογικά αγκυρωμένη απόκριση y_t , απομονώνοντας πλήρως την ποιότητα παραγωγής από τυχόν σφάλματα ανάκτησης:

$$\mathcal{G}(q_t, H_t, \mathcal{D}_t^*) \rightarrow y_t \quad (1.3.3)$$

3. Ενοποιημένη End-to-End Παραγωγή (Task C): Στο πλήρες σύστημα, η παραγωγή εξαρτάται άμεσα από τα αποτελέσματα του πρώτου σταδίου, γεγονός που εισάγει στοχαστική εξάρτηση και επιτρέπει τη σώρευση σφαλμάτων ανάκτησης στην τελική απόκριση:

$$P(y_t | q_t, H_t) = \sum_{\mathcal{D}_t} P(y_t | q_t, H_t, \mathcal{D}_t) \cdot P(\mathcal{D}_t | q_t, H_t) \quad (1.3.4)$$

1.3.2 Το Πρόβλημα της Απαντησιμότητας (Answerability Gate)

Σε πραγματικά σενάρια συνομιλίας, η πληροφοριακή ανάγκη του χρήστη ενδέχεται να μην καλύπτεται από το διαθέσιμο corpus $\mathcal{D}$. Για τη μοντελοποίηση αυτής της συνθήκης, εισάγουμε μια λανθάνουσα δυαδική μεταβλητή απαντησιμότητας $z_t \in \{0, 1\}$, η οποία ορίζεται ως:

$$z_t = \begin{cases} 1, & \text{εάν το } \mathcal{D} \text{ περιέχει επαρκή στοιχεία για την πλήρη τεκμηρίωση του } q_t \text{ υπό το } H_t \\ 0, & \text{διαφορετικά (unanswerable query)} \end{cases} \quad (1.3.5)$$

Το σύστημα οφείλει να εκτιμήσει το z_t μέσω μιας δυαδικής απόφασης $\hat{z}_t \in \{0, 1\}$. Στο προτεινόμενο σύστημα, κάθε κριτής j αποφαινεται για την απαντησιμότητα με βαθμό βεβαιότητας c_j , και η στροφή κρίνεται μη απαντήσιμη όταν κάποιος κριτής δηλώνει ανεπάρκεια στοιχείων με βεβαιότητα τουλάχιστον ίση με ένα κατώφλι βαθμονόμησης τ :

$$\hat{z}_t = \begin{cases} 0, & \text{εάν } \exists j : \text{ο κριτής } j \text{ δηλώνει ανεπάρκεια με } c_j \geq \tau \\ 1, & \text{διαφορετικά} \end{cases} \quad (1.3.6)$$

Η τελική απόκριση προκύπτει ως:

$$y_t = \begin{cases} \mathcal{G}(q_t, H_t, \mathcal{D}_t), & \text{εάν } \hat{z}_t = 1 \\ \text{«Δεν διαθέτω επαρκείς πληροφορίες για να απαντήσω»,} & \text{εάν } \hat{z}_t = 0 \end{cases} \quad (1.3.7)$$

Το σφάλμα στην εκτίμηση του z_t παρουσιάζει έντονη ασυμμετρία: τα ψευδώς θετικά αποτελέσματα ($\hat{z}_t = 1$ ενώ $z_t = 0$) αναγκάζουν το MFM να υποπέσει σε πραγματολογικές ψευδαισθήσεις λόγω της τάσης συμμόρφωσης (compliance bias), ενώ τα ψευδώς αρνητικά μειώνουν δραστικά τη χρησιμότητα του συστήματος. Όπως δείχνουμε στην Ενότητα 1.5.4, η ασυμμετρία αυτή δεν είναι θεωρητική μόνο: στο πραγματικό σύστημα εκδηλώνεται ως ισχυρή μεροληψία αποδοχής (acceptance bias) προς το $\hat{z}_t = 1$.

1.3.3 Διατύπωση ως Πρόβλημα Ενιαίας Βελτιστοποίησης

Η συνολική αρχιτεκτονική στοχεύει στη μεγιστοποίηση της αναμενόμενης χρησιμότητας της απόκρισης υπό μια πολυδιάστατη συνάρτηση κόστους:

$$\mathcal{O}^* = \arg \max_{\mathcal{R}, \mathcal{G}} \mathbb{E}_{(q_t, H_t) \sim \mathcal{X}} [\mathcal{U}(y_t, y_t^*, \mathcal{D}_t, \mathcal{D}_t^*)] \quad (1.3.8)$$

Η συνάρτηση χρησιμότητας $\mathcal{U}$ αναλύεται σε τέσσερις ανεξάρτητους πυλώνες:

$$\mathcal{U} = w_1 \cdot \text{NDCG}(\mathcal{D}_t, \mathcal{D}_t^*) + w_2 \cdot \text{Faithfulness}(y_t, \mathcal{D}_t) + w_3 \cdot \text{Extractive_F1}(y_t, y_t^*) + w_4 \cdot \Phi(\hat{z}_t, z_t) \quad (1.3.9)$$

όπου το Φ ανταμείβει τις σωστά βαθμονομημένες αποφάσεις της πύλης απαντησιμότητας (συμφωνία του $\hat{z}_t$ με το z_t). αφού η $\mathcal{U}$ μεγιστοποιείται, όλοι οι όροι εκφράζονται ως ανταμοιβές. Τα βάρη $w_1, \dots, w_4$ δεν εκτιμώνται αριθμητικά: η διατύπωση είναι εννοιολογική. Λόγω της μη διαφορίσιμης φύσης των μετρικών κειμένου και της ανάκτησης, η βελτιστοποίηση αυτή δεν επιδιώκεται μέσω end-to-end gradient descent, αλλά προσεγγίζεται μέσω σύνθετων agentic pipelines και στοχευμένης μηχανικής προτροπών (prompt engineering), όπως περιγράφεται στην Ενότητα 1.4.

1.3.4 Ιδιαιτερότητες του Πολύστροφου Περιβάλλοντος

Το πολύστροφο RAG εισάγει τρεις θεμελιώδεις ακαδημαϊκές προκλήσεις:

- **Χάσμα Λεξιλογίου (Vocabulary Gap):** Τα ερωτήματα μεταγενέστερων στροφών είναι σύντομα και ελλιπτικά. Η απουσία ρητών λέξεων-κλειδιών καθιστά τους κλασικούς ανακτητές (π.χ. BM25) ανίκανους να γεφυρώσουν τη σημασιολογική απόσταση με το corpus.
- **Σωρευτική Διάδοση Σφαλμάτων (Error Cascade):** Σε έναν πραγματικό βοηθό, εάν η συνάρτηση $\mathcal{R}$ αποτύχει στη στροφή $t - 1$, ο θόρυβος ενσωματώνεται στο H_t μέσω της απάντησης του συστήματος, και η επόμενη αναδιατύπωση βασίζεται σε μολυσμένα συμπραζόμενα. Το MTRAGEval παρέχει το ιστορικό αναφοράς σε κάθε στροφή, οπότε ο μηχανισμός αυτός δεν ενεργοποιείται στην αξιολόγησή μας· παραμένει όμως η δυσκολία επίλυσης αναφορών σε προηγούμενες στροφές.
- **Μετατόπιση Πλαισίου (Context Drift):** Η δυναμική εναλλαγή θεμάτων εντός του ίδιου διαλόγου απαιτεί από το σύστημα να απομονώνει το σχετικό ιστορικό και να αγνοεί τις ξεπερασμένες πληροφορίες.

1.3.5 Κεντρική Υπόθεση Εργασίας

Η παρούσα διπλωματική εργασία θεμελιώνεται πάνω στην εξής κεντρική ερευνητική υπόθεση:

«Η συνολική απόδοση ενός end-to-end συστήματος Πολύστροφου RAG φράσσεται άνω (upper-bounded) από τη σταθερότητα της διαδικασίας ανάκτησης (retrieval stability) και τη βαθμονόμηση της πύλης απαντησιμότητας, και όχι από την εγγενή εκφραστική ή συνθετική ικανότητα των σύγχρονων γλωσσικών μοντέλων.»

Συνεπώς, η έρευνα εστιάζει στη σταθεροποίηση του $P(\mathcal{D}_t \mid q_t, H_t)$ μέσω ελεγχόμενης ποικιλότητας ερωτημάτων, παρά στην αναζήτηση ισχυρότερων ή μεγαλύτερων γλωσσικών μοντέλων.

1.3.6 Συσχέτιση με το Benchmark MTRAGEval

Η αξιολόγηση των προτεινόμενων λύσεων πραγματοποιείται στο απαιτητικό περιβάλλον του SemEval-2026 Task 8, το οποίο αντανακλά τις ανωτέρω προκλήσεις σε ρεαλιστική κλίμακα: (α) η συντριπτική πλειονότητα των στροφών (87%) είναι μη αυτοτελείς, με αναφορές αντωνυμίας να εμφανίζονται στο 97% των μη-πρώτων στροφών· (β) το test set περιλαμβάνει σχεδόν τριπλάσιο ποσοστό μη απαντήσιμων στροφών σε σχέση με το development set· και (γ) παρατηρείται έντονη κατανομική μετατόπιση (distribution shift) μεταξύ development και test set τόσο ως προς την αναλογία unanswerable ερωτημάτων όσο και ως προς την κατανομή των θεματικών πεδίων (domains). Ο Πίνακας 1.2 συνοψίζει τα κρίσιμα αυτά μεγέθη.

Χαρακτηριστικό	Development	Test
Συνομιλίες	110	507
Σύνολο αξιολογούμενων στροφών	842	507
Μέσος αριθμός στροφών/συνομιλία	7.7	1.0
Μη αυτοτελείς στροφές	87%	—
Απαντήσεις ή μερικώς απαντήσεις	92.3%	74.4%
Μη απαντήσεις	6.5%	19.1%
Συνομιλιακές / λοιπές	1.2%	6.5%

Πίνακας 1.2: Σύγκριση development και test set στο MTRAGEval. Η σχεδόν τριπλάσια αύξηση του ποσοστού μη απαντήσιμων στροφών στο test set αποτελεί την κύρια πηγή της κατανομικής μετατόπισης που αναλύεται στην Ενότητα 1.5.5. Στο test set, 377 στροφές διαθέτουν κρίσεις συνάφειας για το Task A και 97 είναι μη απαντήσιμες· η κατηγορία των υπόλοιπων 33 στροφών (6.5%) δεν μπόρεσε να ανακτηθεί από τα διαθέσιμα αρχεία.

1.3.7 Ερευνητικά Ερωτήματα

Με βάση τη διατύπωση του προβλήματος, η εργασία επιχειρεί να απαντήσει στα εξής τέσσερα ερευνητικά ερωτήματα (Research Questions):

- RQ1:** Μπορεί η εισαγωγή στοχευμένης ποικιλότητας ερωτημάτων (query diversity) σε έναν ενιαίο ανακτητή να υποκαταστήσει ή να υπερβεί τη σύνθεση ετερογενών μοντέλων ανάκτησης (retriever diversity);
- RQ2:** Σε ποιο βαθμό η αποσύνθεση της παραγωγής με εισαγωγή σταδίου εξαγωγής αποσπασμάτων (verbatim span extraction) συμβάλλει στον περιορισμό των πραγματολογικών ψευδαισθήσεων;
- RQ3:** Ποια είναι η επίδραση της κατανομικής μετατόπισης των unanswerable ερωτημάτων στην ευαισθησία των πυλών απαντησιμότητας;
- RQ4:** Μπορεί η επαναβαθμολόγηση μέσω MGM (LLM-based reranking) να προσφέρει μετρήσιμο όφελος έναντι εξειδικευμένων cross-encoder μοντέλων ανάκτησης, όταν η ανάκληση του πρώτου σταδίου ανάκτησης πλησιάζει τον κορεσμό;

1.4 Προτεινόμενο Σύστημα

1.4.1 Επισκόπηση Αρχιτεκτονικής

Η αρχιτεκτονική του προτεινόμενου συστήματος **AILS-NTUA** σχεδιάστηκε με γνώμονα την αντιμετώπιση των εξαρτήσεων μεταξύ στροφών και της μετατόπισης πλαισίου (context drift) σε πολύστροφα περιβάλλοντα RAG. Η σχεδιαστική φιλοσοφία του συστήματος αποκλίνει από τις παραδοσιακές προσεγγίσεις ετερογενούς σύνθεσης μοντέλων και βασίζεται σε δύο θεμελιώδεις αρχιτεκτονικές αρχές:


- **Ποικιλότητα Ερωτημάτων έναντι Ποικιλότητας Ανακτητών (Query-Diversity-over-Retriever-Diversity):** Αντί για τη χρήση ενός υπολογιστικά δαπανηρού ensemble διαφορετικών ανακτητών (dense και sparse), το σύστημα σταθεροποιεί τον χώρο ανάκτησης εκδίδοντας πολλαπλές, συμπληρωματικές τροχιές συλλογιστικής (prompts) προς έναν ενιαίο, βέλτιστα ευθυγραμμισμένο με το σώμα κειμένου (corpus-aligned) ανακτητή.
- **Καθυστερημένη Ανάλυση Δέσμευσης (Deferred Commitment):** Ο αγωγός παραγωγής αποσυνδέεται από την άμεση σύνθεση απάντησης. Η τελική απόκριση διαμορφώνεται ως μια πολυσταδιακή agentic διαδικασία, η οποία περιλαμβάνει την απομόνωση αποδείξεων σε επίπεδο πρότασης, τη δημιουργία εναλλακτικών υποψηφίων και την τελική επιλογή μέσω ενός συστήματος πολλαπλών εξειδικευμένων κριτών (multi-judge framework).

Η ολοκληρωμένη αρχιτεκτονική οργανώνεται σε τρεις λειτουργικές ενότητες που αντιστοιχούν στις προδιαγραφές του διαγωνισμού: τον Αγωγό Ανάκτησης Πολλαπλών Στρατηγικών (**Task A**, Σχήμα 1.4.1), τον Πολυσταδιακό Αγωγό Παραγωγής (**Task B**, Σχήμα 1.4.2), και το Ενοποιημένο Σύστημα RAG με Πύλη Απαντησιμότητας (**Task C**, Σχήμα 1.4.3).

1.4.2 Αγωγός Ανάκτησης Πολλαπλών Στρατηγικών (Task A)

Ο αγωγός ανάκτησης εκμεταλλεύεται την ικανότητα των MGM να αναλύουν το ιστορικό H_t και να αναδιατυπώνουν το τρέχον ελλιπές ερώτημα q_t υπό πέντε διακριτές, συμπληρωματικές οπτικές γωνίες, με στόχο τον περιορισμό του vocabulary gap:

1. **Ελάχιστη Αναδιατύπωση (Minimal Reformulation):** Εστιάζει αποκλειστικά στην επίλυση αναφορών (coreference resolution) και τη συντακτική συμπλήρωση των ελλείψεων, διατηρώντας τη δομή του αρχικού ερωτήματος.
2. **Corpus-Ειδική Αναδιατύπωση (Corpus-Specific):** Εμπλουτίζει το ερώτημα με εξειδικευμένη τεχνική ορολογία και συνώνυμα που ταιριάζουν με το συγκεκριμένο θεματικό πεδίο (π.χ. FiQA, Cloud).
3. **Υποθετικό Έγγραφο (HyDE):** Παράγει μια ιδεατή, zero-shot απάντηση στο ερώτημα, μετατοπίζοντας την αναζήτηση από τον χώρο των ερωτήσεων στον χώρο των απαντήσεων του corpus.
4. **Αλυσίδα Σκέψης (Chain-of-Thought - CoT):** Παράγει μια σύντομη λογική ανάλυση των επιμέρους πληροφοριακών αναγκών που πρέπει να ικανοποιηθούν για να απαντηθεί το q_t .
5. **Στόχευση Λέξεων-Κλειδιών (Anchor Keywords):** Εξάγει ονοματοποιημένες οντότητες και στατικά λεκτικά triggers που λειτουργούν ως άγκυρες (anchors) για τον εντοπισμό των εγγράφων.



Σχήμα 1.4.1: Αγωγός ανάκτησης Task A: πέντε συμπληρωματικές αναδιατυπώσεις προωθούνται ανεξάρτητα στον ανακτητή ELSER v1, ακολουθεί υβριδική επαναβαθμολόγηση και τελικά ιεραρχική σύντηξη (Nested RRF).

Διαδικασία Ανάκτησης και Επαναβαθμολόγησης: Κάθε μία από τις πέντε αναδιατυπώσεις προωθείται ανεξάρτητα στον μαθητό αραιό ανακτητή **ELSER v1**, ο οποίος επιστρέφει τα κορυφαία $N = 100$ αποσπάσματα ανά αναδιατύπωση. Στη συνέχεια, τα κορυφαία 60 έγγραφα κάθε λίστας επεξεργάζονται από ένα cross-encoder μοντέλο επαναβαθμολόγησης (**Cohere Rerank v4**), του οποίου η βαθμολογία συνδυάζεται με την αρχική κατάταξη του ανακτητή μέσω σταθμισμένης RRF:

$$\text{Score}(d) = \frac{1}{k + r_E(d)} + \alpha \cdot \frac{1}{k + r_R(d)} \quad (1.4.1)$$

όπου r_E, r_R οι κατατάξεις ανακτητή και reranker αντίστοιχα, k ελέγχει τη φθίνουσα βαρύτητα ανά θέση και α σταθμίζει τα δύο σήματα ($k = 60, \alpha = 0.5$ στη βαθμονομημένη ρύθμιση του συστήματος).

Ιεραρχική Σύντηξη Κατάταξης (Nested RRF): Για τη σταθερή ενοποίηση των πέντε επαναβαθμολογημένων κατατάξεων, εισάγεται ένας αλγόριθμος Ιεραρχικής Σύντηξης δύο επιπέδων. Ο σχεδιασμός βασίζεται στην εκτίμηση ότι οι στρατηγικές HyDE, CoT και Anchor-KeyWord είναι πιο ασταθείς ανά στροφή και θεματικό πεδίο, ενώ οι Minimal και Corpus-Specific παράγουν πιο σταθερές κατατάξεις· η διακύμανση αυτή δεν μετρήθηκε άμεσα. Στο **Επίπεδο 1**, οι τρεις διερευνητικές στρατηγικές συγχωνεύονται μέσω RRF για τη διαμόρφωση μιας ενδιάμεσης κατάταξης «Ασθενούς Συναινέσης» (Weak Consensus). Στο **Επίπεδο 2**, η κατάταξη αυτή συντίθεται μέσω βεβαρυμμένης RRF με τις δύο σταθερές στρατηγικές, χρησιμοποιώντας βάρη βαθμονομημένα ανά θεματικό πεδίο, παράγοντας την τελική κατάταξη εγγράφων D_t :

$$\text{Score}_{\text{final}}(d) = \sum_s w_s^{(c)} \cdot \frac{1}{k^{(c)} + r_s(d)} \quad (1.4.2)$$

όπου s διατρέχει τις δύο σταθερές στρατηγικές και την ενδιάμεση κατάταξη Weak Consensus, και $w_s^{(c)}, k^{(c)}$ είναι παράμετροι εξαρτώμενες από το εκάστοτε corpus c .


1.4.3 Πολυσταδιακός Αγωγός Παραγωγής (Task B)

Όταν το σύστημα τροφοδοτείται με ένα προκαθορισμένο, έγκυρο σύνολο εγγράφων αναφοράς, η παραγωγή απάντησης εκτελείται μέσω ενός αυστηρά δομημένου agentic pipeline πέντε σταδίων (Σχήμα 1.4.2):

1. **Προκαταρκτικός Έλεγχος Απαντησιμότητας (Answerability Check):** Ένα γρήγορο φίλτρο (gate) εξετάζει αν τα έγγραφα αναφοράς επαρκούν για την κάλυψη του ερωτήματος, αποτρέποντας την ενεργοποίηση των επόμενων, κοστοβόρων σταδίων αν η στροφή είναι unanswerable.
2. **Εξαγωγή Αποδεικτικών Εκτάσεων (Evidence Span Extraction):** Το MGM αναλύει τα έγγραφα και απομονώνει αυτούσιες (*verbatim*) τις συγκεκριμένες προτάσεις ή φράσεις που περιέχουν την αποδεικτική πληροφορία (έως 8 αποσπάσματα). Αυτό το στάδιο «φιλτράρει» τον περιβάλλοντα θόρυβο και εξαναγκάζει το μοντέλο σε αυστηρή πραγματολογική αγκύρωση (grounding).
3. **Παραγωγή Διπλών Υποψηφίων (Dual-Candidate Drafting):** Παράγονται παράλληλα δύο διαφορετικά προσχέδια απαντήσεων από το μοντέλο: ένα *ντετερμινιστικό* προσχέδιο ($T=0.0$) με έμφαση στην ακριβή μεταφορά των δεδομένων, και ένα *στοχαστικό* προσχέδιο ($T=0.1$) με στόχο τη βελτίωση της συνομιλιακής ροής και της φυσικότητας του λόγου.
4. **Επιλογή Απάντησης βάσει Πολλαπλών Κριτών (Multi-Judge Selection):** Τα δύο προσχέδια αξιολογούνται από ένα σχήμα δύο εξειδικευμένων LLM κριτών:
 - *Τεχνικός Κριτής (Technical Judge):* Ελέγχει την πραγματολογική ορθότητα και την απουσία αντιφάσεων έναντι των εξαχθέντων spans.
 - *Κριτής Ικανοποίησης (User Satisfaction Judge):* Καλείται σε στοχαστικό υποσύνολο στροφών (60%) και αξιολογεί αν η απάντηση καλύπτει πλήρως την πληροφοριακή ανάγκη του χρήστη με φυσικό τρόπο.

Η τελική επιλογή ενσωματώνει επιπλέον έναν όρο *Διαμόρφωσης Εκχύλισης* (Extractiveness Shaping), ο οποίος τιμωρεί τόσο απαντήσεις επιρρεπείς σε ψευδαισθήσεις (πολύ χαμηλό *verbatim overlap* με τα spans) όσο και υπερβολικά κυριολεκτικές αντιγραφές.

5. **Μικροδιορθώσεις και Μορφοποίηση:** Η επιλεγείσα απάντηση υφίσταται τελικό συντακτικό έλεγχο για την αφαίρεση περιττών εκφράσεων εισαγωγής (π.χ. «Βάσει του κειμένου...») και την ευθυγράμμιση του μήκους της με τον στόχο που ορίζεται από τον τύπο ερώτησης.



Σχήμα 1.4.2: Αγωγός παραγωγής Task B: αλυσίδα πέντε σταδίων που αναβάλλει τη δέσμευση στην τελική απάντηση μέχρι τη συμφωνία πολλαπλών κριτών.


1.4.4 Ολοκληρωμένο Σύστημα RAG (Task C)

Στο end-to-end σενάριο (Task C), οι δύο ανωτέρω αγωγοί ενοποιούνται (Σχήμα 1.4.3). Σε αντίθεση με το Task A, όπου ανακτώνται $k = 10$ αποσπάσματα, εδώ το σύστημα περιορίζεται σκόπιμα στα κορυφαία $k = 3$ αποσπάσματα — επιλογή που μειώνει τον θόρυβο στην παραγωγή σε συνθήκες αβέβαιης ανάκτησης (βλ. Ενότητα 1.5.4). Για τον περιορισμό των ψευδαισθήσεων, το σύστημα εισάγει μια σύνθετη **Πύλη Απαντησιμότητας Πολλαπλών Επιπέδων (Multi-Layer Answerability Gate)**.

Αντί της χρήσης ενός μονού κριτή, η απαντησιμότητα αξιολογείται σε τρία διαφορετικά επίπεδα αφαίρεσης:

- **Κριτής Εγγράφου (Document Judge):** Αξιολογεί τη συνολική συνάφεια των ανακτηθέντων κειμένων με το διαλογικό ιστορικό.
- **Κριτής Αποσπάσματος (Span Judge):** Αποφαινεται για το αν τα εξαχθέντα verbatim spans επαρκούν δομικά για να στηρίξουν μια απάντηση.
- **Κριτής Απάντησης (Answer Judge):** Ελέγχει το τελικό προσχέδιο σε σχέση με το ερώτημα για να εντοπίσει partial ή ελλιπείς πληροφορίες.

Οι αποφάσεις των τριών κριτών συνδυάζονται μέσω ενός μηχανισμού *στάθμισης εμπιστοσύνης με δικαίωμα αρνησικυρίας απόκλισης* (confidence-weighted voting with dissenter override): εάν έστω και ένας κριτής δηλώσει με βεβαιότητα τουλάχιστον $\tau=0.7$ ότι τα στοιχεία είναι ανεπαρκή, το προσχέδιο απορρίπτεται και επιστρέφεται μια τυποποιημένη άρνηση απάντησης· διαφορετικά, οι αποφάσεις συνδυάζονται με ψηφοφορία σταθμισμένη ως προς τη βεβαιότητα. Επειδή ο Κριτής Απάντησης χρειάζεται προσχέδιο, η εξαγωγή spans και η παραγωγή των δύο υποψηφίων προηγούνται της πύλης· οι απαντήσιμες στροφές συνεχίζουν στα στάδια επιλογής και μικροδιόρθωσης του Task B. Οι τρεις κριτές χρησιμοποιούν το ίδιο πρότυπο προτροπής, αλλά λαμβάνουν διαφορετική είσοδο (αποσπάσματα, spans ή προσχέδιο).



Σχήμα 1.4.3: Ενοποιημένος αγωγός Task C: η εξαγωγή spans και η σύνταξη προσχεδίων εκτελούνται στα ανακτημένα αποσπάσματα· στη συνέχεια μια πύλη τριών κριτών είτε επιτρέπει στη στροφή να ολοκληρώσει τα υπόλοιπα στάδια του Task B είτε αντικαθιστά το προσχέδιο με τυποποιημένη άρνηση.

1.4.5 Σχεδιαστικές Επιλογές και Συνεισφορά

Η αρχιτεκτονική συνεισφορά του συστήματος AILS-NTUA συνοψίζεται στις ακόλουθες καινοτόμες σχεδιαστικές επιλογές:

- **Αντικατάσταση των Ετερογενών Ensembles:** Ένδειξη, στο development set, ότι η στοχευμένη υπολογιστική επένδυση στην ποικιλότητα των ερωτημάτων (query diversity) υπερτερεί της χρήσης πολλών διαφορετικών μοντέλων ανάκτησης.
- **Αλγόριθμος Nested RRF:** Εισαγωγή ιεραρχικής δομής στη σύντηξη κατατάξεων, η οποία συγκεντρώνει τις διερευνητικές στρατηγικές σε μία ενδιάμεση κατάταξη πριν τη συνδυάσει με τις συντηρητικές.
- **Αποσύνθεση Παραγωγής μέσω Spans:** Η μετάβαση από το text-to-text RAG στο span-guided generation, γεγονός που ελαχιστοποιεί τον θόρυβο εισόδου στον generator.
- **Βαθμονομημένο Multi-Judge Voting:** Η ανάπτυξη μιας πύλης απαντησιμότητας πολλών επιπέδων, σχεδιασμένης να περιορίζει τις ψευδαισθήσεις πριν από την τελική δέσμευση της απάντησης (inference commitment).

1.5 Πειραματικά Αποτελέσματα

Η παρούσα ενότητα παρουσιάζει την ποσοτική και ποιοτική αξιολόγηση του συστήματος AILS-NTUA. Αναλύεται η πειραματική διάταξη, παρατίθενται οι επίσημες επιδόσεις στα leaderboards του SemEval-2026 Task 8, και πραγματοποιείται εκτενής ανάλυση συνιστωσών (ablation studies) για τον προσδιορισμό της συνεισφοράς κάθε αρχιτεκτονικής επιλογής στα Tasks A, B και C.

1.5.1 Πειραματική Διάταξη

Η αξιολόγηση του συστήματος πραγματοποιήθηκε στο επίσημο benchmark του MTRAGEval (SemEval-2026 Task 8). Το σύνολο δεδομένων περιλαμβάνει 110 πολύστροφες συνομιλίες που εκτείνονται σε συνολικά 842 στροφές (turns) και καλύπτουν τέσσερα ετερογενή θεματικά πεδία (domains): *FiQA* (οικονομικά), *ClapNQ* (γενικές γνώσεις), *Govt* (κυβερνητικά έγγραφα) και *Cloud* (τεχνική υποστήριξη). Η ετερογένεια αυτή είναι σχόπιμη και δομικά σημαντική: όπως φαίνεται στον Πίνακα 1.3, τα τέσσερα corpora διαφέρουν σημαντικά ως προς τη μέση πυκνότητα αποσπασμάτων ανά έγγραφο — από ατομικά έγγραφα-αναρτήσεις στο FiQA έως εκτενή εγκυκλοπαιδικά λήμματα στο ClapNQ — στρεσάροντας διαφορετικές πτυχές του μηχανισμού ανάκτησης. Η αξιολόγηση του Task A (Passage Retrieval) περιορίζεται στις 777 στροφές που χαρακτηρίζονται ως απαντήσιμες (answerable) ή μερικώς απαντήσιμες (partially answerable).

Χαρακτηριστικό	ClapNQ	FiQA	Govt	Cloud
Τύπος πεδίου	Εγκυκλοπαιδικό	Οικονομικό φόρουμ	Κυβερνητικά κείμενα	Τεχνική τεκμηρίωση
Σύνολο εγγράφων	4,293	57,638	7,661	8,578
Σύνολο αποσπασμάτων	183,408	61,022	49,607	72,442
Μέσος όρος αποσπ./έγγρ.	42.7	1.1	6.5	8.4
Κύρια πηγή	Wikipedia	StackExchange	Κυβ. ιστότοποι	IBM Cloud Docs

Πίνακας 1.3: Στατιστικά δομικής ετερογένειας του corpus MTRAG ανά θεματικό πεδίο.

Υπερπαράμετροι και Ρύθμιση Συστήματος: Η βαθμονόμηση όλων των υπερπαραμέτρων πραγματοποιήθηκε αποκλειστικά στο development set. Στον αγωγό ανάκτησης, κάθε μία από τις 5 LLM-based αναδιατυπώσεις εκδίδει ερώτημα προς τον ανακτητή **ELSER v1**, επιστρέφοντας τα κορυφαία 100 αποσπάσματα κειμένου. Η επαναβαθμολόγηση εκτελείται μέσω του μοντέλου **Cohere Rerank v4** για τα 60 επικρατέστερα έγγραφα, με σταθερά RRF $k = 60$, ενώ η ιεραρχική συγχώνευση (Nested RRF) χρησιμοποιεί σταθερές εξομάλυνσης $k_{\text{internal}} = 40$ στο Επίπεδο 1 και k_{final} από 20 έως 60 ανά θεματικό πεδίο στο Επίπεδο 2.

Υπολογιστική Δρομολόγηση Μοντέλων (Model Routing): Για τη διαχείριση του οικονομικού κόστους των API, υιοθετήθηκε μια αρχιτεκτονική δρομολόγησης βάσει της χρησιμότητας του ρόλου (role-based model routing):

- **DeepSeek-V3.2:** Χρησιμοποιείται για τις εργασίες υψηλής δομικής ακρίβειας, όπως η εξαγωγή των verbatim αποδεικτικών εκτάσεων (span extraction) και η υλοποίηση του Τεχνικού Κριτή (Technical Judge).
- **GPT-4o:** Αξιοποιείται για την Παραγωγή Υποψηφίων Απαντήσεων (Dual-Candidate Drafting) και για τους τρεις κριτές της πύλης απαντησιμότητας του Task C.
- **GPT-4o-mini:** Χρησιμοποιείται για υπολογιστικά ελαφριές εργασίες, όπως ο προκαταρκτικός έλεγχος απαντησιμότητας, ο Κριτής Ικανοποίησης Χρήστη και οι τελικές μικροδιορθώσεις.

1.5.2 Αποτελέσματα Ανάκτησης — Task A

Συγκριτική Ανάλυση Μοντέλων Ανάκτησης: Η αξιολόγηση εννέα ανακτητών (λεξιλογικών, πυκνών και learned sparse) στο development set, χωρίς αναδιατύπωση ερωτήματος, κατέδειξε την ξεκάθαρη υπεροχή των learned sparse αναπαραστάσεων. Ο ανακτητής ELSER v1 πέτυχε $Recall@5 : 0.483$ και $nDCG@5 : 0.444$, υπερτερώντας του ισχυρότερου πυκνού ανακτητή (Cohere Embed v4, $R@5=0.397$) κατά +8.6 ποσοστιαίες μονάδες, και του κλασικού λεξιλογικού BM25 ($R@5=0.153$) κατά +33.0 ποσοστιαίες μονάδες στα ίδια 777 ερωτήματα. Μέρος του πλεονεκτήματος αυτού μπορεί να οφείλεται στο ότι οι κρίσεις συνάφειας του MTRAG παρήχθησαν κυρίως από αποσπάσματα του ELSER. Το αποτέλεσμα είναι συνεπές με την υπόθεση ότι η επέκταση όρων (term expansion) σε επίπεδο corpus μειώνει το vocabulary gap χωρίς τον σημασιολογικό θόρυβο των cross-domain dense embeddings, αλλά δεν μπορεί να διαχωριστεί πλήρως από την παραπάνω μεροληψία των κρίσεων.

Ανάλυση Συνεισφοράς Αναδιατυπώσεων (Query Reformulation Ablation): Ο Πίνακας 1.4 καταγράφει τη σωρευτική επίδραση της σταδιακής προσθήκης των πέντε στρατηγικών αναδιατύπωσης πάνω στον ανακτητή ELSER v1. Ο πλήρης συνδυασμός και των πέντε στρατηγικών υπό το αλγόριθμο Nested RRF αυξάνει το $Recall@5$ κατά +25.7% σε σχέση με τη βασική γραμμή χωρίς αναδιατύπωση. Σε επίπεδο μεμονωμένης στρατηγικής, η *Corpus-Specific* αναδεικνύεται ως η ισχυρότερη επιλογή στα πεδία ClapNQ ($R@5=0.637$) και FiQA ($R@5=0.491$), η *Chain-of-Thought* υπερτερεί στο Govt ($R@5=0.580$), ενώ η *Minimal* παραμένει η πλέον αποδοτική στο τεχνικό domain Cloud ($R@5=0.463$) — το HyDE, αντίθετα, αποδεικνύεται συστηματικά η ασθενέστερη μεμονωμένη στρατηγική σε όλα τα domains, χρήσιμη όμως ως συμπληρωματικό σήμα εντός του σχήματος Nested RRF. Ο πλήρης συνδυασμός ($R@5=0.607$) υπερβαίνει κατά 6.6 μονάδες ακόμη και την καλύτερη μεμονωμένη στρατηγική· επειδή όμως περιλαμβάνει και την επαναβαθμολόγηση, η διαφορά είναι συνεπής με τη συμπληρωματικότητα των στρατηγικών χωρίς να την απομονώνει.

Διαμόρφωση Ανάκτησης	Recall@5	Σχετική Βελτίωση (Δ)
Μη ενισχυμένη βάση (αρχικό ερώτημα)	0.483	—
+ Ελάχιστη Αναδιατύπωση (Minimal)	0.527	+9.1%
+ Corpus-Ειδική Επέκταση	0.558	+15.5%
+ Αλυσίδα Σκέψης (CoT)	0.573	+18.6%
+ Υποθετικό Έγγραφο (HyDE)	0.584	+20.9%
+ Στόχευση Λέξεων-Κλειδιών	0.591	+22.4%
+ Σύντηξη Nested RRF (πλήρες σύστημα)	0.607	+25.7%

Πίνακας 1.4: Σωρευτική ανάλυση συνεισφοράς (ablation) των πέντε στρατηγικών αναδιατύπωσης ερωτήματος στο development set. Οι γραμμές είναι σωρευτικές, οπότε κάθε αύξηση εξαρτάται από τη σειρά προσθήκης· ο πίνακας δεν απομονώνει τη συνεισφορά του reranker ή της ιεραρχικής σύντηξης.

Το Παράδοξο της Σύνθεσης Ανακτητών (Retriever Ensemble Paradox): Ένα από τα πιο σημαντικά ευρήματα της εργασίας είναι ότι η σύνθεση ετερογενών μοντέλων (π.χ. ELSER + BM25 + Dense μέσω επίπεδης RRF) υποβαθμίζει την ακρίβεια κορυφής (top-rank precision), παρότι βελτιώνει την οριακή ανάκληση σε μεγάλο βάθος. Όπως φαίνεται στον Πίνακα 1.5, στο πλήρως βελτιστοποιημένο στάδιο του αγωγού (ELSER με τις πέντε αναδιατυπώσεις), η προσθήκη όλων των εναλλακτικών ανακτητών αυξάνει το $Recall@100$ από 0.901 σε 0.926, ταυτόχρονα όμως μειώνει το $Recall@5$ από 0.607 σε 0.569. Μια εξήγηση είναι ότι τα μοναδικά χρυσά έγγραφα που εισάγουν οι εναλλακτικοί ανακτητές εμφανίζονται σε μέση θέση από 27,5 έως 54,2 μετά τη σύντηξη (39,5 για όλους μαζί), κάτω δηλαδή από το όριο top-10, ενώ ταυτόχρονα η

σύντηξη μετατοπίζει οριακά σχετικά αποτελέσματα του ELSER εκτός των κορυφαίων θέσεων. Η προτεινόμενη προσέγγιση *ενιαίου ανακτητή με ποικιλότητα ερωτημάτων* αποφεύγει αυτή την παγίδα, καθώς όλα τα σήματα παραμένουν ευθυγραμμισμένα με τον ίδιο χώρο βαθμολόγησης. Σημειώνεται ότι οι κρίσεις συνάφειας του MTRAG παρήχθησαν κυρίως από αποσπάσματα που ανέκτησε το ELSER· αποσπάσματα που φέρνουν μόνο οι υπόλοιποι ανακτητές είναι πιθανότερο να μην έχουν κριθεί και να μετρώνται ως άσχετα. Η μεροληψία αυτή μπορεί από μόνη της να συμβάλλει στο παράδοξο, και δεν ποσοτικοποιήθηκε.

Διαμόρφωση (τελικό στάδιο, 5 αναδιατυπώσεις)	R@5	R@100	Μέση θέση μοναδικών χρυσών εγγρ.
ELSER v1 (μόνο)	0.607	0.901	—
+ Cohere Embed (dense)	0.582 ↓	0.925 ↑	37.0
+ SPLADE	0.592 ↓	0.919 ↑	54.2
+ BM25	0.536 ↓	0.915 ↑	27.5
+ Όλοι οι ανακτητές	0.569 ↓	0.926 ↑	39.5

Πίνακας 1.5: Το παράδοξο σύνθεσης ανακτητών: η προσθήκη εναλλακτικών ανακτητών βελτιώνει το $R@100$ αλλά υποβαθμίζει συστηματικά το $R@5$.

Σταθερότητα ανά Στροφή Διαλόγου: Η απόδοση ανάκτησης εξαρτάται έντονα από τη θέση της στροφής (Σχήμα 6.2.1). Χωρίς αναδιατύπωση, το $Recall@5$ πέφτει από 0.879 στην πρώτη στροφή σε 0.428 στις στροφές 6+ (σχετική πτώση 51%)· με το πλήρες σύστημα η πτώση περιορίζεται στο 39% (από 0.890 σε 0.540). Η πτώση δεν είναι σταδιακή: συγκεντρώνεται κυρίως μεταξύ της πρώτης στροφής, που είναι εξ ορισμού αυτοτελής, και της δεύτερης, ενώ στη συνέχεια οι καμπύλες μένουν σχεδόν σταθερές. Συνεπώς η επίδραση της θέσης οφείλεται κυρίως στο αν το ερώτημα είναι αυτοτελές ή εξαρτάται από προηγούμενες στροφές (αναφορές αντωνυμίας στο 97% των μη-πρώτων στροφών, συγκριτικές ερωτήσεις-συνέχειες στο 67%). Η αναδιατύπωση περιορίζει, χωρίς να εξαλείφει, το χάσμα αυτό.

1.5.3 Αποτελέσματα Τεκμηριωμένης Παραγωγής — Task B

Ablation Analysis του Agentic Pipeline: Ο Πίνακας 1.6 καταγράφει τη σωρευτική συνεισφορά κάθε σταδίου του πολυσταδιακού αγωγού παραγωγής στο Task B. Η σταδιακή ενσωμάτωση των συνιστωσών οδηγεί σε συνολική αύξηση του Αρμονικού Μέσου (HM) κατά +8.9 μονάδες (0.654 → 0.743) έναντι μίας απλής, μονοβηματικής (greedy) παραγωγής.

Διαμόρφωση Αγωγού	Αρμονικός Μέσος (HM)
Βάση: Μονοβηματική Greedy Παραγωγή ($T=0.0$)	0.654
+ Εξαγωγή Αποδεικτικών Εκτάσεων (Verbatim)	0.688
+ Παραγωγή Δύο Υποψηφίων (τυχαία επιλογή)	0.706
+ Τεχνικός Κριτής	0.725
+ Κριτής Ικανοποίησης Χρήστη (60% δειγματοληψία)	0.738
+ Τελικές Μικροδιορθώσεις	0.743

Πίνακας 1.6: Ανάλυση συνεισφοράς (ablation) του αγωγού παραγωγής Task B στο development set.

Η Κρισιμότητα του Evidence Span Extraction: Η εισαγωγή του σταδίου εξαγωγής αποδεικτικών εκτάσεων αναδεικνύεται ως η *μεμονωμένα* μεγαλύτερη βελτίωση του αγωγού (+0.034 HM, Πίνακας 1.6), μαζί με αύξηση κατά +0.041 στη μετρική πιστότητας χωρίς αναφορά RL_F . Η verbatim απομόνωση των σχετικών προτάσεων περιορίζει την τάση των μοντέλων να ενσωματώνουν άσχετες πληροφορίες (distractors) από το υπόλοιπο σώμα των εγγράφων, εμποδίζοντας έτσι τον generator να «δραπετεύσει» από τα παρεχόμενα στοιχεία.

Αποτίμηση του Σχήματος Πολλαπλών Κριτών: Η εισαγωγή των δύο LLM κριτών (Technical, User Satisfaction) σε συνδυασμό με τον όρο Διαμόρφωσης Εχχύλισης (Extractiveness Shaping) στοχεύει στην εξισορρόπηση της πραγματολογικής ακρίβειας με τη συνομιλιακή φυσικότητα, και κάθε στάδιο προσθέτει θετική συνεισφορά στο ablation του Πίνακα 1.6. Ο όρος εχχύλισης ποινικοποιεί προσχέδια που είτε απομακρύνονται

υπερβολικά από τα εξαχθέντα spans (κίνδυνος ψευδαίσθησης) είτε τα αντιγράφουν σχεδόν αυτολεξεί, ευνοώντας επικάλυψη 4-γραμμάτων εντός της ζώνης [0.28, 0.38], που επιλέχθηκε στο development set (Πίνακας 6.11).

Οικονομική Αποδοτικότητα μέσω Routing: Η δρομολόγηση μοντέλων (DeepSeek-V3.2 για εξαγωγή/τεχνική κρίση, GPT-4o για τη σύνθεση, GPT-4o-mini για ελαφριές εργασίες) είναι σχεδιαστική επιλογή με κίνητρο το κόστος. Με ονομαστικές τιμές API, ο αγωγός του Task B κοστίζει κατά εκτίμηση \$0,010–0,012 ανά στροφή, από τα οποία τα \$0,009 αντιστοιχούν στις δύο κλήσεις του GPT-4o, έναντι εκτιμώμενων \$0,024 αν όλα τα στάδια χρησιμοποιούσαν GPT-4o, δηλαδή περίπου 2–2,4 φορές χαμηλότερο κόστος.¹ Δεν διατηρήθηκε ελεγχόμενη σύγκριση ποιότητας με ομοιόμορφη χρήση ενός μοντέλου, οπότε δεν διατυπώνεται ισχυρισμός για την επίδραση της δρομολόγησης στην ποιότητα.

1.5.4 Η Απαντησιμότητα ως Καθοριστικός Παράγοντας — Task C

Η end-to-end αξιολόγηση (Task C) παρουσιάζει απότομη πτώση σε σχέση με την παραγωγή με αποσπάσματα αναφοράς ($HM: 0.7698 \rightarrow 0.5409$ στο test set). Σε συμφωνία με το δημοσιευμένο άρθρο [5], θεωρούμε τη βαθμονόμηση της απαντησιμότητας καθοριστικό παράγοντα υπό την κατανομή του test set: η πύλη αποδέχεται τις περισσότερες μη απαντήσιμες στροφές ακόμη και στο development set και βαθμονομήθηκε σε ποσοστό μη απαντήσιμων 6.5%, ενώ στο test set αντιμετωπίζει 19.1%. Η ανάκτηση παραμένει πάντως σημαντικός παράγοντας. Στο Task C ο generator λαμβάνει μόνο τα τρία πρώτα αποσπάσματα, οπότε το αν τα αποδεικτικά στοιχεία φτάνουν σε αυτόν καθορίζεται από την ακρίβεια κορυφής ($Recall@5=0.607$ στο development set, Πίνακας 1.5) και όχι από την ανάκληση σε βάθος ($Recall@100=0.901$). Επιπλέον, τα σφάλματα ανάκτησης στις κορυφαίες θέσεις αντιστοιχούν στις περισσότερες αποτυχίες του development set που εξετάστηκαν χειροκίνητα (Πίνακας 1.8), σε ένα σύνολο όπου οι μη απαντήσιμες στροφές είναι σπάνιες. Η ανάλυση των επίσημων σκορ του test set ανά κατηγορία απαντησιμότητας θα ποσοτικοποιούσε τις δύο συνεισφορές. Όπως φαίνεται στον Πίνακα 1.7, καμία διαμόρφωση πύλης δεν ξεπερνά το 25% $F1$ στην ανίχνευση μη απαντήσιμων στροφών στο πλήρες development set. Το προτεινόμενο σχήμα πολλαπλών κριτών πετυχαίνει 95.8% ανάκληση στις απαντήσιμες στροφές αλλά μόλις 21.8% στις μη απαντήσιμες, δηλαδή 12 από τις 55 (95% διάστημα Wilson 12,9–34,4%), ένδειξη ισχυρής μεροληψίας αποδοχής (acceptance bias). Η ποιοτική εξέταση των αποφάσεων της πύλης δείχνει ότι οι κριτές Εγγράφου και Αποσπάσματος συχνά επισημαίνουν ανεπαρκή στοιχεία, ενώ ο Κριτής Απάντησης τείνει να αποδέχεται προσχέδια που παραμένουν εύλογα, δίνοντας προτεραιότητα στην ευλογοφάνεια έναντι της επάρκειας των αποδείξεων.

Μέθοδος	Ανάκληση Απαντ.	Ανάκληση Μη Απαντ.	F1 Μη Απαντ.
Πάντα Απάντηση (χωρίς πύλη)	100.0% (777/777)	0.0% (0/55)	0.0%
Αγωγός + Κανόνας Επαλήθευσης	92.3% (717/777)	27.3% (15/55)	23.1%
Πολλαπλοί Κριτές (δικό μας)	95.8% (744/777)	21.8% (12/55)	24.0%

Πίνακας 1.7: Μετρικές ανίχνευσης απαντησιμότητας στο development set (832 στροφές: 777 απαντήσιμες ή μερικώς απαντήσιμες και 55 μη απαντήσιμες· εξαιρούνται οι 10 συνομιλιακές στροφές). Καμία διαμόρφωση που αξιολογήθηκε δεν ξεπερνά το 25% $F1$ στις μη απαντήσιμες στροφές του πλήρους development set.

Ποσοτική Κατανομή Σφαλμάτων και Εξαρτήσεις μεταξύ Στροφών: Ο συγγραφέας εξέτασε χειροκίνητα 50 περιπτώσεις αποτυχίας του development set και απέδωσε σε καθεμία μία κύρια αιτία (Πίνακας 1.8). Οι περιπτώσεις δεν επιλέχθηκαν με τεχνηρωμένη τυχαία διαδικασία και η κατηγοριοποίηση έγινε από έναν σχολιαστή, οπότε τα ποσοστά είναι ενδεικτικά.

Οι αιτίες που σχετίζονται με την ανάκτηση αντιστοιχούν συνολικά στο 72% των περιπτώσεων και η εσφαλμένη εκτίμηση απαντησιμότητας στο 18%. Η δεύτερη κατηγορία ανάκτησης (34%) χρειάζεται προσεκτική ανάγνωση: επειδή το MTRAGEval παρέχει το ιστορικό αναφοράς και όχι τις προηγούμενες απαντήσεις του συστήματος, ένα σφάλμα του συστήματος στη στροφή $t-1$ δεν μπορεί να περάσει στο H_t . Η κατηγορία 34% αφορά επομένως στροφές των οποίων το ερώτημα εξαρτάται από προηγούμενες στροφές και η αναδιατύπωση δεν επέλυσε την εξάρτηση, με αποτέλεσμα να αποτύχει η ανάκτηση στη στροφή t παρότι το ιστορικό είναι σωστό. Οι περιπτώσεις

¹Το δημοσιευμένο άρθρο [5] αναφέρει \$0,008 ανά στροφή και 3× μείωση. Το άθροισμα των εκτιμήσεων ανά στάδιο, με προσμέτρηση και των δύο κλήσεων παραγωγής, δίνει \$0,010–0,012, τιμή που υιοθετείται εδώ.

Αιτία Σφάλματος	Ποσοστό	Κύριο Πεδίο
Σφάλμα ανάκτησης (περιεχόμενο τρέχουσας στροφής)	38%	FiQA
Σφάλμα ανάκτησης (ανεπίλυτη εξάρτηση από προηγούμενες στροφές)	34%	Cloud
Εσφαλμένη εκτίμηση Απαντησιμότητας	18%	Όλα
Καθαρό σφάλμα παραγωγής (σωστά αποσπάσματα)	10%	ClapNQ

Πίνακας 1.8: Κύρια αιτία σε 50 περιπτώσεις αποτυχίας του Task C που εξετάστηκαν χειροκίνητα (development set, ένας σχολιαστής). Οι αιτίες που σχετίζονται με την ανάκτηση αντιστοιχούν στο 72%.

αυτές υποδεικνύουν την επίλυση συναναφοράς και έλλειψης ως σημαντική εναπομένουσα αδυναμία της ανάκτησης, σε συμφωνία με το χάσμα μεταξύ αυτοτελών και μη αυτοτελών ερωτημάτων.

1.5.5 Επίσημα Αποτελέσματα Leaderboard

Στην επίσημη διεθνή αξιολόγηση του SemEval-2026 Task 8, η αρχιτεκτονική **AELS-NTUA** κατέλαβε την 1η θέση στο Task A και τη 2η στο Task B (Πίνακας 1.9):

- **1η Θέση στο Task A (Passage Retrieval):** Το σύστημα πέτυχε την κορυφαία επίδοση με $nDCG@5$: 0.5776, σημειώνοντας διαφορά +20.5% έναντι της ισχυρότερης επίσημης γραμμής βάσης (baseline) του διαγωνισμού, μεταξύ 38 συμμετοχών.
- **2η Θέση στο Task B (Grounded Generation):** Το σύστημα κατέλαβε τη δεύτερη θέση με Αρμονικό Μέσο HM : 0.7698 ($RB_{alg}=0.633$, $RL_F=0.897$, $RB_{llm}=0.832$), σε συμφωνία με τα ευρήματα για το span extraction και το multi-judge framework, μεταξύ 26 συμμετοχών.
- **11η Θέση στο Task C (End-to-End RAG):** Το σύστημα πέτυχε HM : 0.5409 μεταξύ 29 συμμετοχών, μόλις οριακά πάνω από την ισχυρότερη γραμμή βάσης των διοργανωτών (0.5366, +0.004). Η πτώση από το $HM=0.7698$ του Task B οφείλεται κυρίως στη μετρική RB_{alg} ($0.633 \rightarrow 0.400$) και συμφωνεί με την ανάλυση της Ενότητας 1.5.4: η πύλη βαθμονομήθηκε σε development set με ποσοστό μη απαντήσιμων στροφών περίπου ίσο με το ένα τρίτο εκείνου του test set (6.5% έναντι 19.1%, Πίνακας 1.2), οπότε το κατώφλι $\tau=0.7$ δεν ταιριάζει στις συνθήκες του test set. Συμβάλλουν επίσης τα σφάλματα ανάκτησης στις κορυφαίες θέσεις, αφού στον generator φτάνουν μόνο τρία αποσπάσματα. Το αν ένα χαμηλότερο κατώφλι (π.χ. $\tau \approx 0.6$) θα απέδιδε καλύτερα στο test set αποτελεί υπόθεση που δεν μπορεί να ελεγχθεί με μία μόνο υποβολή· στο development set, το $\tau=0.6$ αποδίδει ελαφρώς χειρότερα από το $\tau=0.7$.

Task	Μετρική	Επίδοση	Κατάταξη
A — Ανάκτηση	nDCG@5	0.5776	1/38
B — Παραγωγή	HM	0.7698	2/26
C — End-to-End RAG	HM	0.5409	11/29

Πίνακας 1.9: Επίσημα αποτελέσματα του AELS-NTUA στο test set του SemEval-2026 Task 8.

1.6 Συμπεράσματα και Μελλοντική Εργασία

Η παρούσα ενότητα ολοκληρώνει την εκτεταμένη περίληψη της διπλωματικής εργασίας. Πραγματοποιείται μια συνθετική αποτίμηση των αρχιτεκτονικών συνεισφορών του συστήματος AELS-NTUA, δίνονται ρητές απαντήσεις στα θεμελιώδη ερευνητικά ερωτήματα που καθοδήγησαν την έρευνα, αναλύονται οι εγγενείς περιορισμοί της παρούσας υλοποίησης και χαράσσονται οι μελλοντικές ερευνητικές κατευθύνσεις για τον χώρο των πολύστροφων συστημάτων RAG.

1.6.1 Σύνοψη Συνεισφορών

Η παρούσα εργασία διερεύνησε συστηματικά το πρόβλημα της πολύστροφης Ανάκτησης-Επαυξημένης Παραγωγής (Multi-Turn RAG) υπό το πρίσμα της σταθερότητας ανάκτησης συμφραζομένων (context-aware

retrieval stability) και της αξιόπιστης πραγματολογικής αγκύρωσης αποδείξεων. Σε αντίθεση με τις συμβατικές προσεγγίσεις της βιβλιογραφίας που περιορίζονται στη βελτιστοποίηση μεμονωμένων σταδίων, αναπτύχθηκε μια ενοποιημένη αρχιτεκτονική που διαχωρίζει λειτουργικά τη διατήρηση του διαλογικού ιστορικού, την ανακάλυψη αποδείξεων και την παραγωγή απάντησης υπό περιορισμούς.

Οι κύριες ερευνητικές και τεχνολογικές συνεισφορές της εργασίας συνοψίζονται ως εξής:

- **Αναδιατύπωση ως Πρωτεύον Σήμα Ανάκτησης (Query Diversity):** Στο development set και με βάση τις επίσημες κρίσεις συνάφειας του benchmark, η εισαγωγή στοχευμένης ποικιλότητας ερωτημάτων μέσω πέντε συμπληρωματικών LLM προτροπών πάνω σε έναν ενιαίο, corpus-ευθυγραμμισμένο ανακτητή (ELSER v1) υπερτερεί της σύνθεσης ετερογενών μοντέλων ανάκτησης (retriever ensembles) (Ενότητα 1.5.2).
- **Αλγόριθμος Ιεραρχικής Σύντηξης Κατατάξεων (Nested RRF):** Σχεδιάστηκε μια στρατηγική σύντηξης δύο επιπέδων, η οποία συγκεντρώνει τις διερευνητικές στρατηγικές (HyDE, Chain-of-Thought, Anchor-Keyword) σε μια ενδιάμεση κατάταξη πριν τη συνδυάσει με τις συντηρητικές. Η πλήρης διάταξη ανάκτησης περιορίζει την πτώση της απόδοσης μετά την πρώτη στροφή από 51% σε 39%, χωρίς όμως να έχει απομονωθεί η συνεισφορά της ιεραρχικής σύντηξης αυτής καθαυτής.
- **Διύλιση Πλαισίου μέσω Evidence Span Extraction:** Η εισαγωγή ενός ενδιάμεσου σταδίου verbatim εξαγωγής αποδεικτικών προτάσεων πριν από την παραγωγή περιορίζει την επίδραση των σημασιολογικών παραπλανητών (distractors) και αποτελεί τη μεμονωμένα μεγαλύτερη συνεισφορά στον αγωγό παραγωγής (+0.034 HM στο development set).
- **Agentic Επιλογή Απάντησης Δύο Κριτών:** Ένα σχήμα εξειδικευμένων LLM κριτών (Technical, User Satisfaction) σε συνδυασμό με όρο Διαμόρφωσης Εκχύλισης (Extractiveness Shaping) στοχεύει στην εξισορρόπηση της πραγματολογικής πιστότητας με τη φυσικότητα της συνομιλιακής ροής.
- **Ανάλυση του Task C:** Η πτώση Task B→C στο test set ($HM : 0.7698 \rightarrow 0.5409$) υποδεικνύει ως καθοριστικό παράγοντα τη βαθμονόμηση της πύλης απαντησιμότητας υπό σχεδόν τριπλάσιο ποσοστό μη απαντήσιμων ερωτημάτων, ενώ τα σφάλματα ανάκτησης στις κορυφαίες θέσεις συμβάλλουν σημαντικά· στο development set, όπου οι μη απαντήσιμες στροφές είναι σπάνιες, τα σφάλματα ανάκτησης στις κορυφαίες θέσεις εξηγούν το 72% των αποτυχιών που εξετάστηκαν χειροκίνητα· καμία διαμόρφωση πύλης δεν ξεπερνά το 25% F1 στο πλήρες development set (Πίνακας 1.7).

1.6.2 Απαντήσεις στα Ερευνητικά Ερωτήματα

Τα τέσσερα κεντρικά ερευνητικά ερωτήματα (Research Questions) που διατυπώθηκαν στην Ενότητα 1.3 απαντώνται βάσει των πειραματικών δεδομένων ως εξής:

RQ1: Μπορεί η εισαγωγή στοχευμένης ποικιλότητας ερωτημάτων να υποκαταστήσει τη σύνθεση ετερογενών ανακτητών;

Απάντηση: Ναι, με βάση τις επίσημες κρίσεις συνάφειας. Η ποικιλότητα ερωτημάτων σε έναν ενιαίο ανακτητή υπερτερεί στο development set και αντιστοιχεί στην 1η θέση στο Task A ($nDCG@5 : 0.5776$). Αντίθετα, η προσθήκη εναλλακτικών ανακτητών μειώνει το $Recall@5$, καθώς τα χρυσά έγγραφα που φέρνουν εμφανίζονται σε μέση θέση από 27,5 έως 54,2 μετά τη σύντηξη (Πίνακας 1.5), κάτω δηλαδή από το όριο top-10. Μέρος του φαινομένου μπορεί να οφείλεται στη μεροληψία των κρίσεων συνάφειας υπέρ του ELSER.

RQ2: Σε ποιο βαθμό η εξαγωγή verbatim αποδεικτικών εκτάσεων συμβάλλει στον περιορισμό των ψευδαισθήσεων;

Απάντηση: Στο development set, η εξαγωγή spans αποτελεί τη μεγαλύτερη μεμονωμένη βελτίωση στον αγωγό παραγωγής (+0.034 Αρμονικό Μέσο), μαζί με αύξηση +0.041 στη μετρική πιστότητας χωρίς αναφορά (RLF). Επειδή μια μεταβολή σε μία μόνο συνιστώσα αυξάνει τον αρμονικό μέσο τριών μετρικών μόνο κατά ένα κλάσμα της, το κέρδος +0.034 στον HM δείχνει ότι βελτιώθηκαν και οι μετρικές με αναφορά· η ευφράδεια δεν μετρήθηκε χωριστά. Ο περιορισμός της εισόδου του generator σε επαληθεύσιμες προτάσεις περιορίζει τον χώρο στον οποίο μπορούν να εισαχθούν αστήρικτοι ισχυρισμοί· το υψηλό RLF του test set (0.897) είναι συνεπές με αυτό το εύρημα.

RQ3: Ποια είναι η επίδραση της κατανομικής μετατόπισης των *unanswerable* ερωτημάτων στην ευαισθησία των πυλών;

Απάντηση: Ουσιαστική. Η βαθμονόμηση της πύλης στο development set (κατώφλι $\tau=0.7$, ποσοστό *unanswerable* 6.5%) είναι πιθανότατα ακατάλληλη για το test set, όπου το ποσοστό σχεδόν τριπλασιάζεται (19.1%), και η πτώση Task B→C προέρχεται κυρίως από τη μετρική RB_{alg} ($0.633 \rightarrow 0.400$). Τα στοιχεία αυτά αναδεικνύουν τη βαθμονόμηση της απαντησιμότητας ως καθοριστικό παράγοντα της end-to-end απόδοσης υπό την κατανομή του test set, αν και συμβάλλουν και τα σφάλματα ανάκτησης στις κορυφαίες θέσεις· οι δύο επιδράσεις δεν μπορούν να διαχωριστούν χωρίς ανάλυση των σκορ του test set ανά κατηγορία. Το σχήμα πολλαπλών κριτών βελτιώνει τον μονό κριτή στο development set, αλλά αφήνει ισχυρό acceptance bias.

RQ4: Μπορεί η επαναβαθμολόγηση μέσω MFM (LLM-based reranking) να προσφέρει όφελος έναντι εξειδικευμένων cross-encoder μοντέλων όταν η ανάκληση του πρώτου σταδίου είναι κοντά στον κορεσμό;

Απάντηση: Όχι ουσιαστικά. Καμία από τις τρεις μορφές LLM reranking (pointwise, listwise, generation-based) δεν βελτίωσε τη σταθμισμένη σύντηξη ανακτητή και cross-encoder όταν το $Recall@100$ ξεπερνά το 0.90· ως βοηθητικό σήμα με μικρό βάρος δίνουν το πολύ οριακά κέρδη (έως +2 μονάδες $Recall@5$ ανά θεματικό πεδίο), που δεν δικαιολογούν το πρόσθετο κόστος.

1.6.3 Περιορισμοί του Συστήματος

Παρά τις υψηλές επιδόσεις στα Tasks A και B, το σύστημα και η αξιολόγησή του έχουν συγκεκριμένους περιορισμούς:

1. **Ρύθμιση και αναφορά στο ίδιο σύνολο:** Όλες οι υπερπαράμετροι ρυθμίστηκαν στο development set, στο οποίο αναφέρονται και όλα τα ablations, χωρίς ξεχωριστό τμήμα ελέγχου ή cross-validation ανά συνομιλία· τα αποτελέσματα του development set είναι επομένως πιθανώς αισιόδοξα. Κάθε διαμόρφωση εκτελέστηκε μία φορά, οπότε μικρές διαφορές (της τάξης του 0.01 HM ή λιγότερο) δεν πρέπει να υπερερμηνεύονται.
2. **Στατικότητα Κατωφλίων Απόφασης:** Η Πύλη Απαντησιμότητας βασίζεται σε σταθερό κατώφλι εμπιστοσύνης ($\tau = 0.7$), βαθμονομημένο αποκλειστικά στο development set. Το κατώφλι αυτό, μαζί με τη ζώνη εκχύλισης ($[0.28, 0.38]$) και τα βάρη του Nested RRF ανά corpus, δεν επανα-βαθμονομήθηκαν για το test set. Η αναντιστοιχία αυτή είναι πιθανότατα σημαντικός παράγοντας του χάσματος Task B→C, μαζί με τα σφάλματα ανάκτησης στις κορυφαίες θέσεις· το αν ένα άλλο κατώφλι θα απέδιδε καλύτερα στο test set δεν μπορεί να επαληθευτεί με μία μόνο υποβολή.
3. **Ιστορικό αναφοράς στην αξιολόγηση:** Το MTRAGEval παρέχει σε κάθε στροφή το ιστορικό αναφοράς, οπότε η αξιολόγηση δεν ελέγχει την ανθεκτικότητα του συστήματος στα δικά του προηγούμενα σφάλματα, όπως θα συνέβαινε σε έναν πραγματικό βοηθό.
4. **Μεροληψία των κρίσεων συνάφειας:** Οι κρίσεις συνάφειας του MTRAG παρήχθησαν κυρίως από αποσπάσματα του ELSER, γεγονός που μπορεί να ευνοεί το ELSER έναντι άλλων ανακτητών και να συμβάλλει στο παραδόξο σύνθεσης ανακτητών.
5. **Εξάρτηση από Κλειστά API (Proprietary Models):** Η αρχιτεκτονική βασίζεται στο GPT-4o και στο DeepSeek-V3.2, γεγονός που αυξάνει το λειτουργικό κόστος και μειώνει την αναπαραγωγικότητα, λόγω της έλλειψης πρόσβασης στα βάρη των μοντέλων. Κανένα στάδιο του αγωγού δεν έχει υποστεί fine-tuning στα δεδομένα MTRAG· όλα τα κέρδη προέρχονται από μηχανική προτροπών (prompt engineering) και αρχιτεκτονικές επιλογές.
6. **Υπολογιστική Πολυπλοκότητα Pipeline:** Η πολυσταδιακή φύση του αγωγού (5 αναδιατυπώσεις, cross-encoder reranking, πύλη απαντησιμότητας τριών κριτών) αυξάνει τη δομική πολυπλοκότητα και τον χρόνο απόκρισης, ο οποίος δεν μετρήθηκε, και απαιτεί πρόσθετη μηχανική ενορχήστρωσης (orchestration) για χρήση σε κλίμακα.

1.6.4 Μελλοντικές Ερευνητικές Κατευθύνσεις

Η παρούσα διπλωματική εργασία ανοίγει τις ακόλουθες ερευνητικές κατευθύνσεις:

- **Προσαρμοστική Βαθμονόμηση (Adaptive Thresholding):** Δυναμικοί μηχανισμοί απαντησιμότητας, όπου το κατώφλι τ μεταβάλλεται βάσει της εκτίμησης της εντροπίας των ανακτηθέντων εγγράφων και της ανίχνευσης μετατοπίσεων κατανομής, αντί να παραμένει στατικό. Επειδή η βαθμονόμηση της απαντησιμότητας είναι ο καθοριστικός παράγοντας υπό την κατανομή του test set, πρόκειται για κατεύθυνση υψηλής αναμενόμενης αξίας· η ανάλυση των επίσημων σκορ του test set ανά κατηγορία απαντησιμότητας θα βοηθούσε να ποσοτικοποιηθεί το αναμενόμενο κέρδος.
- **Ισχυρότερες γραμμές βάσης για την πύλη:** Ταξινομητές επάρκειας βασισμένοι σε NLI, ταξινομητές πάνω στα σκορ ανάκτησης και κατώφλια βαθμονομημένα ανά θεματικό πεδίο, που δεν αξιολογήθηκαν στην παρούσα εργασία.
- **Ανθεκτική επίλυση εξαρτήσεων μεταξύ στρωφών:** Η δεύτερη μεγαλύτερη κατηγορία σφαλμάτων είναι η ανεπίλυτη εξάρτηση από προηγούμενες στρώφες (34%). Καλύτερη επίλυση αναφορών και ελλείψεων —π.χ. με ρητή παρακολούθηση οντοτήτων— στοχεύει άμεσα σε αυτήν. Σε πραγματικά συστήματα, όπου το ιστορικό περιέχει τις απαντήσεις του ίδιου του συστήματος, μηχανισμοί ελέγχου και αναίρεσης προηγούμενων βημάτων (backtracking) θα μπορούσαν επιπλέον να περιορίσουν το error cascade.
- **Fine-Tuning Ανοιχτών Μοντέλων Συλλογιστικής (Open-Weight Reasoning):** Εκπαίδευση εξειδικευμένων open-weight μοντέλων (π.χ. Llama-3-Reasoning, DeepSeek-R1) μέσω απόσταξης γνώσης (knowledge distillation) από το προτεινόμενο pipeline, με στόχο τη μείωση του κόστους και την άρση της εξάρτησης από κλειστά API.
- **Ενισχυτική Μάθηση (RL) για Query Formulation:** Εφαρμογή αλγορίθμων ενισχυτικής μάθησης (π.χ. PPO) για την εκπαίδευση του query rewriter, με συνάρτηση ανταμοιβής (reward function) απευθείας το nDCG@5 του ανακτητή.

1.6.5 Τελικό Συμπέρασμα

Συμπερασματικά, η παρούσα εργασία υποδεικνύει ότι η επιτυχής υλοποίηση συστημάτων Πολύστρωφου RAG δεν εξαρτάται αποκλειστικά από τη χρήση ισχυρότερων γλωσσικών μοντέλων. Η μετατόπιση της έμφασης από την απλή κλιμάκωση (scaling) προς τον προσεκτικό αρχιτεκτονικό σχεδιασμό, τη *σταθερότητα της ανάκτησης* και την *αυστηρή βαθμονόμηση των αποφάσεων* αποτελεί μια υποσχόμενη κατεύθυνση για συστήματα υψηλής αξιοπιστίας και διαφάνειας. Τα ευρήματα της εργασίας στηρίζονται στις αναλύσεις του development set και στα επίσημα αποτελέσματα, με την 1η και τη 2η θέση στα Tasks A και B· η υστέρηση στο Task C αναδεικνύει τη *βαθμονόμηση της απαντησιμότητας*, δηλαδή την απόφαση απάντησης ή αποχής υπό μετατόπιση κατανομής, ως το καθοριστικό ανοιχτό πρόβλημα, με την ακρίβεια κορυφής της ανάκτησης να παραμένει σημαντικός δευτερεύων περιορισμός.

Chapter 2

Introduction

2.1 Motivation

Large Language Models (LLMs) have emerged as a foundational paradigm in Natural Language Processing, demonstrating strong capabilities in coherent text generation, in-context learning, and multi-step reasoning through chain-of-thought prompting. These abilities arise from autoregressive pretraining on massive text corpora, without requiring task-specific supervision at inference time. Despite this representational power, LLMs remain fundamentally constrained by the static nature of their parametric knowledge: information is crystallized at pretraining time, and updating it requires computationally expensive retraining or fine-tuning procedures. Equally important, LLM outputs lack an intrinsic mechanism for traceability—the model cannot point to the specific evidence that grounds a given claim—which frequently manifests as *hallucinations*: fluent, syntactically well-formed text that is nonetheless factually unsupported. This limitation is particularly consequential in knowledge-intensive applications where factual reliability is a hard requirement.

Retrieval-Augmented Generation (RAG) addresses both limitations by coupling the parametric memory of an LLM with a non-parametric, externally maintained knowledge source, dynamically consulted at inference time [24]. A RAG system conditions generation on passages retrieved from an external corpus, which improves factual accuracy, enables adaptation to evolving information without retraining, and supports source attribution. Subsequent work extended this paradigm through multi-passage fusion architectures [15], joint retriever-generator training [16], and self-reflective generation mechanisms that actively decide when and what to retrieve [4]. RAG has since become an established approach for knowledge-intensive NLP tasks, underpinning practical deployments ranging from enterprise document search and technical support automation to open-domain question answering assistants—settings in which an ungrounded hallucination is not merely an academic evaluation failure but a concrete source of user harm or business risk.

The overwhelming majority of this literature, however, treats retrieval as a *single-turn* problem: each query is assumed to be self-contained, evaluated in isolation from any surrounding dialogue. This assumption is at odds with realistic deployment settings, which are inherently conversational. Virtually every production use case named above—a customer asking follow-up questions about a cloud service, an analyst probing a financial document across several exchanges, a citizen navigating a government procedure through successive clarifications—unfolds as a multi-turn dialogue, not a sequence of independent lookups. Studying multi-turn RAG is therefore not a niche extension of the single-turn setting; it is closer to the setting that most real deployments actually face.

2.2 The Multi-Turn RAG Problem

In a multi-turn interaction, successive user utterances exhibit strong contextual dependencies—anaphoric references without an explicit antecedent, syntactic ellipsis that omits information carried over from prior turns, and abrupt topic shifts within the same session. Table 2.1 reproduces a representative example from the MTRAG benchmark [22] that illustrates the failure mode directly: the query “*How much does it cost?*”,

taken in isolation, contains no retrievable entity at all. Only by resolving *it* against an entity introduced three turns earlier in the conversation (IBM Cloud Object Storage) does the query become answerable. A retriever that treats this turn as a standalone lookup—as single-turn RAG systems are designed to do—receives an uninformative signal and returns topically plausible but ultimately irrelevant passages.

Turn type	User query (verbatim)	Underlying challenge
Follow-up (coreference)	“How much does it cost?” — <i>it</i> refers to IBM Cloud Object Storage, introduced 3 turns prior	Non-standalone query; the retriever sees no resolvable entity without history-aware rewriting
Unanswerable (temporal)	“Where do the Cardinals play this week?” — corpus contains only a 2017 schedule	Topically relevant but temporally mismatched evidence; high risk of confident hallucination
Partial (incomplete)	“Is it worth having a web chat widget?” — corpus describes features, not subjective value	Retrieved evidence supports description but not the evaluative judgment the user is asking for

Table 2.1: Representative multi-turn RAG failure modes from the MTRAG benchmark [22], reproduced in condensed form. Each row illustrates a distinct structural challenge addressed by this thesis: non-standalone queries (Section 5.2), unanswerability under topical-but-irrelevant evidence (Section 5.4), and partial evidence coverage (Section 5.3).

When a system fails to resolve such dependencies, the resulting non-standalone query causes *context drift* in the retrieval stage: the retriever receives an underspecified signal and returns topically adjacent but ultimately irrelevant passages. Because the generator conditions on both the retrieved passages and the accumulated conversation history, a single retrieval failure at turn t does not remain isolated—it contaminates the history window H_{t+1} available at the next turn, giving rise to an *error cascade* that compounds across the dialogue whenever the history contains the system’s own earlier answers, as in a deployed assistant (MTRAGEval itself supplies the reference history; Section 6.4.2). Prior work on conversational search has largely approached this problem through learned query rewriting into standalone form [38, 3], though such sequence-to-sequence rewriters have been shown to degrade under sudden topic switching [1]. A second, closely related failure mode concerns *unanswerability*, illustrated by the second row of Table 2.1: the user’s information need may simply not be covered by the available corpus, a scenario that faithful information-seeking dialogue systems must explicitly detect rather than answer regardless [9]. As the third row shows, the boundary between answerable and unanswerable is itself often graded rather than binary—evidence may support part of a question while leaving its evaluative or comparative component unaddressed, a distinction that motivates the partial-answerability handling developed in Section 5.3.

2.3 Thesis Statement and Contributions

Motivated by this gap, the present thesis investigates multi-turn conversational RAG within the framework of the international MTRAGEval competition, organized as SemEval-2026 Task 8 [33] on the MTRAG benchmark [22]. The benchmark is explicitly designed to stress-test context-aware retrieval stability and answer-commitment behavior under non-standalone queries, spanning four heterogeneous domains (encyclopedic, financial, governmental, and technical-support content) and explicitly labeling turns as answerable, partially answerable, unanswerable, or conversational. We approach the problem as fundamentally one of *retrieval stability*: small, seemingly innocuous errors in query reformulation, compounded with the vocabulary gap that naturally opens up between conversational turns, translate into a sharp degradation of retrieval quality after the first turn of the dialogue. We further observe that standard RAG configurations exhibit a systematic *acceptance bias*—generators confidently answer unanswerable turns by falling back on parametric priors instead of verifying that the retrieved evidence actually justifies a response. We refer to this vulnerability as *answerability miscalibration*, and study its interaction with retrieval architecture choices through a unified system built on two design principles: query diversity over retriever diversity, and deferred commitment in generation.

Concretely, this thesis makes the following contributions:

- **A stability-oriented, multi-strategy query rewriting engine** that issues five complementary, failure-mode-targeted LLM reformulations against a single corpus-aligned retriever, aggregated through a hierarchical Nested Reciprocal Rank Fusion algorithm (Section 5.2); on the development set, this configuration outperforms heterogeneous retriever ensembling under the benchmark’s official relevance judgments (Section 6.2).
- **An agentic, evidence-commitment generation pipeline** that decomposes grounded response synthesis into answerability triage, verbatim evidence span extraction, dual-candidate drafting, judge-based selection, and micro-adjustment (Section 5.3), improving both reference-less faithfulness and the overall Harmonic Mean on the development set (Section 6.3).
- **A multi-layer answerability gate** for the end-to-end setting, combining document-, span-, and answer-level judges through confidence-weighted voting with dissenter override (Section 5.4).
- **A systematic empirical characterization of multi-turn RAG failure modes** on the MTRAGEval benchmark, including the retriever ensemble paradox (Section 6.2), answerability calibration as the decisive end-to-end factor under distribution shift, alongside persistent top-rank retrieval errors (Section 6.4), and quantitative evidence that LLM-based reranking saturates once first-stage recall is already high (Section 6.2).

The resulting system, AILS-NTUA, ranked 1st of 38 on Task A (passage retrieval) and 2nd of 26 on Task B (reference-grounded generation) on the official SemEval-2026 Task 8 leaderboard, consistent with the two design principles above (Section 6.5).

Relation to published work and personal contribution. The system was developed within the AILS-NTUA team and published as a SemEval-2026 system description paper [5]; this thesis builds on that paper and extends its analysis. The author designed and implemented the retrieval, generation, and answerability components, carried out all experiments and analyses, and wrote this thesis. M. Lymperaiou and G. Filandrianos provided research guidance and feedback, and A. Voulodimos and G. Stamou supervised the work.

2.4 Thesis Structure

The remainder of this thesis is organized as follows:

- Provide theoretical background on Large Language Models and Information Retrieval frameworks, covering learned sparse representations (ELSER v1), dense neural embeddings, unsupervised rank aggregation via Reciprocal Rank Fusion (RRF), and multi-stage agentic verification paradigms (Chapter 3).
- Formally define the multi-turn RAG problem under the three-subtask specification of MTRAGEval—passage retrieval, reference-grounded generation, and end-to-end RAG—derive the structural challenges (vocabulary gap, cross-turn dependency, context drift) that motivate our architectural choices, and state the four research questions and hypotheses that structure the empirical investigation (Chapter 4).
- Detail the technical architecture of our AILS-NTUA system, presenting the design of the five-pronged query rewriting engine, the mathematical formulation of the hierarchical Nested RRF algorithm, and the multi-stage agentic generation pipeline featuring verbatim evidence span extraction and multi-judge answerability gating (Chapter 5).
- Present comprehensive experimental results on the MTRAGEval benchmark, including ablation analyses of retrieval and generation components, an investigation of how conversational stability degrades across turn depth, and a quantitative account of the retriever ensemble paradox (Chapter 6).
- Conclude by summarizing the key architectural insights of the study, characterizing the limits of answerability gates under the distribution shift between development and test conditions, and discussing directions for future work, including reinforcement learning over open-weight reasoning models (Chapter 7).

Chapter 3

Background and Related Work

This chapter establishes the theoretical and empirical foundation upon which the AILS-NTUA system is built. We proceed in four stages. Section 3.1 surveys the dominant paradigms of information retrieval and situates learned sparse representations—the retrieval backbone adopted in this thesis—relative to lexical and dense alternatives. Section 3.2 formalizes unsupervised rank aggregation via Reciprocal Rank Fusion and develops the mathematical extension toward a hierarchical fusion scheme. Section 3.3 characterizes the structural failure modes specific to multi-turn conversational search, situating them within the broader conversational-QA literature. Section 3.4 reviews agentic generation pipelines and LLM-as-a-judge evaluation paradigms, which underpin the deferred-commitment generation strategy of Chapter 5. Section 3.5 closes with a synthetic positioning of this thesis relative to prior work.

3.1 Information Retrieval Paradigms and Neural Representation

Information Retrieval (IR) forms the structural foundation of any retrieval-augmented pipeline. The core objective of an IR system is to map a user information need, formulated as a query q , to a subset of relevant documents extracted from a massive, static knowledge repository $\mathcal{D} = \{d_1, d_2, \dots, d_{|\mathcal{D}|}\}$. Over the past decades, this paradigm has evolved from exact lexical matching, through continuous dense vector spaces, to hybrid *learned sparse* representations that attempt to reconcile the strengths of both extremes—a progression that directly motivates the retriever choice made in this thesis.

3.1.1 Lexical and Probabilistic Retrieval: The BM25 Framework

The classical paradigm of information retrieval is built upon sparse lexical matching, where documents and queries are represented as high-dimensional, orthogonal vectors indexed by the vocabulary of the corpus. The most prominent model within this framework is Best Matching 25 (BM25) [32], a non-linear combination of term frequency, inverse document frequency, and document-length normalization. Formally, given a query q containing terms $t \in q$, the BM25 relevance score for a document d is defined as:

$$\text{Score}_{\text{BM25}}(d, q) = \sum_{t \in q} \text{IDF}(t) \cdot \frac{f(t, d) \cdot (k_1 + 1)}{f(t, d) + k_1 \cdot \left(1 - b + b \cdot \frac{|d|}{\text{avgdl}}\right)} \quad (3.1.1)$$

where $f(t, d)$ is the raw term frequency of t within d , $|d|$ is the document length in tokens, and avgdl is the average document length across $\mathcal{D}$. The hyperparameter $k_1 \in [1.2, 2.0]$ controls term-frequency saturation, while $b \in [0, 1]$ (typically $b=0.75$) governs the severity of the length-normalization penalty. The inverse document frequency term rewards rare, discriminative terms:

$$\text{IDF}(t) = \ln \left(1 + \frac{|\mathcal{D}| - n(t) + 0.5}{n(t) + 0.5} \right) \quad (3.1.2)$$

where $n(t)$ is the number of documents containing t . BM25 offers exceptional precision for exact technical identifiers, serial numbers, and acronyms, but is fundamentally bounded by the *vocabulary mismatch problem*:

if a query paraphrases the target content using synonyms or morphologically distinct variants, the lexical intersection $q \cap d$ collapses toward zero and the document is missed entirely—regardless of its true semantic relevance. As we quantify empirically in Chapter 6 (Table 6.2), this weakness is amplified in the multi-turn setting, where later-turn queries are short and elliptical almost by construction.

3.1.2 Dense Retrieval and Contrastive Embedding Vector Spaces

To transcend the lexical boundaries of exact term matching, dense neural retrieval projects both queries and documents into a low-dimensional, continuous vector space $\mathbb{R}^d$ (typically $d \in [768, 1536]$). This approach employs a bi-encoder (dual-encoder) architecture [21] in which a query encoder $E_Q(\cdot)$ and a document encoder $E_D(\cdot)$ map text sequences independently into dense embeddings; relevance is then computed as inner product or cosine similarity:

$$S_{\text{dense}}(q, d) = \text{Sim}(E_Q(q), E_D(d)) = \frac{\langle E_Q(q), E_D(d) \rangle}{\|E_Q(q)\|_2 \cdot \|E_D(d)\|_2} \quad (3.1.3)$$

Dense encoders are trained via contrastive learning objectives that minimize an InfoNCE-style loss. Given a training triplet consisting of a query q , a positive document d^+ , and a set of negative documents $\{d_1^-, \dots, d_n^-\}$:

$$\mathcal{L}_{\text{contrastive}} = -\log \frac{\exp(\text{Sim}(E_Q(q), E_D(d^+))/T)}{\exp(\text{Sim}(E_Q(q), E_D(d^+))/T) + \sum_{i=1}^n \exp(\text{Sim}(E_Q(q), E_D(d_i^-))/T)} \quad (3.1.4)$$

where T is a temperature hyperparameter that governs the penalization of hard negatives. Dense retrieval excels at matching abstract semantic concepts and cross-lingual paraphrases, but—as documented broadly in recent RAG surveys [14]—frequently introduces semantic noise in domain-specific or multi-turn settings, over-generalizing technical tokens and misrouting alphanumeric identifiers that BM25-style matching would have captured trivially. This trade-off between semantic generalization and lexical precision is precisely what motivates the third retrieval paradigm.

3.1.3 Learned Sparse Representations and Vocabulary Expansion

Learned Sparse Retrieval has emerged as a powerful intermediate paradigm designed to unify the structural advantages of lexical precision and semantic generalization (e.g., SPLADE [12], ELSER [10]). Rather than compressing an entire sequence into a low-dimensional dense embedding, learned sparse encoders use a masked-language-modeling head to project text onto the full vocabulary space of the model, $\mathcal{V} = \mathbb{R}^{|\mathcal{V}|}$ (where $|\mathcal{V}| \approx 30,522$ for typical WordPiece vocabularies).

Formally, given a document d , the learned sparse encoder outputs a high-dimensional, sparse vector w_d , where the weight $w_d(t)$ for each token $t \in \mathcal{V}$ is computed by predicting its semantic importance:

$$w_d(t) = \ln(1 + \max(0, W_t \cdot h_i + b_t)) \quad (3.1.5)$$

where h_i is the contextualized hidden state of token i produced by the Transformer layers, and W_t, b_t are the parameters of a linear projection head associated with vocabulary token t . This mechanism enables *term expansion*: the encoder populates the document vector with non-zero weights for semantically related terms and synonyms that were never present in the raw string, thereby directly resolving the vocabulary mismatch problem without abandoning the interpretability and exact-match precision of a sparse representation. The final relevance score reduces to an efficient sparse dot product over the shared vocabulary support:

$$S_{\text{learned_sparse}}(q, d) = \sum_{t \in q \cap d} w_q(t) \cdot w_d(t) \quad (3.1.6)$$

This thesis adopts **ELSER v1** as its corpus-aligned sparse base retriever, capitalizing on its balanced handling of alphanumeric constraints (error codes, financial tickers, product identifiers) alongside cross-turn paraphrase resolution—an empirical justification developed in detail in Chapter 6.

3.1.4 Hypothetical Document Embeddings: Bridging the Query–Passage Gap

A structurally distinct approach to closing the vocabulary gap operates not on the document side but on the *query* side. **Hypothetical Document Embeddings (HyDE)** [13] reformulate the retrieval problem

by having an LLM first generate a plausible, zero-shot hypothetical answer to the query, and then using that generated passage—rather than the original query—as the retrieval signal. The underlying intuition is that a hypothetical answer, even if factually imperfect, is lexically and structurally much closer to the target passages in the corpus than a short, often elliptical, user question. This effectively reframes retrieval as a passage-to-passage matching problem rather than a query-to-passage one, at the cost of introducing generation-time variance: because the hypothetical passage is itself sampled from the LLM’s parametric knowledge, its quality and topical fidelity can fluctuate from one invocation to the next. A closely related approach, Query2doc [39], appends an LLM-generated pseudo-document to the original query instead of replacing it. The expected variability of such generated signals motivates the hierarchical fusion design discussed in Section 3.2; empirically, HyDE is the weakest single reformulation strategy in our development experiments (Section 6.2), while still contributing within the fusion.

3.2 Unsupervised Rank Aggregation and Rank Decay Theory

In complex RAG pipelines where multiple independent rankings are surfaced—whether through multi-retriever ensembling or multi-query reformulation—an unsupervised rank aggregation algorithm is required to combine these permutations into a single, robust output list without access to ground-truth relevance labels at inference time.

3.2.1 Reciprocal Rank Fusion (RRF)

Reciprocal Rank Fusion (RRF) [6] operates as a non-parametric rank aggregation standard. Unlike score-based fusion strategies, which require careful calibration to normalize heterogeneous score scales across retrieval models, RRF relies strictly on the *relative order* of items within each list, making it immune to scale mismatches between, e.g., BM25 scores and cosine similarities. Given a set of individual query-result permutations $\mathcal{M}$, the aggregate RRF score for a document $d \in \mathcal{D}$ is defined as:

$$\text{RRF_Score}(d \in \mathcal{D}) = \sum_{m \in \mathcal{M}} \frac{1}{k + r_m(d)} \quad (3.2.1)$$

where $r_m(d)$ denotes the rank of document d within the m -th permutation list, and $k \in \mathbb{N}$ is a constant smoothing hyperparameter, typically optimized around $k=60$ in practice. The mathematical intuition behind RRF lies in its penalization of high-rank volatility: documents that achieve a consistently high rank across multiple independent strategies are disproportionately rewarded, while the influence of documents that appear only near the tail of individual lists decays smoothly rather than being discarded outright. This property makes RRF particularly attractive in our setting, where the five query reformulation strategies of Chapter 5 are expected to agree strongly on some documents while disagreeing substantially on others.

3.2.2 Weighted and Nested Rank Aggregation Foundations

To accommodate scenarios where individual ranking strategies exhibit asymmetric reliability, the standard RRF formulation generalizes naturally into a *Weighted RRF*. Let w_m denote the static weight allocated to the m -th ranking strategy, estimated from empirical precision on a validation set:

$$\text{WRRF_Score}(d \in \mathcal{D}) = \sum_{m \in \mathcal{M}} \frac{w_m}{k + r_m(d)}, \quad \text{subject to } \sum_{m \in \mathcal{M}} w_m = 1 \quad (3.2.2)$$

Flat weighting, however, is insufficient when the reliability gap between strategies is not merely a matter of average precision but of *variance*: a strategy such as HyDE (Section 3.1.4) may perform excellently on some turns and poorly on others, depending on whether the LLM’s hypothetical passage happens to align with the true topical content. Assigning it a fixed, average-case weight either under-exploits its good turns or over-exposes the fusion to its bad ones. This consideration motivates a hierarchical variant, termed **Nested RRF**, developed as a core technical contribution of this thesis. Let $\mathcal{M}_{\text{high}}$ denote the subset of exploratory rankings, expected to be more volatile (HyDE, Chain-of-Thought, Anchor-Keyword), and $\mathcal{M}_{\text{stable}}$ the subset of conservative rankings (Minimal, Corpus-Specific). A flat, peer-to-peer fusion of all five strategies would allow a single noisy reformulation to contaminate top- k slots on turns where it happens to fail. The Nested

RRF framework instead constructs a two-level hierarchical aggregation tree. At **Level 1**, the noisy paths are pre-aggregated into a single intermediate consensus ranking, $\mathcal{R}_{\text{consensus}}$:

$$\text{Score}_{\text{Level 1}}(d) = \sum_{m \in \mathcal{M}_{\text{high}}} \frac{1}{k_{\text{internal}} + r_m(d)} \rightarrow \text{Sort} \rightarrow \mathcal{R}_{\text{consensus}}(d) \quad (3.2.3)$$

At **Level 2**, the final ranking is compiled by fusing the consensus ranking with the two conservative rankings, under domain-specific corpus weights $w_s^{(c)}$ tuned per topical field c :

$$\text{Score}_{\text{final}}(d) = \frac{w_{\text{consensus}}}{k_{\text{final}} + r_{\text{consensus}}(d)} + \sum_{s \in \mathcal{M}_{\text{stable}}} \frac{w_s}{k_{\text{final}} + r_s(d)} \quad (3.2.4)$$

Intuitively, this construction makes the exploratory group contribute a *single* vote to the final fusion—rather than one vote per strategy—so that its fluctuations are smoothed before it competes with the conservative reformulations. The construction is part of the multi-strategy retrieval pipeline of Chapter 5; Section 6.2 evaluates the complete configuration, although a direct comparison with flat RRF over the same inputs was not retained.

3.3 Multi-Turn Dialogic Modeling and Structural Failure Cascades

The transposition of RAG frameworks from single-turn transactions into multi-turn dialogue configurations fundamentally changes the mathematical properties of the context window available to the system. In a single-turn scenario, the query is standalone and complete. In a sequential conversation, the user utterance u_t at turn t is generally *non-standalone*, drawing essential structural information from the historical trace $H_t = \{(u_i, a_i)\}_{i=1}^{t-1}$.

3.3.1 Conversational Dependencies: Anaphora, Ellipsis, and Topic Drift

Conversational interaction is governed by principles of linguistic economy that are largely absent from written, single-turn queries, giving rise to three primary categories of context dependency:

- **Pronoun Coreference Resolution:** the occurrence of anaphoric tokens (e.g., “its pricing”, “how much did they fine them?”) whose semantic referent is bound to an entity established several turns earlier in the dialogue.
- **Syntactic Ellipsis:** the omission of complete predicates or structural components that are implicitly carried forward by the discourse state (e.g., Turn $t-1$: “*What is the capital of France?*”, Turn t : “*And Germany?*”).
- **Topic Caching and Drift:** conversational shifts in which the user introduces a new intent or re-activates a historical thread, requiring the system to dynamically distinguish live conversational context from stale, superseded information.

As quantified in our system description paper [5] and reproduced in Section 4.2.3 of this thesis, pronoun coreference alone is present in 97% of non-first turns in the MTRAG development set, making it by a wide margin the dominant source of query underspecification—far ahead of comparative follow-ups (67%) and temporal dependence (18%).

3.3.2 The Error Cascade Phenomenon

A widely discussed failure mode of multi-turn RAG systems is the *error cascade*. In an end-to-end multi-turn loop, the context window supplied to the retrieval module at turn t is parameterized by the history H_t , which encodes the generated outputs of *all* prior turns. If the retrieval module $\mathcal{R}$ experiences a failure or admits irrelevant distractors at turn $t-1$, the downstream generator $\mathcal{G}$ necessarily receives a corrupted context prompt, and consequently produces an ungrounded or partially incorrect response y_{t-1} . Because y_{t-1} is deterministically appended to the history window, the incoming context for turn t is contaminated before the retrieval module even begins its work: the query reformulation engine at turn t processes this already-corrupted trace, leading to context drift and a further retrieval failure. This progressive degradation

highlights that retrieval stability *across* dialogue turns, and not merely within a single turn, is a central requirement for reliable conversational RAG. The cascade presupposes that the history contains the system’s own earlier outputs, as it does in deployed assistants. The MTRAGEval benchmark used in this thesis instead supplies the *reference* history at every turn, so a system error cannot propagate into later turns; our evaluation therefore does not exercise this mechanism (Section 6.4.2).

3.3.3 Conversational Search: Rewriting, Robustness, and Benchmark Design

The challenge of context-dependent retrieval has a substantial prior literature outside the RAG framework proper, under the umbrella of *conversational search*. Early formalizations of the task, such as the TREC Conversational Assistance Track (CAST) [7], established multi-turn retrieval as a distinct evaluation setting with its own passage collections and relevance judgments. The dominant early approach to handling non-standalone queries was learned *query rewriting*: training sequence-to-sequence models to transform a context-dependent utterance into an independent, standalone query prior to retrieval [38, 3]. Alternative lines of work learn conversational query encoders directly, as in ConvDR [42], or prompt large language models to produce several rewrites and pseudo-responses that are aggregated into a single search intent, as in LLM4CS [26]—the latter being the closest prior work to the multi-strategy rewriting of this thesis. While effective on relatively stable conversational trajectories, Adlakha et al. [1] demonstrated with the TopiOCQA benchmark that such rewriters degrade sharply under sudden topic switching and context drift, precisely the failure mode described above—a fragility that directly motivated the development of fine-grained, self-checking mechanisms tailored to conversational QA [41] and, more recently, evaluation frameworks explicitly designed around retrieval-augmented multi-turn dialogue, such as TREC iKAT [2] and RAD-Bench [23]. The MTRAG benchmark adopted in this thesis [22] extends this line of work by combining non-standalone queries with explicit unanswerability labels and heterogeneous, realistic domains (encyclopedic, financial, governmental, technical), rather than relying on a single homogeneous corpus—a design choice that is precisely what surfaces the domain-dependent retrieval behavior analyzed in Chapter 6.

3.4 Agentic Generative Pipelines and Multi-Judge Systems

To shield the language generator from the structural vulnerabilities of raw, unfiltered document inputs, state-of-the-art architectures increasingly transition toward multi-stage *agentic* frameworks. These structures segment a monolithic generation task into discrete, granular sub-problems, each optimized through a targeted persona definition, and defer final commitment to the answer until multiple independent signals agree.

3.4.1 Context Bottlenecks via Evidence Span Extraction

Naively passing long retrieved documents (e.g., multiple 512-token text blocks) directly into an LLM generator introduces the well-documented *lost-in-the-middle* phenomenon [25], in which models systematically under-attend to evidence located away from the beginning or end of an extended context window. To enforce rigorous factual anchoring, modern pipelines introduce an intermediate stage termed *Verbatim Evidence Span Extraction*: an extraction module analyzes the retrieved documents $\mathcal{D}_t$ and outputs a filtered set of exact sentence strings $\mathcal{S}_t = \{s_1, s_2, \dots, s_m\}$ that directly support the query. The downstream generator is then strictly conditioned on $\mathcal{S}_t$ rather than the full documents, creating a tight context bottleneck that substantially reduces the opportunity for parametric hallucination. This principle is closely related to, and partly inspired by, work on teaching language models to support their answers with verified quotes drawn directly from source material [27], which similarly argues that constraining a generator’s output to be traceable to exact source spans is a more robust grounding mechanism than post-hoc citation or free-form paraphrase.

3.4.2 The LLM-as-a-Judge Evaluation and Selection Paradigm

The validation and selection of generated responses within complex agentic pipelines is increasingly managed through the *LLM-as-a-Judge* framework [43], originally proposed as a scalable substitute for human preference annotation in open-ended chatbot evaluation (MT-Bench, Chatbot Arena). Rather than committing to a single greedy generation pass, agentic pipelines instead adopt a strategy of *deferred commitment*: multiple diverse response candidates are generated simultaneously—for instance, balancing deterministic factual

transmission against stochastic natural fluency—and are then cross-evaluated by an ensemble of orthogonal, persona-conditioned judge prompts. Each judge persona scores the candidates along a specific operational axis (e.g., technical faithfulness to the extracted evidence spans, or user-facing conversational adequacy), and the resulting scores are synthesized into a composite selection criterion that delays final text commitment until an acceptable consensus is reached. This general paradigm underlies the multi-judge selection scheme developed in Section 5.3 of this thesis, extended here to explicitly penalize both hallucination-prone under-extraction and mechanically verbatim over-extraction via the extractiveness shaping function of Section 5.3 (Equation (5.3.1)).

3.4.3 Retrieval-Augmented Generation Beyond Single-Pass Fusion

The agentic pipelines discussed above are best understood as a natural extension of a broader trajectory in RAG research away from single-pass, static retrieve-then-generate architectures. Fusion-in-Decoder (FiD) [15] first demonstrated that encoding multiple retrieved passages independently and fusing their representations only within the decoder substantially improves the integration of dispersed evidence, relative to naively concatenating all passages into a single prompt. Subsequent work on Atlas [16] extended this architecture toward continuous joint training of the retriever and generator, improving few-shot performance on knowledge-intensive tasks. A parallel line of research has explored making the retrieval decision itself dynamic and generation-aware, rather than a single upfront step: Self-RAG [4] trains a model to self-reflect on whether retrieval is needed at all and to critique its own generated output against retrieved evidence, while active retrieval augmented generation [17] triggers additional retrieval calls mid-generation whenever the model’s own confidence signals suggest that further evidence is required. Corrective RAG (CRAG) [40] adds a lightweight retrieval evaluator that grades the retrieved documents and triggers corrective actions when they are judged insufficient—an idea closely related to the answerability gate of this thesis. REPLUG [36] takes a complementary, black-box-compatible approach, treating the language model itself as a frozen component and tuning only the retriever to better serve a fixed, non-differentiable generator—a design constraint that closely mirrors the proprietary-API setting of this thesis (Chapter 5), where the underlying LLMs cannot be fine-tuned and all architectural gains must instead be realized through prompting, orchestration, and evidence-filtering design.

3.5 Related Work

The formalization of Retrieval-Augmented Generation was established by Lewis et al. [24], who demonstrated that conditioning language model generation on explicit, non-parametric retrieved documents substantially reduces hallucination on knowledge-intensive tasks relative to purely parametric generation. This foundational architecture was subsequently extended along several complementary axes reviewed in Section 3.4: multi-passage integration via Fusion-in-Decoder [15], continuous joint retriever-generator training [16], self-reflective and actively triggered retrieval [4, 17], and black-box-compatible retriever tuning [36]. More broadly, recent surveys of the RAG literature [14] document the rapid diversification of this design space across retrieval strategies, augmentation points, and generation-time integration mechanisms.

In parallel, conversational search research has long targeted the specific problem of context-dependent multi-turn query resolution [7]. Early approaches relied heavily on sequence-to-sequence models trained to rewrite conversational inputs into independent, standalone queries [38, 3]. However, Adlakha et al. [1] exposed the fragility of these sequence-based rewriters under sudden topic switching and severe context drift, a failure mode that directly motivated the development of fine-grained self-checking mechanisms tailored explicitly to conversational QA environments [41], and, at the benchmark-design level, retrieval-augmented conversational assistants evaluated under realistic multi-turn constraints [2, 23].

The problem of *unanswerability* has a long history in question answering, from benchmarks that include questions without an answer in the given context, such as SQuAD 2.0 [31], to selective question answering, in which a model abstains when its confidence is low, a setting known to be fragile under domain shift [20]. Whether language models can estimate their own confidence reliably is itself an open question [19], and recent work on RAG systems distinguishes explicitly between relevant and *sufficient* context [18]. In information-seeking dialogue, unanswerability is a central challenge for faithful responses [9]: systems must trade off answering against abstaining when the retrieved context may not justify an

answer. Automated RAG evaluation frameworks such as RAGAS [11], ARES [35], and RAGChecker [34] assess this grounding automatically; RAGAS-style faithfulness is the reference-less component of our evaluation metric (Section 4.5). To probe these compounding conversational failure modes across genuinely heterogeneous domains, Katsis et al. [22] introduced the MTRAG conversational benchmark. Unlike traditional single-turn or single-domain datasets, MTRAG features factoid, comparative, and explicitly unanswerable questions configured within realistic multi-turn histories spanning encyclopedic, financial, governmental, and technical-support content, serving as the core experimental bed for validating the retrieval-stability and agentic-commitment design principles presented throughout this thesis, and for the SemEval-2026 Task 8 shared task in which this system was evaluated [33].

Table 3.1 summarizes the positioning of this thesis relative to the strands of prior work reviewed above, and the specific structural gap that each line of work leaves open in the multi-turn RAG setting.

Prior Work	Core Contribution	Gap Addressed by AILS-NTUA
Lewis et al. [24]; Izacard & Grave [15] Vakulenko et al. [38]; Anantha et al. [3]	Single-turn RAG; multi-passage fusion Sequence-to-sequence query rewriting to standalone form	Extended to explicitly non-standalone, multi-turn queries Replaced with five complementary, failure-mode-targeted LLM reformulations, fused rather than committed to a single rewrite
Adlakha et al. [1]	Documents rewriter fragility under topic drift	Nested RRF is designed to limit the influence of high-variance reformulations instead of relying on a single rewrite
Asai et al. [4]; Jiang et al. [17]	Dynamic, self-triggered retrieval within generation	Retrieval decoupled from generation entirely (Task A/B separation); dynamic behavior instead concentrated in the answerability gate
Dziri et al. [9]	Faithfulness benchmark for unanswerable dialogue	Multi-layer, confidence-weighted answerability gate operating over documents, spans, and answers jointly
Katsis et al. [22]	MTRAG benchmark: multi-turn, multi-domain, explicit unanswerability	This thesis: unified system evaluated across all three MTRAGEval subtasks under this benchmark

Table 3.1: Positioning of the AILS-NTUA system relative to representative prior work discussed in this chapter.

Chapter 4

Problem Definition and Task Specifications

This chapter provides a formal definition of the Multi-Turn Retrieval-Augmented Generation (RAG) problem under sequential decision constraints. It delineates the structural specifications of the MTRAGEval benchmark (SemEval-2026 Task 8), conducts an empirical analysis of the underlying multi-domain corpora, profiles the evaluation metrics, and establishes the formal research questions and hypotheses that guide the experimental framework developed in Chapter 5 and evaluated in Chapter 6.

4.1 Formal Mathematical Formulation

We formalize multi-turn conversational RAG as a sequential process unfolding over a set of discrete dialogue turns indexed by $t \in \{1, 2, \dots, L\}$, where L is the length of the conversation. At any given turn t , the state of the conversation is fully encapsulated by the user-agent history window, denoted H_t :

$$H_t = \left((u_1, \mathcal{D}_1, y_1), (u_2, \mathcal{D}_2, y_2), \dots, (u_{t-1}, \mathcal{D}_{t-1}, y_{t-1}) \right) \quad (4.1.1)$$

where u_i is the raw user utterance at turn i , $\mathcal{D}_i$ is the subset of document passages retrieved at turn i , and y_i is the agent response at turn i . In a deployed assistant, $\mathcal{D}_i$ and y_i are the system’s own earlier outputs; in the MTRAGEval benchmark used in this thesis, the history is the benchmark’s *reference* conversation, so earlier system errors do not enter H_t . At the current turn t , the user introduces a new conversational utterance u_t , which defines the active query $q_t \equiv u_t$. The system has access to a massive, static global corpus $\mathcal{D} = \{d_1, d_2, \dots, d_{|\mathcal{D}|}\}$.

The objective of multi-turn RAG decomposes into three separate probabilistic functions, evaluated explicitly under the tripartite MTRAGEval specification. These three functions are not merely three ways of measuring the same underlying capability—each isolates a distinct point of potential failure in the pipeline, which is precisely why the MTRAGEval competition (and this thesis) evaluates them independently rather than only end-to-end.

Table 4.1 summarizes the principal notation used throughout the thesis.

4.1.1 Task A: Multi-Turn Passage Retrieval Specification

The objective of Task A is to evaluate conversational search *independently of downstream generation*, isolating retrieval quality from any confound introduced by the generator. Given the conversational history H_t and the active, potentially non-standalone query q_t , the retrieval module $\mathcal{R}$ must produce a ranked list $\mathcal{D}_t$ containing exactly the top- k (with $k=10$ under the competition specification) most relevant passages extracted from the global corpus $\mathcal{D}$, sorted by decreasing order of semantic relevance to q_t under the context of H_t :

$$\mathcal{R}(q_t, H_t, \mathcal{D}) \longrightarrow \mathcal{D}_t = \{d_{(1)}, d_{(2)}, \dots, d_{(k)}\}, \quad d_{(i)} \in \mathcal{D}, \quad k = 10 \quad (4.1.2)$$

Symbol	Meaning
t, L	Turn index; number of turns in a conversation
u_t, q_t	User utterance at turn t ; active query ($q_t \equiv u_t$)
H_t	Conversation history available at turn t
$\mathcal{D}, \mathcal{D}_t, \mathcal{D}_t^*$	Corpus; passages retrieved at turn t ; gold reference passages
$\mathcal{S}_t$	Verbatim evidence spans extracted at turn t
y_t, y_t^*	Generated response; reference response
$z_t, \hat{z}_t$	True answerability label; answerability decision of the gate
τ	Confidence threshold of the answerability gate ($\tau=0.7$)
T	LLM sampling temperature (and temperature of the contrastive loss in Section 3.1)
k	Rank-decay constant of (weighted) RRF ($k_{\text{internal}}, k_{\text{final}}^{(c)}$ in Nested RRF)
α	Weight of the reranker signal in the hybrid fusion
$w_s^{(c)}$	Nested RRF weight of input s for corpus c
N, K	Passages retrieved per reformulation; maximum number of extracted spans
$r_4, \phi(r_4)$	4-gram overlap with the evidence spans; extractiveness shaping function

Table 4.1: Principal notation.

4.1.2 Task B: Reference-Grounded Response Generation Specification

The objective of Task B is to isolate *generation* quality from retrieval mechanics by entirely removing the search bottleneck. The system is provided with the true dialogue history H_t , the active query q_t , and a fixed set of gold-standard relevant reference passages $\mathcal{D}_t^* \subset \mathcal{D}$. The generator function $\mathcal{G}$ must synthesize a natural-language response y_t that is strictly grounded in $\mathcal{D}_t^*$, maximizing factual alignment while avoiding out-of-context abstraction:

$$\mathcal{G}(q_t, H_t, \mathcal{D}_t^*) \longrightarrow y_t \quad (4.1.3)$$

4.1.3 Task C: End-to-End Retrieval-Augmented Generation Specification

Task C unifies retrieval and generation, mirroring real-world deployment conditions in which no gold evidence set is ever supplied at inference time. Given only H_t, q_t , and the raw global corpus $\mathcal{D}$, the architecture must first retrieve up to 10 relevant passages using its own internal retrieval module, and subsequently condition its generator on these *noisy, self-retrieved* documents to produce the final response y_t . Because the retrieved set $\mathcal{D}_t$ is no longer guaranteed to be relevant, Task C requires the system to additionally model a latent binary answerability variable $z_t \in \{0, 1\}$:

$$z_t = \begin{cases} 1, & \text{if } \mathcal{D}_t \text{ contains sufficient evidence to fully justify an answer to } q_t \\ 0, & \text{otherwise (unanswerable turn)} \end{cases} \quad (4.1.4)$$

The end-to-end objective therefore reduces to mapping $[q_t, H_t, \mathcal{D}]$ to an output pair $(\mathcal{D}_t, y_t)$, maximizing factual grounding if $\hat{z}_t = 1$, or executing a calibrated refusal if $\hat{z}_t = 0$. As we show in Chapter 6, this additional decision layer—absent from Tasks A and B by construction—is a major source of the additional difficulty of Task C, together with the fact that generation must rely on system-retrieved rather than reference passages.

4.1.4 A Unified Optimization Perspective

Tasks A, B, and C are not merely three independent evaluation protocols; they are three coordinates of a single underlying design objective. It is useful, before turning to the concrete system of Chapter 5, to state this objective explicitly in idealized form, even though—as discussed below—it is not the objective actually optimized by the system. Let $\mathcal{X}$ denote the distribution of (query, history) pairs induced by the benchmark, and let $y_t^*, \mathcal{D}_t^*$ denote the human reference response and gold evidence set for turn t . The architecture as a whole seeks to maximize the expected utility of its output over this distribution:

$$\mathcal{O}^* = \arg \max_{\mathcal{R}, \mathcal{G}} \mathbb{E}_{(q_t, H_t) \sim \mathcal{X}} \left[\mathcal{U}(y_t, y_t^*, \mathcal{D}_t, \mathcal{D}_t^*) \right] \quad (4.1.5)$$

where the composite utility $\mathcal{U}$ decomposes into four terms corresponding directly to the evaluation axes of Section 4.5:

$$\mathcal{U} = w_1 \cdot \text{NDCG}(\mathcal{D}_t, \mathcal{D}_t^*) + w_2 \cdot \text{Faithfulness}(y_t, \mathcal{D}_t) + w_3 \cdot \text{Extractive_F1}(y_t, y_t^*) + w_4 \cdot \Phi(\hat{z}_t, z_t) \quad (4.1.6)$$

with NDCG rewarding retrieval quality (Task A), Faithfulness and Extractive_F1 jointly rewarding grounded, reference-aligned generation (Task B), and Φ rewarding correctly calibrated answerability decisions, i.e., agreement between $\hat{z}_t$ and z_t (the Task C-specific term of Section 4.3); since $\mathcal{U}$ is maximized, all four terms are written as rewards.

We emphasize that Equation (4.1.5) is a *conceptual* organizing device, not a training objective actually optimized by the system: $\mathcal{U}$ is not differentiable end-to-end (it composes discrete retrieval decisions, free-text generation, and a thresholded gate), no component of the pipeline is trained via gradient descent against it, and the weights $w_1, \dots, w_4$ are never estimated numerically anywhere in this thesis. Its purpose is exclusively explanatory: it makes explicit that the architectural decomposition of Chapter 5 into a retrieval pipeline (Section 5.2), a generation pipeline (Section 5.3), and an answerability gate (Section 5.4) is not an arbitrary engineering choice but a direct functional decomposition of $\mathcal{U}$ into independently addressable sub-problems, each approximated through targeted prompt engineering and architectural design rather than joint numerical optimization. The additive form of $\mathcal{U}$ is a simplification. The official harmonic-mean scoring rule of Section 4.5 is stricter: unlike a weighted sum, it penalizes asymmetric performance across components, so a weak component can lower the final score even when the others are strong. This is one reason why Task C performance can fall well below Task B performance (Section 6.4).

4.2 MTRAGEval Benchmark and Corpus Analysis

The empirical evaluation of this thesis is conducted on the MTRAG benchmark dataset [22], which comprises 110 highly structured, human-authored multi-turn conversations containing a total of 842 annotated dialogue turns. Conversations average 7.7 turns in length, exhibiting deep sequential dependencies that make the benchmark substantially more demanding than single-turn retrieval collections.

4.2.1 Heterogeneous Domain Characterization

The global corpus is deliberately segmented into four structurally distinct domains, designed to stress-test RAG architectures under varied document structures, linguistic registers, and token distributions. Table 4.2 details the corpus statistics across the four domains.

Characteristic	ClapNQ	FiQA	Govt	Cloud
Domain Type	Encyclopedic	Financial Forum	Public Policy	Technical Docs
Total Documents	4,293	57,638	7,661	8,578
Total Passages	183,408	61,022	49,607	72,442
Avg. Passages / Doc	42.7	1.1	6.5	8.4
Primary Source	Wikipedia	StackExchange	Government Portals	IBM Cloud Docs

Table 4.2: MTRAG corpus structural heterogeneity and domain statistics.

The structural variation across these domains introduces qualitatively distinct challenges for the retrieval module:

- **ClapNQ:** long, densely structured encyclopedic entries (median 31 passages per document), demanding strict retrieval precision to isolate the single correct paragraph within massive documents.
- **FiQA:** short, subjective forum posts where documents are essentially atomic (1 passage $\approx$ 1 post). This domain exhibits highly informal, non-standard language, creating a severe vocabulary gap with respect to standard user queries—a property confirmed empirically in Chapter 6, where FiQA proves the single hardest domain for the unaugmented retriever baseline.

- **Govt:** formal policy, instructional guidelines, and bureaucratic content, characterized by high rates of *partial* answerability, as relevant information is frequently scattered across structural cross-references rather than concentrated in a single passage.
- **Cloud:** extremely dense technical documentation (up to 64k words per source file) containing error codes, CLI commands, and complex service configuration matrices, demanding high retrieval precision under long-context constraints.

4.2.2 Question Type and Answerability Distributions

Each turn in the benchmark is multi-labeled across ten question categories, dominated by Factoid (33%), Summarization (23%), and Explanation (19%). This distribution, however, is far from uniform across domains, as shown in Table 4.3: FiQA is uniquely dominated by *Opinion* questions, reflecting its user-generated, forum-driven content, whereas ClapNQ and Govt share a similar Factoid/Summarization-heavy profile.

Domain	Top-3 Question Types	Coverage
ClapNQ	Factoid, Summarization, Explanation	71%
FiQA	Opinion, Factoid, Explanation	51%
Govt	Factoid, Summarization, Explanation	63%
Cloud	Factoid, Explanation, Summarization	50%

Table 4.3: Top-3 question types per domain (development set). Coverage indicates the percentage of domain turns matching one of the three listed types; FiQA’s lower coverage reflects its markedly more diverse question distribution.

The length of reference responses exhibits substantial variance across question type: Summarization answers average 121 words while Factoid answers average only 77 words, motivating the question-type-specific length targets adopted in the generation pipeline of Section 5.3.

The ground-truth answerability distribution in the development set is heavily skewed toward positive cases, as shown in Table 4.4: 84% Answerable, 8% Partially Answerable, 7% Unanswerable, and 1% Conversational. This skew creates a substantial baseline *acceptance bias* risk that, as we discuss in Section 4.3, complicates end-to-end evaluation—a model that always attempts to answer already achieves 84% nominal accuracy on the answerability dimension alone, without any actual discrimination capability.

Domain	Answerable	Partial	Unanswerable	Conversational
ClapNQ	86%	7%	7%	0%
FiQA	82%	9%	7%	3%
Govt	83%	11%	6%	0%
Cloud	86%	5%	7%	1%
Overall	84%	8%	7%	1%

Table 4.4: Answerability distribution per domain (development set, 842 turns). The distribution is broadly uniform across domains at development time—a property that, as shown in Section 6.4, does *not* hold on the held-out test set.

4.2.3 Non-Standalone Query Phenomena

A structural property of the benchmark that is easy to understate in aggregate statistics is *how* non-standalone turns fail to be self-contained. Figure 4.2.1 decomposes the phenomenon across the 732 non-first turns of the development set (multi-label, as a single turn may exhibit more than one dependency simultaneously). Pronoun coreference is overwhelmingly the dominant phenomenon, present in 97% of non-first turns, followed by comparative follow-up constructions (67%) and, less frequently, explicit temporal dependence (18%). This distribution directly motivates the design of the five-pronged query rewriting engine in Section 5.2: the

Minimal reformulation strategy is explicitly scoped to resolve coreference and ellipsis, while comparative and temporally dependent queries are handled by the Chain-of-Thought and Corpus-Specific strategies respectively.




Figure 4.2.1: Distribution of non-standalone phenomena in the development set’s non-first turns ($N=732$, multi-label: a single turn may exhibit more than one phenomenon simultaneously).

4.3 Key Architectural Challenges

Based on the statistical properties of the corpus documented above, we identify three primary engineering bottlenecks that directly shape the system architecture of Chapter 5. We make explicit, for each challenge, which research question (Section 4.4) it motivates.

1. Later-Turn Degradation (motivates RQ1). Unaugmented retrieval performance drops sharply after the first turn. Under ELSER v1 with raw, non-rewritten query formulations, Recall@5 falls from 0.879 at Turn 1 to 0.428 at Turns 6+, a 51% relative drop, most of which occurs between Turns 1 and 2 (Section 6.2.6). This drop co-occurs with pronoun coreference (present in 97% of non-first turns, Figure 4.2.1) and comparative follow-ups (67%), which systematically underspecify the query unless resolved against the history window—the empirical basis for RQ1’s investigation of query diversity as a stabilization mechanism.

2. High Passage Diversity per Conversation (motivates RQ1). Conversations contain an average of 16.9 unique relevant passages distributed across different source files. This high variance implies that the system cannot simply lock onto a single document block once found early in the conversation; it must dynamically adjust its search parameters at each turn to preserve breadth recall without flooding the generator’s context with redundant or stale tokens.

3. The Test Set Distribution Shift (motivates RQ3). The held-out evaluation test set introduces severe distributional shifts relative to the development split, summarized in Table 4.5. While the development split contains multi-turn threads averaging 7.7 evaluated turns per conversation, every record in the test set consists of a *single* evaluated turn embedded within a historical trace, and almost all of these turns (465 of 507, 91.7%) are non-first turns that require contextual understanding, so the “easy” first-turn queries that inflate development-set averages are rare. Furthermore, the unanswerable rate nearly triples, from 6.5% to 19.1% globally, peaking in the Cloud domain at 27% unanswerable turns. Systems whose answerability threshold is calibrated for the development set’s low unanswerable rate therefore face precision degradation at test time due to this threshold mismatch—the central end-to-end finding developed in Section 6.4.

4.4 Research Questions and Hypotheses

The thesis is organized around one central hypothesis:

The end-to-end performance of a multi-turn RAG system is limited primarily by the stability of retrieval across turns and by the calibration of the answerability gate, rather than by the expressive or synthesis capacity of current language models.

Characteristic	Development	Test
Conversations	110	507
Total evaluated turns	842	507
Avg. turns/conversation	7.7	1.0
Answerable or partially answerable	92.3%	74.4%
Unanswerable	6.5%	19.1%
Conversational / other	1.2%	6.5% [†]

Table 4.5: Development vs. test set comparison. The near-tripling of the unanswerable rate, combined with the predominance of non-first turns (91.7% of test turns), makes the test set substantially harder along both the retrieval and answerability-calibration axes. Development: 777 answerable or partially answerable, 55 unanswerable, and 10 conversational turns. Test: 377 turns with Task A relevance judgments (answerable or partially answerable) and 97 unanswerable turns. [†]The category of the remaining 33 test turns could not be recovered from our records.

To examine it, this thesis investigates four Research Questions (RQs), each paired with a concrete, falsifiable hypothesis (H). The hypotheses address the retrieval and answerability parts of the central hypothesis; its final clause—that model capacity is not the binding constraint—is not tested directly, since we did not compare generators of different capability within Task C.

RQ1: Can structural query reformulation diversity substitute for heterogeneous retriever ensembling when targeting the vocabulary gap in deep dialogue turns?

H1: *Fusing diverse, prompt-targeted query expansions over a single, highly corpus-aligned index captures complementary evidence pools without admitting the cross-domain ranking noise characteristic of multi-model retrieval ensembles.*

RQ2: Does the introduction of a context bottleneck via verbatim evidence sentence extraction suppress parametric hallucinations without degrading the reference-based measures of answer quality?

H2: *Restricting the generator’s input to a compressed set of exact, extracted spans structurally bounds the token space available for hallucination, driving an asymmetric optimization in reference-less faithfulness metrics relative to reference-based metrics.*

RQ3: How does the precision–recall trade-off of answerability gates behave under sudden, severe distribution shifts in unanswerable query density?

H3: *Multi-layer answerability judges operating over independent signals (documents, spans, answers) reduce acceptance bias relative to a single-judge baseline, but nonetheless require distribution-adaptive threshold calibration to maximize harmonic-mean scores under high-unanswerable-rate test conditions.*

RQ4: Can LLM-based reranking provide measurable gains over cross-encoder models when first-stage retrieval recall is close to saturation?

H4: *Once first-stage retrieval recall approaches its Pareto upper bound ($R@100 > 0.90$), general-purpose LLM-as-a-judge listwise rerankers saturate, introducing substantial additional latency and cost for marginal or negative utility compared to optimized, specialized cross-encoders.*

These four hypotheses are evaluated empirically in Chapter 6: H1 and H4 are addressed jointly in the Task A retrieval ablations (Section 6.2), H2 in the Task B generation ablations (Section 6.3), and H3 in the Task C answerability analysis (Section 6.4).

4.5 Formal Evaluation Methodology

System evaluation follows the strict tripartite protocol of MTRAGEval. Retrieval performance (Task A) is quantified using Recall@ k (for $k \in \{5, 10, 50, 100\}$) and nDCG@5. Generation quality (Tasks B and C)

is measured via three complementary metrics, synthesized into a final Harmonic Mean (HM) leaderboard metric:

1. **Reference-Based Algorithmic Score (RB_{alg})**: evaluates syntactic and sentence-level alignment against human-edited reference corrections, computed as an algorithmic fusion of BERT-Recall, BERT-K-Precision, and ROUGE-L.
2. **Reference-Less Faithfulness Metric (RL_F)**: derived from the RAGAS framework [11], evaluating whether generated claims are strictly supported by the extracted evidence spans, independently of the human reference string.
3. **Reference-Based LLM Judge (RB_{llm})**: a median-aggregated, multi-persona evaluator assessing three explicit criteria—Faithfulness (hallucination audit), Appropriateness (intent fulfillment and correct answerability handling), and Completeness (evidence coverage).

The final leaderboard score is calculated as the harmonic mean of the three components:

$$HM = \frac{3}{\frac{1}{RB_{alg}} + \frac{1}{RL_F} + \frac{1}{RB_{llm}}} \quad (4.5.1)$$

The choice of harmonic—rather than arithmetic—mean is deliberate and consequential: it strictly penalizes systems that exhibit asymmetric performance across the three axes (e.g., high fluency but low faithfulness due to hallucination), forcing balanced optimization across all three components rather than allowing strength on one axis to compensate for weakness on another. The additive objective of Equation (4.1.6) (Section 4.1.4) does not reproduce this property; it serves only as a conceptual decomposition of the task.

Crucially, an automated “I Don’t Know” (IDK) classifier filters all response strings prior to scoring. Correct refusals on genuinely unanswerable turns are awarded a perfect score of 1.0 across all three axes, whereas incorrect refusals on answerable turns, or false acceptances on unanswerable turns, receive a score of 0. This scoring rule makes the answerability gate a high-stakes component of the end-to-end system alongside retrieval and generation quality, and motivates the answerability part of the central hypothesis stated in Section 4.4.

4.6 Scope and Constraints

To situate the contributions of Chapter 5 correctly, we state explicitly what this thesis does and does not attempt, rather than leaving these boundaries implicit until the limitations discussion of Chapter 7.

4.6.1 In Scope

- **All three MTRAGEval subtasks** (Sections 4.1): passage retrieval (Task A), reference-grounded generation (Task B), and end-to-end RAG (Task C), evaluated under the official competition protocol on both the development and held-out test splits.
- **Architectural and prompt-level interventions** over frozen, proprietary API models (DeepSeek-V3.2 [8], GPT-4o, GPT-4o-mini [30]): query reformulation strategy design, rank fusion algorithm design, evidence extraction and multi-candidate generation, and multi-judge answerability gating.
- **A single, corpus-aligned learned sparse retriever** (ELSER v1) as the retrieval backbone, with retriever *selection* itself treated as an empirical question addressed in Section 6.2 rather than assumed a priori.
- **Development-set ablation of the main architectural components** introduced in Chapter 5 (query rewriting, retriever choice, reranking, the generation stages, the extractiveness band, and the answerability gate). Settings without a retained ablation—model routing, the per-corpus Nested RRF weights, the five-passage extraction limit, and the 60% judge-invocation rate—are reported explicitly as design decisions (Sections 5.3 and 6.3.4).

4.6.2 Out of Scope

- **Fine-tuning or parameter adaptation of any model.** No component of the pipeline—rewriter, generator, extractor, or judge—is fine-tuned on MTRAG data. Every reported gain is attributable to prompt engineering, architectural decomposition, and inference-time orchestration, not to gradient-based adaptation. Knowledge distillation into open-weight models is discussed only as future work (Section 7.4), not attempted here.
- **Cross-benchmark generalization.** The system is designed, tuned, and evaluated exclusively on MTRAG [22]. We do not claim, nor do we evaluate, transfer to other conversational RAG benchmarks (e.g., TREC iKAT [2], RAD-Bench [23]); the architectural principles of Chapter 5 are motivated by structural properties of multi-turn RAG that are plausibly shared across benchmarks, but this claim is not empirically tested in this thesis.
- **Distribution-adaptive calibration at inference time.** All thresholds and weights (the answerability confidence threshold τ , the extractiveness band, the Nested RRF corpus weights) are tuned once on the development set and frozen for the test-set submission. As Section 6.4 discusses, this static calibration is a likely major driver of the Task C performance gap; online, distribution-adaptive calibration is scoped as future work rather than implemented here.
- **Non-English or cross-lingual retrieval and generation.** All four MTRAG corpora (Table 4.2) are English-language; no claim is made about the system’s behavior on multilingual or code-switched conversational input.
- **Human user studies and production deployment.** Evaluation is conducted exclusively against the offline MTRAGEval benchmark and its automated metrics (Section 4.5); no live user study, latency-under-load measurement, or production A/B test is performed. Section 7.3 discusses the orchestration engineering that would be required before such deployment.

This scope delineation follows directly from the unified optimization perspective of Section 4.1.4: the thesis addresses the architectural decomposition of $\mathcal{U}$ into retrieval, generation, and answerability sub-objectives, and the empirical validation of each sub-objective in isolation and in composition—not the orthogonal questions of model training, cross-domain transfer, or production-scale deployment engineering.

Chapter 5

The AILS-NTUA System Architecture

This chapter provides an exhaustive technical description of the AILS-NTUA architecture developed for multi-turn conversational Retrieval-Augmented Generation. We proceed from architectural principles (Section 5.1) to the multi-strategy retrieval engine addressing Task A (Section 5.2), the multi-stage agentic generation pipeline addressing Task B (Section 5.3), and finally the unified end-to-end system with its multi-layer answerability gate addressing Task C (Section 5.4). Throughout, we use the notation established in Chapter 4: H_t for dialogue history, q_t for the active query, $\mathcal{D}_t$ for retrieved passages, and y_t for the generated response at turn t .

5.1 Architectural Overview and System Principles

The design of AILS-NTUA addresses the two systematic vulnerabilities of multi-turn dialogue identified in Chapter 4—unresolved cross-turn dependency and the resulting context drift in retrieval, and the answer-or-abstain decision of end-to-end RAG—by replacing brittle, monolithic components with an engineered chain of decentralized, task-specific modules. Rather than treating retrieval and generation as opaque black boxes to be scaled with larger models, the architecture is governed by two orthogonal design principles that recur throughout this chapter.

Principle 1 — Query Diversity over Retriever Diversity. A common architectural instinct when facing retrieval brittleness is to ensemble multiple heterogeneous retrievers (e.g., a sparse lexical model, a dense neural model, and a learned sparse model), on the assumption that diverse retrieval signals are strictly complementary. Under the benchmark’s official relevance judgments, our ablations (Section 6.2) do not support this assumption in the multi-turn setting: heterogeneous retriever ensembling raises deep recall but lowers top-rank precision, displacing high-confidence hits from the top of the ranking (subject to the pooling-bias caveat of Section 6.2.4). AILS-NTUA instead fixes the search index onto a single corpus-aligned encoder, the strongest in our retriever comparison (ELSER v1, Section 6.2), and diversifies the *query side* instead, projecting the same underspecified utterance across five complementary LLM-generated reasoning paths (Section 5.2).

Principle 2 — Deferred Answer Commitment via Multi-Agent Verification. Rather than committing to a single generation pass, the system insulates factual synthesis from full-document noise through a sequence of evidence bottlenecks: sentence-level span extraction, parallel drafting of multiple candidate responses, and programmatic validation by a persona-conditioned judge ensemble before any answer is finalized. This mirrors the LLM-as-a-Judge paradigm reviewed in Section 3.4.2, extended here with an explicit extractiveness-calibration objective (Section 5.3).

These two principles map directly onto the three functional modules of the system, which correspond one-to-one with the MTRAGEval subtask specification of Section 4.1: the **Multi-Strategy Retrieval Pipeline** (Task A, Figure 5.2.1), the **Multi-Stage Agentic Generation Pipeline** (Task B, Figure 5.3.2), and the **Unified End-to-End System** (Task C, Figure 5.4.1), which composes the first two modules and

adds a dedicated answerability-gating layer. Figure 5.1.1 summarizes how these three modules relate before the following sections detail each one individually.




Figure 5.1.1: High-level composition of the three functional modules of AILS-NTUA. Task A (retrieval) and Task B (reference-grounded generation) are each evaluated independently in their standalone configurations; Task C composes both: span extraction and dual-candidate drafting run first, because the answer-level judge of the Multi-Layer Answerability Gate (Sec. 5.4, Fig. 5.4.1) inspects a drafted answer; the gate then either lets the turn finish the remaining Task B stages or replaces the draft with a calibrated refusal.

5.2 The Multi-Strategy Retrieval Pipeline (Task A)

The retrieval pipeline transforms a brief, context-dependent query q_t and its conversation history H_t into a stable, noise-resilient ranked list of passages $\mathcal{D}_t$, through a four-stage process: query rewriting, first-stage sparse retrieval, cross-encoder reranking, and hierarchical rank fusion.

5.2.1 The Five-Pronged Query Rewriting Engine

At turn t , the historical window H_t (truncated to the six most recent user turns and up to three assistant turns, per the ablation of Table 5.5) and the active utterance u_t are passed to a query rewriting module instantiated on DeepSeek-V3.2 at temperature $T=0.0$. The module executes five independent prompt tracks *simultaneously*, each engineered to target a distinct failure mode identified in Section 4.2.3:

Minimal Reformulation ($q_t^{\min}$). Resolves purely anaphoric tokens and structural ellipsis, converting the query into a grammatically complete, standalone question while preserving the user’s original phrasing as closely as possible. This strategy is deliberately conservative—its system prompt explicitly instructs the model *not* to introduce new terminology—so as to avoid the over-expansion failure mode observed with weaker rewriting models (Section 6.2).

Corpus-Specific Reformulation (q_t^{corp}). Maps the user’s conversational terminology onto the formal register, synonym sets, and structural metadata conventions of the active domain corpus (e.g., translating informal forum phrasing in FiQA into standard financial terminology). Domain-specific preservation rules govern what must be kept verbatim—entity variants and temporal phrasing for ClapNQ, exact amounts and tickers for FiQA, program names and form identifiers for Govt, and error codes and CLI flags for Cloud.

Hypothetical Document Embedding (q_t^{hyde}). Following the HyDE paradigm introduced in Section 3.1.4, instructs the LLM to generate a brief, zero-shot hypothetical answer passage

based entirely on its parametric knowledge. This hypothetical block acts as a semantic proxy that pivots the matching problem from question-to-passage to answer-to-passage similarity.

Chain-of-Thought Decomposition (q_t^{cot}). Triggers a sequential reasoning prompt that first identifies the explicit sub-questions and intermediate information primitives necessary to answer q_t , before producing the final rewritten query. This captures the underlying informational structure of complex or comparative questions that a single surface-level rewrite would miss.

Anchor Keyword Targeting (q_t^{key}). Extracts static, high-discrimination alphanumeric sequences—entity names, acronyms, error codes, system identifiers—that function as structural indexing anchors, particularly valuable for the technical, code-dense Cloud domain where semantic paraphrase strategies are least reliable.

Each of the five strategies produces both a rewritten query string and a binary standalone/non-standalone classification, returned as structured JSON to guarantee downstream parseability. All five prompt templates share a common XML-structured scaffold (system instructions, few-shot demonstration, structured output schema) but differ in their preservation rules and the amount of assistant-turn context supplied, summarized in Table 5.1.

Strategy	Assistant Turns	Key Behavior
Minimal	3	Coreference and ellipsis resolution only
Corpus-Specific	0–3	Domain-aware terminology mapping
Chain-of-Thought	3	Explicit intermediate reasoning trace
HyDE	3	Zero-shot hypothetical answer passage
Anchor-Keyword	1	Entity and intent term extraction

Table 5.1: Configuration of the five query rewriting strategies. The amount of assistant-turn context supplied is tuned per strategy: Anchor-Keyword requires minimal context since it operates primarily on the current utterance, while reasoning-heavy strategies (Minimal, CoT, HyDE) benefit from a wider historical window.

5.2.2 Validating the Necessity of LLM-Based Rewriting

Before committing to the five-strategy design of Table 5.1, we first verified that instruction-following LLM rewriting is actually *necessary*, rather than assuming it a priori. Table 5.2 compares the unaugmented baseline against a non-LLM neural rewriter (FlanT5, fine-tuned for query reformulation) and an annotator-replica prompt that reproduces the query rewriting instructions used during MTRAG’s own data collection process [22].

Method	Recall@5	nDCG@5
Unaugmented baseline	0.483	0.444
FlanT5 (non-LLM neural rewriter)	0.462	0.421
Annotator-replica prompt	0.513	0.470
Minimal (ours, DeepSeek-V3.2)	0.527	0.487
Corpus-Specific (ours, best single strategy)	0.541	0.498

Table 5.2: Rewriting method necessity check, development set. FlanT5 falls *below* the unaugmented baseline, confirming that poorly calibrated rewriting actively harms retrieval; every LLM-based strategy improves over both the baseline and the annotator-replica prompt.

The result is a genuine negative finding for the smaller, non-LLM rewriter: FlanT5 degrades Recall@5 *below* the unaugmented baseline ($0.483 \rightarrow 0.462$), confirming that rewriting is not unconditionally beneficial—a reformulation model without strong instruction-following capability introduces more query drift than it resolves, over-generalizing the original intent rather than sharpening it. This ruled out non-LLM rewriters and classical pseudo-relevance feedback early in development (see also the negative PIR result of Section 6.2.5, which encounters a structurally related failure mode) and confined the design space explored in Section 5.2.1 to prompt-level variation over a single strong instruction-following backbone.

Table 5.3 illustrates the qualitative behavior of each strategy on a representative non-standalone Cloud-domain query, where *the pricing* refers to an entity (IBM Cloud Object Storage) introduced several turns earlier in the conversation.

Strategy	Example Output
Original	“What about the pricing?”
Minimal	“What is the pricing for IBM Cloud Object Storage?”
Corpus-Specific	“IBM Cloud Object Storage pricing tiers and cost structure”
HyDE	“IBM Cloud Object Storage offers flexible pricing based on storage class, including Standard, Vault, and Cold Vault tiers...”
Chain-of-Thought	“Need: storage costs, transfer fees, API pricing → IBM Cloud Object Storage full pricing breakdown”
Anchor-Keyword	“IBM Cloud Object Storage pricing cost GB month tier”

Table 5.3: Representative reformulations of a non-standalone Cloud-domain query. Each strategy resolves the underspecified reference to *the pricing* differently, illustrating the complementary failure-mode coverage that motivates fusing all five under Nested RRF (Section 5.2.4) rather than selecting a single “best” strategy.

5.2.3 First-Stage Learned Sparse Search and Cross-Encoder Reranking

Each of the five generated queries q_t^m (for $m \in \{\text{min, corp, hyde, cot, key}\}$) is issued *independently* to the ELSER v1 learned sparse retriever, which scans the corpus-specific index and surfaces the top- N ($N=100$) document passages according to its learned term-expansion weights (Section 3.1.3).

To sharpen top-tier precision beyond what the sparse retriever alone provides, the top-60 passages from each individual track are routed to a specialized cross-encoder reranker [28, 29], instantiated as **Cohere Rerank v4**. The cross-encoder computes full cross-attention over the concatenated query–passage token sequence, returning a finely calibrated relevance score that the sparse retriever’s bag-of-weights scoring cannot capture—in particular, negation, multi-hop entity disambiguation, and fine-grained numerical comparison.

The reranker’s output is *not* used as a standalone ranking signal. As shown in Section 6.2 (Table 6.5), replacing the retriever entirely with a cross-encoder lowers Recall@5 by 4.6–10.6 points (8.7–20.0% relative) compared with the sparse retriever baseline, despite the cross-encoder’s strong performance on standard, static IR benchmarks. Instead, retriever and reranker signals are fused through a weighted RRF combination:

$$\text{Score}(d) = \frac{1}{k + r_E(d)} + \alpha \cdot \frac{1}{k + r_R(d)} \quad (5.2.1)$$

where $r_E(d)$ and $r_R(d)$ denote the ranks assigned to document d by the ELSER retriever and the Cohere reranker respectively, k controls rank-decay steepness ($k=60$), and α balances the relative contribution of the two signals ($\alpha=0.5$, tuned on the development set). We interpret this asymmetry—strong *fused* contribution but weak *standalone* contribution—as evidence that the cross-encoder functions as a complementary refinement filter operating on an already-relevant candidate pool, rather than as an independent source of retrieval recall; a distinction with direct implications for practitioners tempted to deploy reranker-only pipelines in low-resource settings.

5.2.4 The Nested Reciprocal Rank Fusion (Nested RRF) Algorithm

Rather than combining the five reranked candidate lists under a single, flat RRF aggregation (Section 3.2.1), the pipeline introduces a hierarchical, two-level **Nested RRF** structure, designed to limit the influence of the exploratory reformulations. The design rests on the expectation, motivated in Section 3.2.2, that Minimal and Corpus-Specific reformulations behave consistently across turns, whereas HyDE, Chain-of-Thought, and Anchor-Keyword are more volatile—helpful on some turns and misleading on others, depending on whether the generated hypothesis or reasoning trace matches the true topic. We did not measure per-turn variance directly; the per-strategy results of Section 6.2 show that HyDE is the weakest single strategy in every domain, while the complete fusion still exceeds the best single strategy.

Algorithm 1 formalizes the two-level fusion procedure. At **Level 1**, the three exploratory tracks are pre-aggregated via flat RRF into a single intermediate “weak consensus” ranking, using an internal smoothing constant $k_{\text{internal}}=40$; this pre-aggregation step is intended to absorb the idiosyncratic noise of any single exploratory strategy before it can independently displace a high-confidence document from the final top- k . At **Level 2**, this consensus ranking is fused with the two conservative strategies under domain-specific weights $w_s^{(c)}$, producing the final passage ranking $\mathcal{D}_t$.

Algorithm 1: Nested Reciprocal Rank Fusion

Input: Reranked lists $\mathcal{L}_{\text{min}}, \mathcal{L}_{\text{corp}}, \mathcal{L}_{\text{key}}, \mathcal{L}_{\text{hyde}}, \mathcal{L}_{\text{cot}}$; constant k ; corpus-specific weights $w_s^{(c)}$

Output: Unified ranked passage list $\mathcal{D}_t$

▷ **Level 1: pre-aggregate high-variance exploratory paths**

1 **for** each document $d \in \mathcal{L}_{\text{hyde}} \cup \mathcal{L}_{\text{cot}} \cup \mathcal{L}_{\text{key}}$ **do**

2 $\text{Score}_{\text{L1}}(d) \leftarrow \frac{1}{k_{\text{internal}} + \text{rank}_{\text{hyde}}(d)} + \frac{1}{k_{\text{internal}} + \text{rank}_{\text{cot}}(d)} + \frac{1}{k_{\text{internal}} + \text{rank}_{\text{key}}(d)}$;

3 $\mathcal{L}_{\text{consensus}} \leftarrow \text{SortDocumentsByScore}(\text{Score}_{\text{L1}})$;

▷ **Level 2: final aggregation with low-variance stable paths**

4 **for** each document $d \in \mathcal{L}_{\text{min}} \cup \mathcal{L}_{\text{corp}} \cup \mathcal{L}_{\text{consensus}}$ **do**

5 $\text{Score}_{\text{final}}(d) \leftarrow \sum_{s \in \{\text{min}, \text{corp}, \text{consensus}\}} \frac{w_s^{(c)}}{k_{\text{final}}^{(c)} + \text{rank}_s(d)}$;

6 $\mathcal{D}_t \leftarrow \text{SortDocumentsByScore}(\text{Score}_{\text{final}})[\text{top-}k]$;

7 **return** $\mathcal{D}_t$

The domain-specific weights $w_s^{(c)}$ and final-stage smoothing constants $k_{\text{final}}^{(c)}$, reported in Table 5.4, were tuned by grid search exclusively on the development set. The pattern of tuned values is itself interpretable: formal, terminology-dense domains (Govt, Cloud) assign the largest weight to the conservative Minimal strategy, which preserves exact domain terminology, whereas FiQA—the domain with the largest vocabulary gap between informal user language and formal document content—assigns comparatively more weight to the exploratory weak-consensus group, where semantic paraphrase diversity is most valuable. We note, however, that this tuning is a refinement rather than a prerequisite: in development runs, uniform weights across all four domains lowered Recall@5 by less than 1% relative to the tuned configuration (this comparison is not tabulated). The precise weight values therefore matter little; whether the hierarchical structure itself improves over a flat fusion of the same five lists was not isolated (Section 6.2).

Parameter	ClapNQ	FiQA	Govt	Cloud
$k_{\text{final}}^{(c)}$	20	60	40	20
w_{Minimal}	0.55	0.45	0.65	0.65
$w_{\text{Corpus-Spec}}$	0.40	0.40	0.25	0.30
$w_{\text{WeakConsensus}}$	0.05	0.15	0.10	0.05

Table 5.4: Nested RRF parameters tuned per corpus on the development set. Formal, terminology-stable domains (Govt, Cloud) weight the conservative Minimal strategy most heavily; FiQA, with the widest vocabulary gap, allocates the largest share to the exploratory weak-consensus group.

5.2.5 Conversation History Window Ablation

The query rewriting stage (Section 5.2.1) requires access to prior conversation turns to resolve coreferences and reconstruct standalone queries. We ablate the amount of history provided to the rewriter along two independent axes: the number of user turns and the number of assistant turns included in the prompt window. Table 5.5 reports the results under Minimal rewriting on the development set.

Two observations follow. First, retrieval quality is essentially insensitive to history beyond the first 4–6 user turns: the gain from 4 to 6 user turns is only +0.002 R@5 (and 0.000 from 4 to 8), an order of magnitude smaller than the +0.038 gain from 0 to 4 turns. This saturation is consistent with the turn-depth degradation




Figure 5.2.1: Task A retrieval pipeline: five complementary reformulations are issued independently to ELSER v1, followed by hybrid cross-encoder reranking and hierarchical Nested RRF fusion.

pattern of Section 6.2.6 — most coreferential ambiguity is resolved by recent, not distant, context. Second, providing the *full* unbounded history scores marginally lower than the 6-turn window (0.531 vs. 0.533), a difference within run-to-run noise; a plausible reason is that early, no-longer-relevant turns dilute the rewriter’s effective attention over the truncated prompt budget. We adopt a window of 6 user turns and 3 assistant turns as a conservative default: while assistant turns add negligible *aggregate* benefit, they remain necessary in edge cases where the user references an entity introduced only in a prior assistant response, and their aggregate cost in prompt length is small.

5.3 The Multi-Stage Agentic Generation Pipeline (Task B)

When the system is provided with a static, gold-standard reference block $\mathcal{D}_t^*$ (Task B specification, Section 4.1.2), the generation module deliberately bypasses single-pass text generation, decomposing synthesis into five structured, sequential operational stages (Figure 5.3.2). This decomposition operationalizes Principle 2 of Section 5.1: no stage commits to the final answer until the preceding evidence-gathering and verification stages have executed.

Stage 1 — Preliminary Answerability Classification. A lightweight verification prompt, executed on GPT-4o-mini, scans the reference passages $\mathcal{D}_t^*$. If the model determines with high confidence that the provided context lacks the information required to answer q_t , the pipeline halts immediately and returns a calibrated refusal string, avoiding the computational cost of the four downstream stages on a turn that cannot be answered regardless of generation quality.

Stage 2 — Verbatim Evidence Span Extraction. To isolate the generator from document-level noise and mitigate the lost-in-the-middle effect [25] discussed in Section 3.4.1, the context is routed through a fine-grained extraction bottleneck. The extraction model isolates the exact sentences or phrases within $\mathcal{D}_t^*$ that explicitly support an answer to q_t , returning a compressed, verbatim evidence set $\mathcal{S}_t = \{s_1, s_2, \dots, s_m\}$ with $m \leq 8$. As shown in Section 6.3, this single stage contributes the largest individual improvement of the entire generation pipeline (+0.034 Harmonic Mean), together with a +0.041 gain in the reference-less faithfulness metric RL_F —development-set support for the faithfulness part of Hypothesis H2 of Section 4.4.

Configuration	User turns	Asst. turns	Recall@5
No history	0	0	0.490
2 user turns	2	0	0.506
4 user turns	4	0	0.528
6 user turns	6	0	0.530
8 user turns	8	0	0.528
6u + 1 asst.	6	1	0.528
6u + 3 asst. (ours)	6	3	0.533
6u + 5 asst.	6	5	0.532
Full history	all	all	0.531

Table 5.5: Conversation history window ablation (Minimal rewriting, development set). Recall@5 saturates after 4–6 user turns; assistant turns contribute negligible aggregate benefit beyond one turn. This sweep was a separate run: under the same window, the Minimal strategy scores $R@5=0.527$ in the strategy ablations (Table 6.4), and the 0.006 difference could not be fully reconciled.

Stage 3 — Dual-Candidate Drafting. The extracted spans $\mathcal{S}_t$ initialize two parallel generation tracks on GPT-4o, producing structurally distinct candidate responses:

- **Deterministic Draft** ($y_t^{\text{det}}, T=0.0$): prioritizes literal precision, exact data formatting, and direct extraction from $\mathcal{S}_t$, maximizing reference-based overlap metrics at the cost of conversational fluency.
- **Stochastic Draft** ($y_t^{\text{sto}}, T=0.1$): targets conversational naturalness and discourse-level fluidity, at the cost of a marginally higher risk of drifting from the extracted evidence.

The narrow temperature gap between the two drafts (0.0 vs. 0.1, rather than a wider spread) is itself a tuned design choice: wider gaps (e.g., $T_2=0.3\text{--}0.5$) were found in preliminary experiments (not retained) to degrade RL_F without a compensating HM gain, since the stochastic draft’s increased diversity comes disproportionately at the expense of grounding rather than genuine fluency variation.

Stage 4 — Multi-Judge Selection Framework. The two candidates are evaluated by an ensemble of specialized judges, each processing the candidate text alongside the original query and the extracted evidence spans $\mathcal{S}_t$:

- **Technical Judge** (DeepSeek-V3.2): evaluates absolute factual accuracy against $\mathcal{S}_t$ and flags internal contradictions or unsupported claims.
- **User Satisfaction Judge** (GPT-4o-mini, invoked stochastically on 60% of turns): scores how completely and naturally the draft addresses the implicit information need, without evasive hedging language.

Selection additionally incorporates an **Extractiveness Shaping** term $\phi(r_4)$, which measures the 4-gram token overlap r_4 between the candidate answer and the concatenated evidence spans, and penalizes deviation from an empirically calibrated ideal band:

$$\phi(r_4) = \begin{cases} -1.5 & \text{if } r_4 < 0.28 \quad (\text{under-extractive: hallucination risk}) \\ +2.5 & \text{if } 0.28 \leq r_4 \leq 0.38 \quad (\text{ideal}) \\ +1.5 & \text{if } 0.38 < r_4 \leq 0.50 \quad (\text{acceptable}) \\ +0.5 & \text{if } r_4 > 0.50 \quad (\text{over-extractive: robotic copying}) \end{cases} \quad (5.3.1)$$

The ideal band $[0.28, 0.38]$ was calibrated directly against the empirical 4-gram overlap of the development set’s human reference answers, which average 36.2%. The function is deliberately *asymmetric*: the penalty for under-extractive drafts (-1.5) is substantially larger in magnitude than the reduced reward for over-extractive ones ($+0.5$), reflecting our expectation that hallucination degrades downstream quality metrics more than mild verbatim repetition. Figure 5.3.1 visualizes this shaping function. The prompts of Section 5.7.2 refer to related but distinct values: the generation prompt asks for roughly 35% verbatim overlap, i.e., close to the

center of the ideal band, and the Technical Judge prompt states a wider tolerance of 28–45%; the band that actually enters the selection score is the one of Equation (5.3.1).




Figure 5.3.1: The extractiveness shaping function $\phi(r_4)$: an asymmetric penalty/reward profile over the fraction of 4-grams shared between a candidate answer and its extracted evidence spans, calibrated so that the ideal band $[0.28, 0.38]$ matches the empirical overlap of human reference answers (36.2%).

The composite selection score combines all three signals—technical judge score, signed user-preference indicator, and extractiveness shaping—together with an explicit penalty for residual hedging or refusal language detected via a forbidden-phrase filter (e.g., “I am not sure”, “it is unclear”), which we found to fire disproportionately on partially-answerable turns where the generator hedges despite the presence of usable evidence.

Stage 5 — Micro-Adjustment and Post-Processing. The selected candidate undergoes a final, lightweight editing pass (GPT-4o-mini, $T=0.1$) that is applied *only* when the answer violates one of three explicit length or extractiveness constraints, removing formulaic meta-commentary (e.g., “Based on the provided context...”) and aligning response length with the question-type-specific target established in Section 4.2.2.

Conversation History in Generation. A distinct question from the retrieval-side history window of Section 5.2.5 is how much prior conversational context the *generation* stage itself should receive, independently of the already-rewritten, already-retrieved evidence. We swept the number of prior turns supplied to the Stage 3 drafting prompt (0, 2, 4, and all). Providing 2–4 turns of history improved HM on follow-up (non-first-turn) tasks by +0.009 relative to providing none, while providing the *full* conversation history scored slightly lower. A plausible explanation, consistent with the prompt-length effect observed for the rewriter in Section 5.2.5, is that longer prompts displace the extracted evidence spans $\mathcal{S}_t$ from the model’s effective attention. We adopt 4 turns as the default for the generation stage. Only these summary differences were retained from this sweep, so per-configuration scores are not tabulated.

Model Routing and Cost Efficiency. Table 5.6 summarizes the role-based model routing strategy adopted across the five stages. The routing principle is *capability-aligned assignment*: within Task B, GPT-4o is reserved for the two generation calls, where fluency and long-form coherence matter most; DeepSeek-V3.2 handles span extraction and technical judging, which are structured, deterministic-output tasks for which a cheaper model was considered sufficient; and GPT-4o-mini covers the remaining lightweight, conditional stages. At nominal API pricing the routed pipeline costs an estimated \$0.010–0.012 per turn, compared with an estimated \$0.024 for assigning GPT-4o to every stage, i.e., roughly 2–2.4× less.¹ Routing is a cost-motivated design decision: we did not retain a controlled quality comparison against uniform single-model configurations (Section 6.3).

¹Our system paper [5] reports \$0.008 per turn and a 3× reduction. Summing the per-stage estimates of Table 5.6, with both generation calls counted, gives \$0.010–0.012, which we report here.




Figure 5.3.2: Task B generation pipeline: a five-stage chain that defers commitment to the final response until multiple candidates have been drafted, evidence-checked, and judged.

Pipeline Stage	Model	Est. Cost / Call
Answerability Triage (Stage 1)	GPT-4o-mini	\$0.0001
Evidence Span Extraction ($\times 1-2$)	DeepSeek-V3.2	\$0.0008
Candidate Generation ($\times 2$)	GPT-4o	\$0.0045 $\times 2$
Force-Answer Fallback (conditional)	GPT-4o-mini	\$0.0003
Technical Judge	DeepSeek-V3.2	\$0.0003
User Satisfaction Judge (60% of turns)	GPT-4o-mini	\$0.0001
Micro-Adjustment (conditional)	GPT-4o-mini	\$0.0002
Total per turn	—	$\approx \\$0.010-0.012$

Table 5.6: Role-based model routing across the Task B generation pipeline, with estimated per-call costs at nominal API pricing (estimates, not measured invoices). The per-turn total ranges from about \$0.010, when only the always-executed stages run, to about \$0.012 when all conditional stages fire.

5.3.1 Question-Type-Specific Generation Targets

Stage 3 generation (Section 5.3) is conditioned on a lightweight, rule-based question-type classifier that sets an explicit style hint and soft length target in the generation prompt, rather than leaving length and register entirely to the generator’s discretion. Table 5.7 lists the seven recognized categories.

The classifier is deliberately rule-based rather than LLM-based. Preliminary experiments with an LLM-based type classifier introduced error propagation whenever the predicted type was itself incorrect — e.g., misclassifying a factoid question as *Explanation* led to verbose, unfocused generation that degraded both faithfulness and naturalness. A rule-based classifier is also deterministic given identical surface patterns, eliminating an additional source of inter-query variance that would otherwise confound the extractiveness-shaping function of Equation (5.3.1).

Type	Target	Δ	Style hint
Keyword	90w	0	Interpret and answer
How-to	95w	+5	Step-by-step
Explanation	100w	+10	Clear explanation
Comparative	95w	+5	Compare systematically
Summarization	105w	+15	Comprehensive summary
Factoid	85w	-5	Direct answer
Default	90w	0	Complete answer

Table 5.7: Question-type rules, style hints, and length targets. Rules are evaluated top-to-bottom; the first pattern match wins. The 90-word base target was calibrated against the development-set reference-answer mean length (90.9 words).

5.4 The Unified End-to-End System and Answerability Gate (Task C)

In the unified end-to-end framework (Task C specification, Section 4.1.3), the retrieval and generation pipelines described above are composed directly: the system first executes the Task A pipeline to obtain retrieved passages, then runs span extraction and dual-candidate drafting (Task B, Stages 2–3) on them, and only then applies the answerability gate described below, because one of its judges inspects the drafted answer. Two departures from the Task A/B configurations are necessary to handle the additional uncertainty introduced by self-retrieved, potentially irrelevant evidence.

First, the system retrieves only the top-3 passages, rather than the top-10 used in the standalone Task A evaluation. This reduction is an empirically motivated noise-control measure: in the Task C ablation (Section 6.4.3), reducing the passage count from 5 to 3 adds +0.024 HM, suggesting that additional, marginally relevant passages increase the opportunity for the generator to drift from the relevant evidence.

Second, and more centrally, the system introduces a **Multi-Layer Answerability Voting Gate** that decomposes the answerability decision $\hat{z}_t$ of Section 4.1.3 across three independent levels of abstraction, rather than relying on the single, coarse-grained answerability check used in Task B:

- **Document-Level Judge** ($\hat{z}_t^{\text{doc}}$): evaluates the raw relevance and semantic coherence of the top-3 retrieved passages against the conversation history.
- **Span-Level Judge** ($\hat{z}_t^{\text{span}}$): assesses whether the extracted verbatim evidence set $\mathcal{S}_t$ contains sufficient semantic content to construct a valid answer, independently of whether the source passages were themselves judged relevant.
- **Answer-Level Judge** ($\hat{z}_t^{\text{ans}}$): audits the final drafted candidate response against the original query to detect partial or incomplete information coverage that may not be visible at the document or span level alone.

The three judges share the prompt template of Section 5.7.3, which outputs one of three classes (ANSWERABLE, PARTIAL, UNANSWERABLE) with a confidence score; they differ in the evidence they receive (retrieved passages, extracted spans, or the drafted answer). A judge’s verdict counts as negative ($\hat{z}_t^{(\cdot)} = 0$) when it outputs UNANSWERABLE; PARTIAL is treated as answerable.

The rationale for three judges, rather than one, is discussed in Section 6.4.1: document- and span-level judges tend to correctly reject genuinely insufficient evidence, while the answer-level judge tends to accept drafted answers that remain plausible on their face—favoring fluency over evidentiary sufficiency. A single judge operating only at the answer level would therefore inherit this acceptance bias in full; decomposing the decision across independent signal spaces allows the system to detect disagreement between levels as an informative signal in its own right.

The three binary verdicts are combined via a **confidence-weighted voting scheme with dissenter override**: if any single judge registers a negative verdict with confidence $\geq \tau$ (calibrated to $\tau=0.7$), the

drafted answer is replaced by a length-capped (≤ 25 words) standardized refusal; otherwise the verdicts are aggregated by a confidence-weighted vote. The override is deliberately asymmetric—one confident dissenter suffices to block an answer—reflecting a deliberate design preference against releasing confidently hallucinated answers, at the price of occasional over-cautious refusals.




Figure 5.4.1: Task C end-to-end pipeline: span extraction and drafting run on the retrieved passages, after which a three-judge, confidence-weighted gate with dissenter override either lets the turn finish the remaining Task B stages (judge-based selection and micro-adjustment) or replaces the draft with a calibrated refusal.

All three judges and the voting arbiter are instantiated on GPT-4o at $T=0.0$, reflecting the higher-stakes, safety-critical nature of the answerability decision relative to the lower-cost structured-extraction stages elsewhere in the pipeline. Answerable turns continue through the remaining Task B stages (judge-based selection and micro-adjustment); for unanswerable turns the drafted answer is discarded and replaced by the refusal, so that no unsupported answer is emitted. Because drafting precedes the gate, a refusal saves only the cost of the selection and micro-adjustment stages, not of generation itself.

5.5 Implementation Details

Beyond the stage-level algorithmic design described above, several lightweight engineering mechanisms recur across the pipeline and are consolidated here for clarity.

Regex-Based Fast Paths (Stage 0). Before invoking the full retrieval-and-generation pipeline, each turn is screened against two cheap, deterministic triggers evaluated on GPT-4o-mini. A short-conversational-pattern filter (regex matching on tokens such as “thanks”, “ok”, “got it”) routes purely social turns to a brief, friendly response (under 50 words) without touching the retrieval index. Independently, if the Task A pipeline returns zero passages for the current turn, a no-context template returns a short, explicit non-availability statement (under 25 words) rather than routing an empty context into the generation stages. Both fast paths avoid the computational cost of the full five-stage pipeline on turns that cannot benefit from it.

Retry with Urgency Escalation (Stage 2). The evidence span extraction module (Section 5.3) occasionally returns zero spans on its first attempt despite relevant evidence being present in the retrieved

passages. When this occurs, a single retry is issued with an escalated system prompt (an explicit “the answer must exist – find it” instruction) rather than silently falling through to a refusal; this recovers a subset of turns that would otherwise be misclassified as unanswerable purely due to an extraction failure rather than a genuine evidentiary gap.

Force-Answer Fallback. If both dual-candidate drafts (Stage 3) are independently classified as refusals via pattern matching on refusal phrasing, despite the retrieved context being non-empty, the pipeline issues a third generation attempt using a simplified prompt that explicitly prohibits refusal. This fallback specifically targets over-cautious double refusal on turns where usable evidence was in fact extracted, and is distinct from the Multi-Layer Answerability Gate of Section 5.4, which decides after drafting whether the drafted answer is released or replaced by a refusal.

Reproducibility of Stochastic Sampling. The 60% invocation rate of the User Satisfaction Judge (Section 5.3) is implemented as a fixed-seed random draw (seed = 42) rather than a per-run random sample, so that the specific subset of turns receiving the stochastic judge signal is identical across repeated evaluations of the same configuration.

API Access and Fault Tolerance. All models are accessed through hosted API endpoints (Azure OpenAI / Azure AI Foundry) rather than local inference. Transient request failures are handled via exponential backoff retry logic, capped at five attempts with jittered delay, applied uniformly across all pipeline stages.

5.6 Summary of Architectural Design Choices

Table 5.8 consolidates the principal architectural decisions introduced in this chapter, together with the specific failure mode from Chapter 4 that each decision targets and the section of Chapter 6 where its empirical justification is developed.

Design Choice	Failure Mode Addressed	Empirical Validation
Five-strategy query rewriting (Sec. 5.2.1)	Vocabulary gap; coreference and ellipsis (Sec. 4.2.3)	Section 6.2, Table 6.4
Fused (not standalone) cross-encoder reranking (Sec. 5.2.3)	Sparse-retriever ranking noise at top- k	Section 6.2, Table 6.5
Nested RRF, two-level fusion (Sec. 5.2.4)	Exploratory reformulations displacing reliable hits from the top- k	Section 6.2 (not isolated from the other components)
Verbatim evidence span extraction (Stage 2, Sec. 5.3)	Lost-in-the-middle hallucination (Sec. 3.4.1)	Section 6.3, largest single ablation gain
Extractiveness shaping $\phi(r_4)$ (Eq. 5.3.1)	Faithfulness–naturalness trade-off	Section 6.3
Role-based model routing	Operational cost under proprietary-API constraints	Estimated cost 2–2.4× lower than uniform GPT-4o (Table 5.6)
Multi-layer answerability gate (Sec. 5.4)	Acceptance bias on unanswerable turns (Sec. 4.2.2)	Section 6.4, central to RQ3

Table 5.8: Summary of the architectural design choices developed in this chapter, mapped to the failure modes they address and to the sections that report the corresponding evidence.

Chapter 6 now turns to the empirical evaluation of the main design choices, beginning with the retrieval ablations of Section 6.2.

5.7 Complete Prompt Templates

To support reproducibility, this section reproduces the instruction templates of the LLM calls of the final system described in Sections 5.2–5.5. Three omissions should be noted: the few-shot demonstrations attached to the query rewriting prompts are not reproduced for space, the short Stage 1 preliminary answerability prompt (GPT-4o-mini) is described in Section 5.3 but not reproduced, and the prompts of baseline configurations evaluated in Chapter 6 (e.g., single-pass generation, the single-judge gate, the LLM rerankers, and PIR) are not included.

5.7.1 Query Rewriting Prompts

All five rewriting strategies of Section 5.2.1 use DeepSeek-V3.2 at $T=0.0$ and return a binary standalone classification alongside the rewritten query.

5.7.1.1 Minimal Reformulation

System:

Rewrite the final utterance into a single standalone utterance without needing history.

Rules:

- Do not rephrase or introduce new terms.
- Stay close to the original.
- If standalone: return THE SAME query.
- Use assistant turns ONLY to resolve pronouns/references.

```
JSON: {"class": "standalone|non-standalone",
      "rewritten version": "..."}

```

```
{history}

```

```
user: {question}

```

5.7.1.2 Corpus-Specific Reformulation

Four domain variants share the template below; only the preservation targets differ (Table 5.1): ClapNQ preserves entity variants, Wikipedia terminology, and temporal phrasing; FiQA preserves amounts, currencies, tickers, and time horizons; Govt preserves program names, agency acronyms, form IDs, and locations; Cloud preserves error codes, CLI commands/flags, config keys, and service names.

System:

You are rewriting queries for retrieval from [DOMAIN] using ELSER (sparse semantic search).

CRITICAL RULES:

1. ENTITY FORMS: include formal AND common names
(e.g., "Apple Inc. Apple")
2. PRONOUNS: resolve to exact entity
3. TEMPORAL: domain-natural phrasing
4. FORMALIZATION: preserve conversational terms
5. DISAMBIGUATION: qualifier only when ambiguous
6. KEYWORDS: preserve who/what/when/where

If standalone, return UNCHANGED.

```
JSON: {"class": "standalone|non-standalone",
      "rewritten version": "..."}

```

```
{history}
user: {question}
```

5.7.1.3 Chain-of-Thought (CoT) Reformulation

The reasoning field is discarded at inference time; only rewritten version is passed to the retriever.

System:

Expert query rewriter for IR systems.

PROCESS (Chain-of-Thought):

1. ANALYZE: entities, pronouns, ambiguity
2. REASON: standalone? what history needed?
3. REWRITE: resolve, add context, keep wording

```
JSON: {"reasoning": "<step-by-step>",
      "class": "standalone|non-standalone",
      "rewritten version": "<query>"}
```

```
{history}
user: {question}
```

5.7.1.4 Hypothetical Document Embedding (HyDE)

Generates a hypothetical 2-4 sentence answer passage, concatenated with the standalone rewrite; the combined string is submitted to ELSER v1.

System:

Generate hypothetical document passages for retrieval
(HyDE strategy).

TASK: Generate a 2-4 sentence passage that would answer
the query. Used for retrieval only.

```
JSON: {"standalone_query": "<rewrite>",
      "hypothetical_passage": "<2-4 sent>"}
```

Rules:

- Write as a document answering the question
- Include facts, names, dates when relevant
- Use vocabulary from authoritative sources

```
{history}
user: {question}
```

5.7.1.5 Anchor-Keyword Targeting

The final query submitted to ELSER is rewritten_version + anchors + keywords, capped at 28 words.

System:

Rewrite into ONE standalone query for RETRIEVAL.

Extract RETRIEVAL TERMS for ELSER:

- anchors: entity names, acronyms, IDs,
error codes, CLI flags (max 8)
- keywords: intent terms (max 12)

Rules:

- Do NOT invent new entities/facts

- Preserve numbers/codes/tickers exactly
- Query ≤ 28 words

```
JSON: {"class": "standalone|non-standalone",  
      "rewritten version": "...",  
      "anchors": [...],  
      "keywords": [...]}
```

```
{history}  
user: {question}
```

5.7.2 Generation Pipeline Prompts

5.7.2.1 Stage 0: Conversational and No-Context Triage

Triggered when the user turn matches a short conversational pattern (regex pre-filter, Section 5.5), on GPT-4o-mini at $T=0.3$:

System: Friendly assistant.
Brief friendly response to conversational message.

```
History: {history}  
User: {question}  
Response (under 50 words):
```

Triggered when retrieval returns zero passages, on GPT-4o-mini at $T=0.0$:

System: Helpful assistant.
No information available for this question.

```
Question: {question}  
Short response (under 25 words) stating information  
is not available.  
Do NOT say "I don't know" -- say "The information is  
not available" or similar.  
Response:
```

5.7.2.2 Stage 2: Evidence Span Extraction

Extracts up to $K=8$ verbatim sentences from the top-5 retrieved passages, on DeepSeek-V3.2, $T=0.0$. If the first attempt returns fewer than one span, a retry is issued with the urgency prefix described in Section 5.5.

System: Extract relevant sentences.
Extract sentences answering the question.
{urgency_if_retry}

```
History: {history}  
Question: {question}
```

```
PASSAGE 1:  
{passage_1_text}  
...  
PASSAGE N:  
{passage_N_text}
```

Rules:
1. Copy EXACT sentences
2. Include: names, numbers, dates, key facts

3. Max 8 sentences
4. Prioritize earlier passages

JSON format:

```
{"extractedSpans": [{"passageId": 1,
                      "sentence": "exact text"}]}
```

5.7.2.3 Stage 3: Dual-Candidate Generation

Called twice per turn on GPT-4o at $T \in \{0.0, 0.1\}$. The `qtype` and `style_hint` fields are set by the rule-based question-type classifier discussed in Section 5.3.

System: Helpful, accurate assistant.
Generate a natural answer using ONLY the facts below.

FACTS:
{extracted_spans_as_bullet_list}

Conversation context: {history}
Question: {question}
Type: {qtype} -- {style_hint}

CRITICAL RULES:

- Use ONLY information from FACTS above
- Copy exact phrases for: names, numbers, dates, technical terms
- Aim for ~35% verbatim overlap with facts
- Make it sound natural and complete
- NO outside knowledge
- NO hedging (seems, possibly, maybe)
- NO meta-phrases (based on, according to)

Length: ~{target_words} words
Answer:

The explicit instruction to aim for ~ 35% verbatim overlap was added after observing that unconstrained generation tends to over-paraphrase evidence, pushing extractiveness below the ideal band of Equation 5.3.1 and degrading faithfulness.

5.7.2.4 Stage 4: Judge Modules

Technical Judge (DeepSeek-V3.2, $T=0.0$); evidence spans truncated to 120 characters each to fit the token budget:

System: Judge assistant.
Compare two answers for quality.

Question: {question}
Facts: {truncated_spans}

A: {answer_A} ({wc_A}w, {extr_A}% extractiveness)
B: {answer_B} ({wc_B}w, {extr_B}% extractiveness)

Evaluate: Faithfulness, Completeness, Naturalness
Ideal extractiveness: 28-45%

JSON: {"winner": "A|B", "score_A": 0-10,

```
"score_B": 0-10, "reason": "brief"}
```

User Satisfaction Judge (GPT-4o-mini, $T=0.0$, 60% sampled with fixed seed, Section 5.5):

System: User perspective.

As a user, which answer do you prefer?

Context: {recent_history}

Question: {question}

A: {answer_A}

B: {answer_B}

```
JSON: {"preferred": "A|B", "confidence": "HIGH|MEDIUM|LOW"}
```

Force-Answer Fallback (GPT-4o-mini, $T=0.2$, Section 5.5):

System: Always answers when facts exist.

Answer using ONLY these facts. Do NOT say you cannot answer.

Facts:

```
{extracted_spans_as_bullet_list}
```

Question: {question}

Direct answer using the facts:

5.7.2.5 Stage 5: Micro-Adjustment

Applied only when the selected answer violates a length or extractiveness constraint (GPT-4o-mini, $T=0.1$); reason is populated dynamically based on the detected violation:

System: Editor.

Fix this answer: {reason}

Facts: {truncated_spans}

Current: {answer}

Fix with minimal changes. Use exact phrases from facts.

Fixed:

5.7.3 Task C Answerability Judge Prompt

All three judges of the Multi-Layer Answerability Gate (Document, Span, Answer, Section 5.4) and the confidence-weighted voting arbiter are instantiated on GPT-4o at $T=0.0$:

Given the user question and retrieved passages, classify the answerability:

- ANSWERABLE: Passages contain sufficient information to fully answer.
- PARTIAL: Passages contain some relevant information but incomplete.
- UNANSWERABLE: No relevant information in passages.

```
Output: {"class": str, "confidence": float}
```

Each judge applies this template to its own input—the top-3 retrieved passages, the extracted spans $\mathcal{S}_t$, or the drafted answer (Section 5.4). If any judge returns UNANSWERABLE with confidence $\geq \tau=0.7$, the drafted answer is replaced by a templated refusal capped at 25 words; PARTIAL counts as answerable, so such turns proceed to selection and micro-adjustment.

Chapter 6

Experimental Evaluation and Discussion

This chapter presents the comprehensive empirical evaluation of the AILS-NTUA framework on the multi-turn conversational MTRAGEval benchmark (SemEval-2026 Task 8). We recap the model configuration and evaluation protocol (Section 6.1), quantify the individual contributions of retrieval and generation pipeline components through systematic ablation (Sections 6.2–6.3), analyze the end-to-end bottleneck, in which answerability calibration is the decisive factor under the test distribution (Section 6.4), and report the official, frozen leaderboard results (Section 6.5).

6.1 Experimental Setup and Baseline Benchmarking

All architectural hyperparameter tuning and incremental component evaluations were conducted exclusively on the official MTRAG development set, comprising 110 human-authored conversations across 842 dialogue turns. Final evaluation was performed on the held-out evaluation test set, containing 507 turns embedded within 507 conversations—as established in Section 4.3, every test-set record consists of a *single* evaluated turn drawn from a historical trace, and almost all of these turns (465 of 507, 91.7%) are non-first turns that require contextual understanding, so the “easy” first-turn queries that inflate development-set averages are rare.

6.1.1 Model Configuration Overview

Before turning to the ablation results, we briefly recap the model assignment established under the capability-aligned routing principle of Section 5.3 (Table 5.6): DeepSeek-V3.2 handles all five query rewriting strategies (Section 5.2.1) as well as span extraction and technical judging, GPT-4o is used for dual-candidate answer generation (Section 5.3) and for the three Task C answerability judges (Section 5.4), and GPT-4o-mini covers the remaining lightweight, high-frequency stages (conversational triage, unanswerable-turn detection, user-satisfaction judging, and micro-adjustment). No component of the pipeline was fine-tuned on MTRAG data; all reported gains stem from prompt engineering and architectural design choices, evaluated exclusively on the development set unless otherwise noted.

6.1.2 Hyperparameter Configuration

Table 6.1 consolidates the core hyperparameter values referenced throughout this chapter, all tuned exclusively on the development set and held fixed for the frozen test-set submission.

6.2 Task A Retrieval Ablations and the Ensemble Paradox

6.2.1 Retriever Family Comparison

Prior to any query rewriting, we benchmarked nine retrievers spanning lexical, dense, and learned sparse families on the full 777-query development set. Table 6.2 reports the outcome: ELSER v1 substantially

Parameter	Value
First-stage retrieval depth per reformulation (N)	100
Cross-encoder reranking depth (k)	60
Hybrid fusion weight (α , Eq. (5.2.1))	0.5
Nested RRF internal smoothing (k_{internal})	40
Task A retrieved passages	10
Task C retrieved passages	3
Extractiveness ideal band (r_4)	[0.28, 0.38]
Answerability confidence threshold (τ)	0.7
Dissenter override threshold (θ)	0.7
User Satisfaction Judge invocation rate	60%

Table 6.1: Core system hyperparameters, tuned on the development set and frozen for test-set evaluation. Section 6.4 discusses how this dev-only calibration may contribute to the Task C performance gap.

outperforms every alternative, exceeding the strongest dense competitor (Cohere Embed v4) by +8.6 Recall@5 points and BM25 by +33.0 points on the same 777 queries. This comparison must be read in light of how MTRAG was constructed: benchmark annotators primarily reviewed ELSER-retrieved passages when producing relevance judgments, so passages surfaced only by other retrievers are more likely to be unjudged and are scored as non-relevant. Part of ELSER’s advantage may therefore reflect this pooling bias. We did not run a judged-only analysis that would quantify its size (see Section 6.2.4).

Type	Retriever	R@5	nDCG@5
Lexical	BM25	0.153	0.130
Dense	Cohere Embed v4	0.397	0.362
	AWS Titan v1	0.352	0.328
	Voyage-3.5-L	0.321	0.302
	GTE-Large	0.326	0.293
	BGE-Large-v1.5	0.282	0.251
Sparse	ELSER v1	0.483	0.444
	ELSER v2	0.411	0.380
	SPLADE v3	0.402	0.374

Table 6.2: Retriever comparison, 777 development-set queries, no query rewriting. ELSER v1 exceeds Cohere Embed v4 by +8.6 R@5 points; see the text for the pooling-bias caveat.

A natural objection to Table 6.2 is that ELSER’s advantage could be an artifact of the downstream pipeline having been co-optimized around it, rather than an intrinsic retrieval quality difference. To rule this out, we additionally optimized each retriever *independently*—applying the same multi-strategy rewriting and reranking components of Sections 5.2.1–5.2.3 to each candidate retriever in turn—and compared the resulting recall at multiple cutoffs (Table 6.3). ELSER retains the best Recall@5/Recall@10 even after this independent optimization, indicating that its advantage is not an artifact of score-scale compatibility with the downstream fusion pipeline (the pooling-bias caveat of Section 6.2.4 still applies).

Retriever	R@5	R@10	R@50	R@100
ELSER v1	0.607	0.729	0.873	0.901
SPLADE	0.539	0.657	0.836	0.874
Cohere	0.503	0.657	0.823	0.854
BM25	0.444	0.536	0.688	0.735

Table 6.3: Per-retriever recall after each retriever is independently optimized with the full rewriting and reranking pipeline. ELSER dominates at R@5/R@10 even under this controlled comparison.

6.2.2 Incremental Value of Query Rewriting Strategies

Table 6.4 documents the incremental performance improvement achieved by sequentially adding the five query rewriting strategies of Section 5.2.1 into the single-retriever index pool. Cumulative integration of all five strategies combined with Nested RRF yields Recall@5= 0.607, a +25.7% relative improvement over the unaugmented baseline, in line with Hypothesis H1. Two caveats apply to the reading of this table. First, its rows are cumulative, so each increment is conditional on the strategies already added and on the order in which they were added; a leave-one-out ablation was not performed. Second, the table does not isolate individual components of the retrieval configuration: it does not indicate where cross-encoder reranking enters the chain (its effect is reported separately in Table 6.5), and a direct comparison between Nested RRF and a flat RRF over the same five inputs was not retained. The +25.7% figure should therefore be attributed to the complete retrieval configuration rather than to any single component.

Retrieval Configuration	Recall@5	Relative Improvement
Unaugmented Baseline (Original Query)	0.483	—
+ Minimal Rewrite	0.527	+9.1%
+ Corpus-Specific Expansion	0.558	+15.5%
+ Chain-of-Thought (CoT) Analysis	0.573	+18.6%
+ Hypothetical Document Embedding (HyDE)	0.584	+20.9%
+ Anchor Keyword Targeting	0.591	+22.4%
+ Nested RRF Fusion (Hierarchical Tree)	0.607	+25.7%

Table 6.4: Incremental ablation of query rewriting strategies on the development set. Rows are cumulative. The largest single increment comes from Minimal rewriting (+0.044 R@5), followed by Corpus-Specific expansion (+0.031).

Per-strategy analysis further reveals that no single reformulation dominates uniformly across domains: Corpus-Specific achieves the best single-strategy performance in ClapNQ ($R@5=0.637$) and FiQA ($R@5=0.491$), Chain-of-Thought leads in Govt ($R@5=0.580$), and Minimal is strongest in the technical Cloud domain ($R@5=0.463$). HyDE, notably, is the *weakest* single strategy across all four domains, yet its inclusion in the full Nested RRF ensemble is not redundant: the complete five-strategy fusion ($R@5=0.607$) exceeds even the best individual strategy by 6.6 points. Because the complete configuration also includes reranking (Table 6.5), part of this difference may be due to the reranker; the comparison is therefore consistent with, but does not isolate, the *complementarity* of the strategies.

6.2.3 The Role of Reranking: Complementary, Not Substitutive

Table 6.5 isolates the specific contribution of cross-encoder reranking (Section 5.2.3). Using a cross-encoder *as the sole ranking mechanism*—bypassing the sparse retriever entirely—lowers Recall@5 by 4.6–10.6 points (8.7–20.0% relative) compared with the ELSER baseline, despite the strong standalone benchmark performance of these same reranker models on static IR collections. Only the weighted RRF fusion of retriever and reranker signals (Equation (5.2.1)) yields an improvement (+0.067 R@5, +12.7% relative)—an increment of the same order as the gains attributed to the additional rewriting strategies in Table 6.4—confirming that reranking functions as a complementary refinement filter over an already-relevant candidate pool rather than an independent source of retrieval quality.

Configuration	Recall@5	Δ vs. baseline
ELSER v1 (baseline, with Minimal rewrite)	0.527	—
Cohere Rerank v4 (sole ranking signal)	0.481	−8.7%
Voyage-Reranker-2.5 (sole ranking signal)	0.469	−11.0%
Cross-Encoder MS-MARCO (sole ranking signal)	0.421	−20.0%
ELSER + Cohere, weighted RRF fusion	0.594	+12.7%

Table 6.5: Standalone reranking degrades performance; weighted RRF fusion with the sparse retriever yields complementary gains.

We additionally investigated LLM-based reranking as a potential substitute for the fixed cross-encoder (Hypothesis H4). Three formulations—pointwise scoring, listwise reordering in the style of RankGPT [37], and generation-based ranking, all operating on the same top-20 candidate pool—were evaluated against the weighted RRF baseline of $R@10=0.725$. None improved upon this baseline when used as a substitute ranking signal: pointwise LLM scoring achieved $R@10=0.701$, listwise reordering 0.688, and generation-based ranking 0.618, at a substantially higher API cost than the weighted RRF fusion. Interpolating the LLM scores into the final ranking with a small fixed weight ($w \in [0.2, 0.45]$) instead yields only marginal gains (at most +2 percentage points in Recall@5 per domain). This result supports H4: once first-stage recall approaches saturation ($R@100 > 0.90$), general-purpose LLM judges lack the fine-grained discriminative sensitivity to replace a well-calibrated, purpose-built reranker, and the marginal benefit they provide as an auxiliary signal does not justify their added computational cost.

6.2.4 Deconstructing the Retriever Ensemble Paradox

A central finding of this thesis is that, under the official relevance judgments, heterogeneous multi-retriever ensembling does not help as a stabilization strategy once the single-retriever pipeline is optimized. Table 6.6 tracks this paradox across three stages of pipeline maturity: as the ELSER-only configuration improves through query rewriting (from $R@5=0.497$ with no rewriting¹ to $R@5=0.607$ with the full five-strategy ensemble), the *marginal* benefit of adding alternative retrievers not only shrinks but reverses sign. At the early, unrewritten stage, adding all alternative retrievers improves $R@5$ from 0.497 to 0.568; at the fully optimized stage, the same addition *degrades* $R@5$ from 0.607 to 0.569 on the same 777 queries, even though $R@100$ continues to improve monotonically at every stage.

Configuration	R@5	R@100	Unique golds / avg. rank
<i>Early Stage — No Rewriting</i>			
ELSER v1 alone	0.497	0.779	—
+ All alternative retrievers	0.568 ↑	0.920 ↑	803 / 22.5
<i>Final Stage — Optimized 5-Rewrite Ensemble</i>			
ELSER v1 alone	0.607	0.901	—
+ All alternative retrievers	0.569 ↓	0.926 ↑	141 / 39.5

Table 6.6: The ensemble paradox: as the single-retriever pipeline matures through query rewriting, the marginal value of retriever ensembling reverses from positive to negative at $R@5$, even as it remains positive at $R@100$. Unique gold documents contributed by alternative retrievers settle at an average rank of 39.5 after fusion (between 27.5 and 54.2 depending on the retriever)—below the top-10 cutoff used for Task A scoring.

A plausible mechanism for this reversal is the following: as the single-retriever configuration becomes increasingly precise at top- k , the unique gold documents that alternative retrievers contribute are, by construction, documents that ELSER did *not* rank highly—and these settle at average ranks between 27.5 (BM25) and 54.2 (SPLADE) after fusion (39.5 for the full ensemble), well below the top-10 cutoff that determines Task A scoring. Meanwhile, the act of fusing in a second, differently-calibrated ranking signal introduces noise that displaces borderline-relevant ELSER hits out of the top-5. This finding directly informs the architectural principle of Section 5.1: retrieval stability is better served by *diversifying the query* against a single, well-aligned index than by *diversifying the index* against a single query.

Threat to validity: pooling bias. The ensemble paradox is measured against MTRAG’s official relevance labels, which were produced by annotators who primarily reviewed ELSER-retrieved passages. Passages that only the alternative retrievers surface are therefore more likely to be unjudged and are counted as non-relevant, which penalizes any fusion that promotes them into the top-5. This pooling bias can contribute to the observed drop independently of the noise mechanism described above, and it may also contribute to ELSER v1’s lead in Table 6.2. Separating the two effects would require a judged-only evaluation (e.g.,

¹This early-stage run yields $R@5=0.497$ for ELSER v1 without rewriting, slightly above the 0.483 of Table 6.2. The two values come from separate experimental runs whose configurations we could not fully reconcile; the difference (0.014) does not affect the sign reversal reported here.

condensed result lists or bpref) or a manual relevance check of the unjudged passages that enter the top-5. We did not perform either, so the ensemble paradox should be read as holding under the benchmark’s official judgments.

6.2.5 Passage-Informed Rewriting: A Negative Result

A related question is whether the rewriter itself could be improved by making it *retrieval-aware*: rather than reformulating the query in isolation, a second-stage rewrite could condition on the passages returned by an initial retrieval pass, closing the loop between retrieval signal and query adaptation. We term this approach Passage-Informed Rewriting (PIR) and evaluate it against classical Pseudo-Relevance Feedback (PRF), which performs the analogous adaptation using term co-occurrence statistics rather than LLM semantic understanding.

Table 6.7 reports the outcome. Classical PRF collapses ($R@5$ as low as 0.182), indicating that term-extraction statistics induce strong query drift once applied to conversational, non-standalone queries. PIR fares substantially better and tracks the quality of its initial retrieval signal almost linearly—when seeded with a minimal rewrite and cross-encoder reranking, PIR reaches $R@5=0.541$, matching our best single-strategy baseline (Corpus-Specific, Table 6.4). However, PIR *never exceeds* the baseline it is seeded from, regardless of variant.

Category	Method	R@5	nDCG@5
Baseline	Minimal rewrite only	0.527	0.487
	Minimal rewrite + rerank	0.594	0.508
Classical PRF	BM25 TF-IDF feedback	0.182	0.155
	ELSER TF-IDF feedback	0.410	0.387
PIR (initial-quality dependent)	+ original query seed	0.504	0.472
	+ minimal rewrite seed	0.520	0.485
	+ minimal rewrite + rerank seed	0.541	0.503

Table 6.7: Classical PRF vs. Passage-Informed Rewriting (PIR), development set. PRF collapses due to query drift; PIR tracks but never exceeds the quality of its seed signal, indicating that its achievable gain is bounded by the coverage already present after the first retrieval stage.

We attribute this ceiling to a diminishing-returns effect tied structurally to our retrieval setup: once first-stage $R@100$ approaches saturation (> 0.90 , Table 6.3), the gold passages are already present in the candidate pool, and the bottleneck shifts entirely from *coverage* to *top-k ranking precision*. PIR is designed to solve a coverage problem, but broadening an already near-complete candidate pool introduces fusion noise rather than new signal—the same mechanism identified in the retriever ensemble paradox above. We therefore exclude PIR from the final system, while noting that it may prove effective in lower-recall settings where first-stage coverage, rather than ranking precision, is the genuine bottleneck. This negative result reinforces, from a second and independent angle, the central architectural lesson of this section: once a single retriever is well-optimized, additional retrieval-side sophistication is better spent on query diversity than on feedback loops around the same retriever.

6.2.6 Turn-Depth Stability

As anticipated from the corpus analysis of Section 4.3, retrieval quality depends strongly on dialogue position. The *Overall* panel of Figure 6.2.1 plots Recall@5 by turn index for the unaugmented ELSER baseline and for the full system. Without rewriting, Recall@5 falls from 0.879 at Turn 1 to 0.428 at Turns 6+ (51% relative); with five-strategy rewriting and Nested RRF it falls from 0.890 to 0.540 (39%). The decline is not gradual: most of it occurs between Turn 1, which is standalone by construction, and Turn 2, after which both curves stay roughly flat. Query rewriting therefore narrows, but does not close, the gap between the first and later turns; Section 6.2.8 shows that this gap is explained largely by whether a query is standalone.




Figure 6.2.1: Recall@5 by turn index, unaugmented ELSER baseline (dashed) vs. final system (solid), overall and per domain (shaded bands: ± 1 standard error across conversations). Overall: Turn 1 0.879 and Turns 6+ 0.428 for the baseline; Turn 1 0.890 and Turns 6+ 0.540 for the final system.

6.2.7 Rewriting Model Selection

The final system uses DeepSeek-V3.2 as the backbone for all five rewriting strategies (Section 5.2.1). This choice was validated against GPT-4o-mini and GPT-4o across three representative strategies spanning the instruction-following-to-open-ended spectrum: Minimal and Corpus-Specific (structured, schema-constrained outputs) and HyDE (open-ended hypothetical-passage generation). Table 6.8 reports Recall@5, nDCG@5, and per-query cost for each combination.

The pattern is not uniform across reformulation types. For strategies requiring strict instruction following and structured JSON output — Minimal and Corpus-Specific — DeepSeek-V3.2 performs within 0.001–0.014 R@5 of GPT-4o, indicating that instruction-following capability, not raw generative fluency, is the binding constraint for these tasks. GPT-4o’s marginal advantage concentrates on HyDE, where the task shifts from schema-constrained rewriting to open-ended hypothetical-passage generation — a regime favoring stronger generative fluency. This gain (+0.019 R@5) is small in absolute terms and arrives at a 15 $\times$ cost premium; since HyDE is only one of five strategies feeding into Nested RRF and is down-weighted at fusion (Table 5.4), the quality delta does not justify the added expense. Notably, GPT-4o with Minimal rewriting matches DeepSeek-V3.2 with Corpus-Specific (both R@5 = 0.541), suggesting model capability can partially substitute for prompt specialization. We therefore retain DeepSeek-V3.2 across all five strategies in the final system, consistent with the cost-efficiency principle underlying the model-routing design of Section 5.3.

Strategy	Model	R@5	nDCG@5	Cost/query
Minimal	DeepSeek-V3.2 (ours)	0.527	0.487	\$0.001
	GPT-4o-mini	0.513	0.481	\$0.003
	GPT-4o	0.541	0.501	\$0.015
HyDE	DeepSeek-V3.2 (ours)	0.485	0.445	\$0.001
	GPT-4o-mini	0.503	0.462	\$0.003
	GPT-4o	0.504	0.464	\$0.015
Corpus-Specific	DeepSeek-V3.2 (ours)	0.541	0.498	\$0.002
	GPT-4o-mini	0.517	0.479	\$0.005
	GPT-4o	0.542	0.503	\$0.020

Table 6.8: Rewriting model comparison across strategy types (development set). GPT-4o’s advantage is concentrated on the open-ended HyDE strategy, at a $15\times$ cost premium; on schema-constrained strategies (Minimal, Corpus-Specific) DeepSeek-V3.2 is within 0.014 R@5 of GPT-4o (no significance test was performed).

6.2.8 Standalone vs. Non-Standalone Query Performance

To isolate the mechanism behind the turn-depth degradation of Section 6.2.6, we decompose Recall@5 by query type: *standalone* queries (self-contained, no coreference resolution needed) versus *non-standalone* queries (dependent on prior turns). Table 6.9 reports the unaugmented ELSER baseline against the final system, both overall and per domain.

Domain	ELSER (no rewrite)		Final system	
	SA	Non-SA	SA	Non-SA
Overall	0.879	0.440	0.890	0.564
ClapNQ	0.929	0.477	0.946	0.651
FiQA	0.861	0.363	0.854	0.493
Govt	0.847	0.470	0.894	0.600
Cloud	0.873	0.440	0.857	0.499

Table 6.9: Recall@5 for standalone (SA) vs. non-standalone (Non-SA) queries, baseline vs. final system. Rewriting improves Non-SA queries by +12.4 pp overall vs. only +1.1 pp for SA queries.

The unaugmented baseline already achieves near-ceiling performance on standalone queries ($R@5 = 0.879$), leaving little room for improvement — the +0.011 overall SA gain confirms that query rewriting is not merely a generic retrieval booster, but a targeted fix for a specific failure mode. The 43.9-percentage-point standalone/non-standalone gap in the unaugmented baseline directly localizes the source of the drop after Turn 1 seen in Figure 6.2.1: Turn 1 queries are standalone, while most later queries depend on earlier turns (Section 4.2), so the turn-position effect is largely a standalone-versus-non-standalone effect rather than a gradual decay with depth. This finding supports Hypothesis H1 (Section 4.4): the value of query rewriting lies in resolving conversational dependency, not in improving retrieval quality uniformly. Rewriting slightly lowers standalone performance in FiQA ($0.861 \rightarrow 0.854$) and Cloud ($0.873 \rightarrow 0.857$): unlike the Minimal and Corpus-Specific prompts, which return standalone queries unchanged, the exploratory strategies (HyDE, CoT, Anchor-Keyword) also reformulate standalone queries, and the added terms can displace relevant passages. This cost is small compared with the non-standalone gains.

6.2.8.1 Per-Domain Turn-Depth Degradation

The per-domain panels of Figure 6.2.1 (Section 6.2.6) break the aggregate turn-depth analysis down by domain, revealing that the $51\% \rightarrow 39\%$ relative degradation reduction reported for the overall corpus masks substantial domain heterogeneity. Cloud and FiQA, the two domains with the highest lexical mismatch between conversational and document language (Section 4.2), retain the steepest late-turn drop even after




Figure 6.2.2: SA vs. Non-SA Recall@5 per domain for the ELSER baseline and the final system (values from Table 6.9). Within each group the bars are, from left to right: ELSER SA (dark blue), ELSER Non-SA (light blue), final SA (dark orange), final Non-SA (light orange). The rewriting gain is concentrated on non-standalone queries; standalone performance is nearly unchanged.

rewriting, while ClapNQ’s encyclopedic phrasing is comparatively robust to dialogue depth.

The per-domain curves confirm the pattern anticipated from the corpus characterization of Section 4.2. ClapNQ, whose encyclopedic Wikipedia phrasing keeps lexical overlap with the underlying documents high even under coreference, shows the largest rewriting gain at later turns, and Table 6.9 shows the largest non-standalone gain of the four domains ($0.477 \rightarrow 0.651$, +17.4 points). Cloud exhibits the noisiest trajectory of the four domains, with the final system’s curve crossing below the unaugmented baseline around turn 4 before recovering; this instability is consistent with Cloud’s technical, identifier-heavy vocabulary (error codes, CLI flags, configuration keys), where a rewriting error can introduce a plausible-looking but incorrect identifier rather than simply failing to resolve a pronoun. Govt falls between these two extremes; like Cloud, FiQA retains a visible late-turn gap relative to its own turn-1 performance even after rewriting, which is consistent with FiQA being identified throughout this chapter (Section 6.2) as the structurally hardest domain for retrieval regardless of turn depth. Overall, the per-domain breakdown does not contradict the aggregate finding of Section 6.2.6, but it refines it: the 51%→39% relative-degradation reduction is not evenly distributed, and the residual late-turn gap that rewriting fails to close is concentrated in the two domains with the largest vocabulary mismatch between conversational and document language (Cloud and FiQA), rather than being a uniform property of dialogue depth itself.

6.3 Task B Generation Ablations and Component Contribution

6.3.1 Pipeline Component Ablation

Table 6.10 decomposes the contribution of each stage of the Section 5.3 generation pipeline. The complete five-stage pipeline yields +8.9 Harmonic Mean points over single-pass greedy generation ($0.654 \rightarrow 0.743$), with evidence span extraction (Stage 2) contributing the single largest individual gain.

Evidence span extraction alone accounts for +0.034 HM, together with a +0.041 gain in the reference-less faithfulness metric RL_F , consistent with the faithfulness part of Hypothesis H2: constraining the generator’s effective input to a compressed set of verbatim spans structurally bounds the space in which unsupported claims can be introduced.

Pipeline Configuration	Harmonic Mean (HM)
Single Greedy Generation Baseline ($T=0.0$)	0.654
+ Verbatim Evidence Span Extraction	0.688
+ Dual-Candidate Drafting (Random Selection)	0.706
+ Technical Judge Verification	0.725
+ User Satisfaction Judge (60% stochastic sample)	0.738
+ Post-Processing Micro-Adjustments	0.743

Table 6.10: Task B generation pipeline component contribution ablation, development set.

6.3.2 Extractiveness Band Calibration

The extractiveness shaping function $\phi(r_4)$ of Equation (5.3.1) depends on a target band, set to $[0.28, 0.38]$ based on the empirical 4-gram overlap of development-set reference answers (36.2% mean overlap). Table 6.11 validates this choice against alternative bands: both tighter and looser bands score lower in HM than the selected configuration. The differences are small, so $[0.28, 0.38]$ is best read as the best of the bands tested rather than as a sharply defined optimum.

Ideal Band	HM	Δ vs. ours
No shaping (uniform $\phi=0$)	0.724	-0.019
$[0.20, 0.50]$ (loose)	0.731	-0.012
$[0.25, 0.45]$	0.738	-0.005
$[0.28, 0.38]$ (ours)	0.743	—
$[0.30, 0.40]$ (tight)	0.737	-0.006
$[0.35, 0.50]$ (high)	0.733	-0.010

Table 6.11: Extractiveness band sensitivity, development set. Deviation from $[0.28, 0.38]$ in either direction degrades HM.

6.3.3 Model Routing

The role-based routing of Section 5.3 is a cost-motivated design decision rather than an experimentally optimized one. At nominal API pricing, the routed Task B pipeline costs an estimated \$0.010–0.012 per turn, of which the two GPT-4o generation calls account for \$0.009 (Table 5.6); this is roughly 2–2.4 $\times$ less than the estimated \$0.024 for assigning GPT-4o to every stage. We did not retain a controlled comparison against uniform single-model configurations, and therefore make no claim about the effect of routing on output quality. The choice of DeepSeek-V3.2 for query rewriting is supported separately by the comparison of Section 6.2.7.

6.3.4 Fixed Pipeline Settings

Two further settings of the Task B pipeline were fixed by design rather than selected through a retained, systematic sweep: span extraction operates on at most five passages, and the User Satisfaction Judge is invoked on a random 60% of turns as a compromise between judge coverage and API cost. We report them for reproducibility, without claiming that they are optimal.

6.4 Task C: Answerability Calibration as the Decisive Factor

The end-to-end evaluation of Task C shows a sharp drop relative to reference-grounded generation, with the global Harmonic Mean falling from 0.7698 (Task B) to 0.5409 on the test set. Consistent with our system paper [5], we view answerability calibration as the decisive factor under the test distribution: the gate accepts most unanswerable turns even on the development set (Section 6.4.1), and it was calibrated at an unanswerable rate of 6.5% but faces 19.1% at test time. Retrieval nonetheless remains a substantial factor. Task C conditions generation on only the top-3 passages (Section 5.4), so top-rank precision ($R@5=0.607$ on

the development set, Table 6.6), rather than deep recall ($R@100=0.901$), determines whether the evidence reaches the generator; and top- k retrieval errors account for most of the development-set failures inspected in Section 6.4.2, a split in which unanswerable turns are rare. A breakdown of the official test scores by answerability category would quantify the two contributions.

6.4.1 The Precision–Recall Trade-off in Answerability Detection

Across all gate configurations we evaluated, we observe a consistent trade-off: any attempt to increase the recall of UNANSWERABLE turns systematically decreases the recall of ANSWERABLE turns. Table 6.12 shows that no evaluated configuration exceeds 25% Unanswerable F1 on the full development set. Our full multi-judge system achieves 95.8% recall on answerable turns but only 21.8% recall on genuinely unanswerable turns—revealing a strong, systematic acceptance bias. Raw classification accuracy is deliberately not reported: with only 6.5% unanswerable turns, a trivial always-answer policy would already exceed 93% accuracy, making the metric uninformative for this decision. With only 55 unanswerable turns in the development set, all of these estimates are coarse: the multi-judge recall of 21.8% corresponds to 12 turns (95% Wilson interval 12.9–34.4%), the intervals of the two gated configurations overlap, and their difference in Unanswerable F1 (24.0% vs. 23.1%) amounts to a few turns.

Configuration	Ans. Recall	Unans. Recall [95% CI]	Unans. Precision	Unans. F1
Always Answer Baseline	100.0% (777/777)	0.0% (0/55)	—	0.0%
Pipeline + Verification Rule	92.3% (717/777)	27.3% (15/55) [17.3, 40.2]	20.0% (15/75)	23.1%
Multi-Judge Voting Gate (Ours)	95.8% (744/777)	21.8% (12/55) [12.9, 34.4]	26.7% (12/45)	24.0%

Table 6.12: Answerability detection on the development set ($N=832$ turns: 777 answerable or partially answerable and 55 unanswerable; the 10 conversational turns are excluded). Intervals are 95% Wilson score intervals. No gate configuration we evaluated exceeds 25% Unanswerable F1 on the full development set.

The multi-judge gate improves end-to-end HM over a single-judge gate (Table 6.15) but does not remove this acceptance bias. Inspection of the gate’s decisions suggests why: the document- and span-level judges often flag insufficient evidence, but the answer-level judge tends to accept drafted answers that remain plausible on their face, favoring fluency over evidentiary sufficiency. Removing the answer-level judge raised Unanswerable recall but lowered Answerable recall by rejecting partially supported, correct responses. These observations are qualitative; per-judge accuracies were not recorded, so we do not quantify the contribution of each judge.

6.4.2 Error Analysis: Retrieval and Cross-Turn Dependency

To characterize Task C failures, the author manually inspected 50 failure cases from the development set and assigned each to one primary root cause (Table 6.13). The cases were not drawn by a documented random procedure and were labeled by a single annotator, so the percentages are indicative rather than precise estimates.

Root Cause	% of Failures	Primary Domain
Retrieval error (current-turn content)	38%	FiQA
Retrieval error (unresolved dependency on earlier turns)	34%	Cloud
Answerability misclassification	18%	All
Generation error (correct passages)	10%	ClapNQ

Table 6.13: Primary root cause in 50 manually inspected Task C failures (development set, single annotator). Retrieval-related causes account for 72% of the inspected failures.

Retrieval-related causes together account for 72% of the inspected failures, and answerability misclassification for 18%. The second retrieval category (34%) requires a precise reading. Because MTRAGEval supplies the *reference* conversation history rather than the system’s own earlier outputs, an error made by our system at turn $t-1$ cannot propagate into H_t ; the error cascade discussed in Section 3.3.2 is therefore not exercised by this evaluation. The 34% category instead covers turns whose query depends on earlier turns and whose

dependency the rewriting stage failed to resolve, so that retrieval at turn t fails even though the history itself is correct. These cases point to coreference and ellipsis resolution as a major remaining retrieval weakness, consistent with the standalone/non-standalone gap of Section 6.2.8.

6.4.3 Threshold Sensitivity and the Task C Ablation

Table 6.14 sweeps the answerability confidence threshold τ (Section 5.4) in $[0.5, 0.9]$, confirming that $\tau=0.7$ maximizes development-set HM by balancing Answerable recall against Unanswerable F1. This threshold was calibrated on a development set with only 6.5% unanswerable turns, whereas the test set contains 19.1%. It is therefore plausibly miscalibrated for test conditions (Section 6.5); since we submitted a single frozen configuration, we cannot verify which threshold would have performed best on the test set.

Threshold	HM	Answerable Recall	Unanswerable F1
0.50	0.573	0.892	0.261
0.60	0.591	0.923	0.251
0.70 (ours)	0.610	0.958	0.240
0.80	0.597	0.971	0.198
0.90	0.578	0.986	0.162

Table 6.14: Answerability confidence threshold sweep, development set. $\tau=0.70$ maximizes HM, but is calibrated against a development-set unanswerable rate roughly one-third of the test-set rate.

Finally, Table 6.15 isolates the architectural decisions specific to the Task C pipeline (Section 5.4). Adding an answerability gate yields the largest gain (+0.043 HM over always answering), replacing the single judge with the multi-judge gate adds +0.025, and reducing the retrieved passages from 5 to 3 adds a further +0.024, suggesting that in this self-retrieved setting additional, marginally relevant passages hurt more than they help.

Configuration	HM	RL_F	RB_{alg}
Always answer (no gate)	0.518	0.798	0.312
Single-judge gate, top-5 passages	0.561	0.821	0.356
Multi-judge gate, top-5 passages	0.586	0.836	0.383
Multi-judge gate, top-3 (ours)	0.610	0.848	0.408
Multi-judge gate, top-1	0.591	0.841	0.389

Table 6.15: Task C ablation, development set. Rows change one setting at a time. The largest increment comes from adding a gate (+0.043 HM); the single-to-multi-judge and top-5-to-top-3 changes contribute +0.025 and +0.024. Top-1 underperforms top-3.

6.5 Official Competition Leaderboard Results

The official, frozen leaderboard rankings for SemEval-2026 Task 8 support the design principles of Chapter 5 for retrieval and reference-grounded generation, while Task C remains the weakest result. Table 6.16 reports the complete official test-set results.

Task	Metric	Ours	Rank	Top Baseline (Score)
A — Retrieval	nDCG@5	0.5776	1/38	ELSER + GPT-OSS-20b rewrite (0.4795)
B — Generation	HM	0.7698	2/26	GPT-OSS-120b (0.6390)
C — RAG	HM	0.5409	11/29	Qwen-30B-A3B-Thinking (0.5366)

Table 6.16: Official test set results. “Top Baseline” refers to the strongest non-participant system released by the organizers.

- **Task A (Retrieval Only):** the system ranks **1st out of 38** submissions with $nDCG@5=0.5776$, a +20.5% relative improvement over the strongest released baseline, consistent with Hypothesis H1.
- **Task B (Reference-Grounded Generation):** the system ranks **2nd out of 26** submissions with $HM=0.7698$ ($RB_{alg}=0.6327$, $RL_F=0.8971$, $RB_{llm}=0.8321$ on the individual components), narrowly behind the top-ranked system (0.7827), with particularly strong reference-less faithfulness and LLM-judged quality.
- **Task C (End-to-End RAG):** the system ranks **11th out of 29** submissions with $HM=0.5409$, only marginally above the strongest organizer baseline (0.5366, +0.004). The Task B→C gap ($0.7698 \rightarrow 0.5409$) comes mostly from the drop in RB_{alg} ($0.6327 \rightarrow 0.3998$). This drop is consistent with the answerability-calibration analysis of Section 6.4: the test set’s near-tripled unanswerable rate (19.1% vs. 6.5% at development time) leaves the development-calibrated threshold $\tau=0.7$ poorly matched to test conditions. Top-rank retrieval errors contribute as well, since only three retrieved passages reach the generator.

Because each subtask was evaluated with a single frozen configuration, the test set cannot confirm the individual component effects measured on the development set; it reports the performance of the complete systems only.

6.6 Synthesis: Answering the Research Questions

We close this chapter by mapping each research question of Section 4.4 to the evidence reported above (Table 6.17); the answers themselves are stated in Section 7.2.

RQ	Evidence	Main caveat
RQ1	Tables 6.4, 6.5, 6.6; Sections 6.2.6 and 6.2.8	Pooling bias of the relevance labels (Section 6.2.4); cumulative ablation
RQ2	Tables 6.10 and 6.11	Development set only, single run per configuration
RQ3	Tables 6.12, 6.14, 6.15 and 4.5	Only 55 unanswerable development turns; one frozen test submission; no per-category test breakdown
RQ4	Section 6.2 (LLM reranking)	Low-weight interpolation gives marginal gains

Table 6.17: Evidence for each research question and its main limitation.

Chapter 7 synthesizes these findings into the overall contributions of this thesis and discusses the concrete architectural limitations and future directions that follow from them.

Chapter 7

Conclusion and Future Work

This final chapter synthesizes the architectural insights, empirical findings, and technical contributions established throughout this thesis. We present a formal summary of the research contributions (Section 7.1), explicitly answer the four research questions posed in Chapter 4 in light of the evidence gathered in Chapter 6 (Section 7.2), critically examine the operational limitations of the developed framework (Section 7.3), outline concrete directions for future research (Section 7.4), and close with concluding remarks (Section 7.5).

7.1 Summary of Technical Contributions

This thesis has investigated the challenges of context drift and cross-turn dependency that characterize multi-turn dialogue in knowledge-intensive settings. Evaluated on the multi-domain MTRAGEval benchmark (SemEval-2026 Task 8), the proposed architecture indicates that retrieval quality at later dialogue turns is improved more effectively by targeted query diversity than by multi-retriever ensembles, and that deferring answer commitment to a multi-stage pipeline benefits grounded generation. The principal contributions are summarized below, each cross-referenced to its point of introduction and to the corresponding evidence.

- **The Query-Diversity Paradigm** (Section 5.2.1; evaluated in Section 6.2). Issuing five complementary, LLM-generated query reformulations over a single corpus-aligned sparse index (ELSER v1) yields higher top-rank retrieval quality on the development set than ensembling heterogeneous retrievers; the complete configuration improves Recall@5 by +25.7% relative to the unaugmented baseline. Under the benchmark’s official relevance judgments, adding alternative retrievers to the optimized configuration lowers Recall@5 (the retriever ensemble paradox, Section 6.2.4), a result whose size may be affected by pooling bias (Section 6.2.4).
- **Hierarchical Nested Rank Fusion (Nested RRF)** (Section 5.2.4). A two-level rank aggregation tree pre-aggregates the exploratory query tracks (HyDE, Chain-of-Thought, Anchor-Keyword) before merging them with the conservative ones (Minimal, Corpus-Specific). The complete retrieval configuration ranked first on the official Task A leaderboard (nDCG@5=0.5776, +20.5% over the strongest baseline); the contribution of the hierarchical fusion itself, relative to a flat fusion of the same lists, was not isolated.
- **Span-Guided Generation** (Section 5.3; evaluated in Section 6.3). The generation pipeline replaces full-passage input with sentence-level verbatim evidence spans and selects between two drafted candidates using judge scores and an extractiveness shaping function $\phi(r_4)$ calibrated on the development references. Span extraction contributes the largest single gain in the generation ablation (+0.034 HM), and the pipeline ranked second on the official Task B leaderboard (HM=0.7698).
- **A Multi-Layer Answerability Gate** (Section 5.4; evaluated in Section 6.4). Judges at the level of documents, evidence spans, and drafted answers are combined through confidence-weighted voting with dissenter override. On the development set the gate improves end-to-end HM over a single-judge gate (+0.025, Table 6.15), and qualitative inspection of its decisions points to the answer-level judge as the

main source of the remaining acceptance bias.

- **An Empirical Characterization of the Answerability Bottleneck** (Section 6.4). Across all evaluated gate configurations, Unanswerable F1 stays below 25% on the full development set (Table 6.12), with wide uncertainty given only 55 unanswerable turns. On the test set, the gap between reference-grounded generation (HM=0.7698) and end-to-end RAG (HM=0.5409) points to answerability calibration under a tripled unanswerable rate as the decisive factor, while top-rank retrieval errors remain a substantial contributor: on the development set, where unanswerable turns are rare, they account for most of the inspected failures. Better-calibrated abstention is therefore a central open problem for multi-turn conversational RAG, alongside top-rank retrieval precision.

7.2 Answers to the Research Questions

The four research questions formulated in Section 4.4 are answered here in light of the evidence of Chapter 6.

RQ1 — Can query diversity substitute for retriever diversity? Yes, under the benchmark’s official judgments. Query reformulation diversity over a single, corpus-aligned retriever outperforms retriever ensembling: the full five-strategy configuration reaches Recall@5=0.607 on the development set and nDCG@5=0.5776 on the official test set, while heterogeneous retriever ensembles improve deep recall (Recall@100) but lower top-rank precision once the base retriever is well optimized (Section 6.2.4). Hypothesis H1 is supported, with two qualifications: the comparison rests on development-set measurements, and it may be affected by pooling bias in MTRAG’s relevance labels (Section 6.2.4).

RQ2 — Does evidence extraction suppress hallucination? Yes, on the development set. Verbatim evidence span extraction contributes the largest single improvement in the generation ablation (+0.034 HM), accompanied by a +0.041 gain in the reference-less faithfulness metric RL_F , as predicted by the faithfulness part of Hypothesis H2: restricting the generator’s input to a compressed, verifiable evidence set limits the space in which unsupported claims can be introduced. The high test-set RL_F of the complete pipeline (0.8971) is consistent with this finding, although component-level effects cannot be measured on the test set. Fluency is not measured separately, but the reference-based metrics did not deteriorate on aggregate: a +0.041 change in one component of a three-way harmonic mean raises it by only a fraction of that amount, so the observed +0.034 HM gain implies that the reference-based components improved as well. Consequently, the asymmetry in favour of faithfulness that H2 also predicts cannot be confirmed, because per-metric changes of the reference-based metrics were not retained.

RQ3 — How does distribution shift affect answerability gate sensitivity? Substantially. The precision–recall trade-off of answerability detection (Section 6.4.1) is present in every gate configuration we evaluated, and none exceeds 25% Unanswerable F1 on the full development set. The test set’s unanswerable rate (19.1%) is about three times the development rate (6.5%) on which $\tau=0.7$ was calibrated, and the official Task B→C gap (0.7698 → 0.5409) comes mostly from the drop in RB_{alg} (0.6327 → 0.3998). This makes answerability calibration the decisive end-to-end factor under the test distribution, although top-rank retrieval errors also contribute and the two effects cannot be separated without a per-category breakdown of the test scores. Hypothesis H3 is partially supported: multi-layer judging improves over a single judge on the development set but does not eliminate acceptance bias, while the claim that distribution-adaptive calibration is required could not be tested directly with a single frozen submission.

RQ4 — Does LLM-based reranking help once first-stage recall saturates? Not meaningfully. None of the three evaluated LLM-based reranking formulations (pointwise, listwise, generation-based) improved upon the weighted-RRF fusion of retriever and cross-encoder signals once first-stage Recall@100 exceeded 0.90; as substitute ranking signals, all three lowered Recall@10 at a substantially higher API cost (Section 6.2.3), and used as a low-weight auxiliary signal they yield at most marginal Recall@5 gains (up to +2 points per domain) that do not justify this cost. Hypothesis H4 is supported, with the practical implication that, in a mature retrieval pipeline, computational budget is better spent on query-side diversity than on LLM-based reranking.

7.3 System Limitations

Despite its strong results on two of the three official leaderboards, the AILS-NTUA system and its evaluation carry several limitations that qualify the generality of the claims made in this thesis.

1. **Development-set tuning and reporting.** All hyperparameters were tuned on the development set, and all ablations are reported on the same set; no held-out portion of the development data or conversation-level cross-validation was used, so the reported development numbers are likely optimistic. Each configuration was run once, without repetitions over random seeds, so small differences (of the order of 0.01 HM or less) should not be over-interpreted, and the cumulative ablations depend on the order in which components were added.
2. **Static decision thresholds under distribution shift.** The answerability confidence threshold ($\tau=0.7$), the extractiveness target band ($[0.28, 0.38]$), and the per-corpus Nested RRF weights (Table 5.4) were calibrated exclusively on the development set and were *not* re-tuned for the test distribution during the frozen evaluation phase. This choice is a likely major driver of the Task C gap, together with top-rank retrieval errors (Section 6.4). Whether a different threshold would have performed better on the test set could not be verified, since a single frozen configuration was submitted; on the development set, $\tau=0.6$ performs slightly worse than $\tau=0.7$ (Table 6.14).
3. **Reference history in the evaluation.** MTRAGEval supplies the reference conversation history at every turn. Our evaluation therefore does not test robustness to the system’s own earlier errors, which a deployed assistant would face (Section 6.4.2).
4. **Dependence on proprietary, closed-source APIs.** The system relies exclusively on API-based models—GPT-4o, GPT-4o-mini, and DeepSeek-V3.2—for generation, judging, and query rewriting (Table 5.6). This design introduces external runtime cost and variability outside the system’s control and limits reproducibility, since neither the models’ weights nor their training data are accessible. No component of the pipeline was fine-tuned on MTRAG data; every reported gain stems from prompt engineering and architectural design, so task-specific training could plausibly yield further improvements that this thesis does not explore.
5. **Evaluation-side biases in the benchmark itself.** As noted in Section 6.2.1 and Section 6.2.4, MTRAG’s relevance annotations were constructed with ELSER-retrieved passages as the primary review pool, which may inflate ELSER’s measured advantage over alternative retrievers and contribute to the ensemble paradox. Independently, the generation-quality metrics (RB_{alg} , RB_{llm}) depend on human reference answers and LLM judges that may reward specific phrasing styles over correct but differently worded responses—a limitation of reference-based generation evaluation in general.
6. **Pipeline latency.** The sequential decomposition of the task into five retrieval tracks, cross-encoder reranking, span extraction, dual-candidate generation, and up to three answerability judges adds end-to-end latency, which we did not measure. Model routing (Section 5.3) reduces the estimated monetary cost but not the sequential dependency chain, and the architecture would require additional orchestration engineering—parallelization of independent stages, caching across turns—before low-latency deployment.
7. **Domain-balance mismatch between development and test conditions.** Beyond the unanswerable-rate shift, the test set under-represents FiQA (15.2% vs. 23.6% at development time) and over-represents Govt (31.0% vs. 25.4%). Since the Nested RRF weights were tuned per domain on the development distribution, this compositional shift may compound the answerability threshold miscalibration discussed above.

7.4 Avenues for Future Work

The limitations enumerated above, together with the negative result of RQ4, point toward five concrete directions for future research.

- **Distribution-Adaptive Threshold Calibration.** Rather than a fixed confidence threshold τ , future systems could estimate the current unanswerable-rate regime online—for instance, via entropy tracking

over the retrieved documents or by monitoring semantic divergence between successive turns—and adjust τ accordingly. Since answerability calibration is the decisive end-to-end factor under the test distribution, this is a high-leverage direction for future work; a per-category analysis of the official test scores would help quantify the expected gain.

- **Stronger Gate Baselines.** NLI-based sufficiency classifiers, learned classifiers over retrieval scores, and per-domain calibrated thresholds are natural baselines for the answerability gate that this thesis did not evaluate.
- **Robust Resolution of Cross-Turn Dependencies.** After current-turn retrieval errors, the largest category in our error analysis is unresolved dependency on earlier turns (34%, Table 6.13). Better coreference and ellipsis resolution—for example, rewriting with explicit entity tracking across turns—targets this directly. In deployed settings, where the history contains the system’s own outputs, mechanisms that audit and roll back earlier turns could additionally limit error cascades, a scenario that MTRAGEval does not evaluate.
- **Knowledge Distillation to Open-Weight Reasoning Models.** The structured reasoning traces produced by the multi-query rewriting engine and the multi-judge selection framework are a rich supervision signal that could be distilled into specialized, open-weight reasoning models (e.g., fine-tuned Llama or DeepSeek-R1 variants), compressing the multi-stage logic into a single model. This would address the closed-API dependency of Section 7.3, reducing inference cost and improving reproducibility.
- **Reinforcement Learning for Query Reformulation.** Rather than relying exclusively on prompt engineering, the query rewriter could be optimized via reinforcement learning from downstream retrieval signal—using nDCG@5 or Recall@5 directly as the reward (e.g., through PPO)—exploiting headroom on the query-formulation side, which the negative LLM-reranking result of RQ4 suggests is no longer available on the reranking side.

7.5 Concluding Remarks

This thesis indicates that the success of multi-turn conversational RAG systems does not depend solely on model scaling. Shifting the architectural focus toward retrieval stability and decision calibration is a promising pathway toward reliable, verifiable information-seeking systems, supported by our development-set analyses and by the official rankings: treating conversational search as a query-diversity problem, and placing generation behind layered verification, the AILS-NTUA system ranked first in passage retrieval and second in reference-grounded generation, among 38 and 26 participants respectively.

At the same time, the eleventh-place result on the end-to-end task—only marginally above the strongest organizer baseline—is informative in its own right. Our analysis identifies *answerability calibration* as the decisive open problem between current multi-turn RAG systems and reliable deployment, with a weight that grows with the share of unanswerable requests, while top-rank retrieval precision remains a substantial secondary constraint. The central hypothesis of this thesis (Section 4.4) is thus supported in its retrieval and answerability parts, while its claim about model capacity was not tested directly: retrieval stability can be improved through disciplined query diversity without model scaling, but end-to-end reliability remains bounded by how well the decision to answer or to abstain is calibrated to a possibly shifting distribution of requests.

Bibliography

- [1] Adlakha, V., Dhuliawala, S., Suleman, K., Vries, H. de, and Reddy, S. “TopiOCQA: Open-domain Conversational Question Answering with Topic Switching”. In: *Transactions of the Association for Computational Linguistics* 10 (2022), pp. 468–483.
- [2] Aliannejadi, M., Abbasiantaeb, Z., Chatterjee, S., Dalton, J., and Azzopardi, L. “TREC iKAT 2023: A Test Collection for Evaluating Conversational and Interactive Knowledge Assistants”. In: *Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval*. SIGIR ’24. 2024, pp. 819–829.
- [3] Anantha, R., Vakulenko, S., Tu, Z., Longpre, S., Pulman, S., and Chappidi, S. “Open-Domain Question Answering Goes Conversational via Question Rewriting”. In: *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*. 2021.
- [4] Asai, A., Wu, Z., Wang, Y., Sil, A., and Hajishirzi, H. “Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection”. In: *The Twelfth International Conference on Learning Representations*. 2024.
- [5] Athanasiou, D., Lymperaio, M., Filandrianos, G., Voulodimos, A., and Stamou, G. “AILS-NTUA at SemEval-2026 Task 8: Query Diversity via Nested Reciprocal Rank Fusion and Evidence-Guided Agentic Generation for Multi-Turn RAG”. In: *Proceedings of the 20th International Workshop on Semantic Evaluation (SemEval-2026)*. Association for Computational Linguistics, 2026.
- [6] Cormack, G. V., Clarke, C. L. A., and Buettcher, S. “Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods”. In: *Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval*. SIGIR ’09. 2009.
- [7] Dalton, J., Xiong, C., and Callan, J. “TREC CAsT 2019: The Conversational Assistance Track Overview”. In: *arXiv preprint arXiv:2003.13624* (2020).
- [8] DeepSeek-AI. “DeepSeek-V3 Technical Report”. In: *arXiv preprint arXiv:2412.19437* (2024).
- [9] Dziri, N., Kamalloo, E., Milton, S., Zaiane, O., Yu, M., Ponti, E. M., and Reddy, S. “FaithDial: A Faithful Benchmark for Information-Seeking Dialogue”. In: *Transactions of the Association for Computational Linguistics* 10 (2022), pp. 1473–1490.
- [10] Elastic. *ELSER: Elastic Learned Sparse Encoder*. Elastic Documentation. 2024.
- [11] Es, S., James, J., Espinosa Anke, L., and Schockaert, S. “RAGAs: Automated Evaluation of Retrieval Augmented Generation”. In: *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations*. 2024, pp. 150–158.
- [12] Formal, T., Piwowarski, B., and Clinchant, S. “SPLADE: Sparse Lexical and Expansion Model for First Stage Ranking”. In: *Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval*. SIGIR ’21. 2021.
- [13] Gao, L., Ma, X., Lin, J., and Callan, J. “Precise Zero-Shot Dense Retrieval without Relevance Labels”. In: *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. 2023, pp. 1762–1777.
- [14] Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., Dai, Y., Sun, J., Wang, M., and Wang, H. “Retrieval-Augmented Generation for Large Language Models: A Survey”. In: *arXiv preprint arXiv:2312.10997* (2024).
- [15] Izacard, G. and Grave, E. “Leveraging Passage Retrieval with Generative Models for Open Domain Question Answering”. In: *Proceedings of the 16th Conference of the European Chapter of the Association for Computational Linguistics: Main Volume*. 2021, pp. 874–880.

- [16] Izacard, G., Lewis, P., Lomeli, M., Hosseini, L., Petroni, F., Schick, T., Dwivedi-Yu, J., Joulin, A., Riedel, S., and Grave, E. “Atlas: Few-shot Learning with Retrieval Augmented Language Models”. In: *Journal of Machine Learning Research* 24.1 (2023).
- [17] Jiang, Z., Xu, F., Gao, L., Sun, Z., Liu, Q., Dwivedi-Yu, J., Yang, Y., Callan, J., and Neubig, G. “Active Retrieval Augmented Generation”. In: *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. 2023, pp. 7969–7992.
- [18] Joren, H. et al. “Sufficient Context: A New Lens on Retrieval Augmented Generation Systems”. In: *The Thirteenth International Conference on Learning Representations*. 2025.
- [19] Kadavath, S., Conerly, T., Askell, A., et al. “Language Models (Mostly) Know What They Know”. In: *arXiv preprint arXiv:2207.05221* (2022).
- [20] Kamath, A., Jia, R., and Liang, P. “Selective Question Answering under Domain Shift”. In: *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*. 2020.
- [21] Karpukhin, V., Oğuz, B., Min, S., Lewis, P., Wu, L., Edunov, S., Chen, D., and Yih, W.-t. “Dense Passage Retrieval for Open-Domain Question Answering”. In: *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. 2020.
- [22] Katsis, Y., Rosenthal, S., Fadnis, K., Gunasekara, C., Lee, Y.-S., Popa, L., Shah, V., Zhu, H., Contractor, D., and Danilevsky, M. “MTRAG: A Multi-Turn Conversational Benchmark for Evaluating Retrieval-Augmented Generation Systems”. In: *Transactions of the Association for Computational Linguistics* 13 (2025), pp. 784–808.
- [23] Kuo, T.-L., Liao, F., Hsieh, M.-W., Chang, F.-C., Hsu, P.-C., and Shiu, D.-s. “RAD-Bench: Evaluating Large Language Models’ Capabilities in Retrieval Augmented Dialogues”. In: *Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies, Industry Track*. 2025, pp. 868–902.
- [24] Lewis, P. et al. “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks”. In: *Proceedings of the 34th International Conference on Neural Information Processing Systems*. NIPS ’20. Curran Associates Inc., 2020.
- [25] Liu, N. F., Lin, K., Hewitt, J., Paranjape, A., Bevilacqua, M., Petroni, F., and Liang, P. “Lost in the Middle: How Language Models Use Long Contexts”. In: *Transactions of the Association for Computational Linguistics* 12 (2024).
- [26] Mao, K., Dou, Z., Mo, F., Hou, J., Chen, H., and Qian, H. “Large Language Models Know Your Contextual Search Intent: A Prompting Framework for Conversational Search”. In: *Findings of the Association for Computational Linguistics: EMNLP 2023*. 2023.
- [27] Menick, J. et al. “Teaching Language Models to Support Answers with Verified Quotes”. In: 2022.
- [28] Nogueira, R. and Cho, K. “Passage Re-ranking with BERT”. In: *arXiv preprint arXiv:1901.04085* (2019).
- [29] Nogueira, R., Jiang, Z., Pradeep, R., and Lin, J. “Document Ranking with a Pretrained Sequence-to-Sequence Model”. In: *Findings of the Association for Computational Linguistics: EMNLP 2020*. 2020.
- [30] OpenAI. “GPT-4o System Card”. In: *arXiv preprint arXiv:2410.21276* (2024).
- [31] Rajpurkar, P., Jia, R., and Liang, P. “Know What You Don’t Know: Unanswerable Questions for SQuAD”. In: *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*. 2018.
- [32] Robertson, S. and Zaragoza, H. “The Probabilistic Relevance Framework: BM25 and Beyond”. In: *Foundations and Trends in Information Retrieval* 3.4 (2009), pp. 333–389.
- [33] Rosenthal, S., Shah, V., Katsis, Y., and Danilevsky, M. “SemEval-2026 Task 8: MTRAGEval: Evaluating Multi-Turn RAG Conversations”. In: *Proceedings of the 20th International Workshop on Semantic Evaluation (SemEval-2026)*. San Diego, California: Association for Computational Linguistics, 2026.
- [34] Ru, D., Qiu, L., Hu, X., et al. “RAGChecker: A Fine-grained Framework for Diagnosing Retrieval-Augmented Generation”. In: *Advances in Neural Information Processing Systems 37, Datasets and Benchmarks Track*. 2024.
- [35] Saad-Falcon, J., Khattab, O., Potts, C., and Zaharia, M. “ARES: An Automated Evaluation Framework for Retrieval-Augmented Generation Systems”. In: *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)*. 2024.

-
- [36] Shi, W., Min, S., Yasunaga, M., Seo, M., James, R., Lewis, M., Zettlemoyer, L., and Yih, W.-t. “REPLUG: Retrieval-Augmented Black-Box Language Models”. In: *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)*. 2024, pp. 8371–8384.
 - [37] Sun, W., Yan, L., Ma, X., Wang, S., Ren, P., Chen, Z., Yin, D., and Ren, Z. “Is ChatGPT Good at Search? Investigating Large Language Models as Re-Ranking Agents”. In: *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. 2023.
 - [38] Vakulenko, S., Longpre, S., Tu, Z., and Anantha, R. “Question Rewriting for Conversational Question Answering”. In: *Proceedings of the 14th ACM International Conference on Web Search and Data Mining*. WSDM '21. 2021, pp. 355–363.
 - [39] Wang, L., Yang, N., and Wei, F. “Query2doc: Query Expansion with Large Language Models”. In: *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. 2023.
 - [40] Yan, S.-Q., Gu, J.-C., Zhu, Y., and Ling, Z.-H. “Corrective Retrieval Augmented Generation”. In: *arXiv preprint arXiv:2401.15884* (2024).
 - [41] Ye, L., Lei, Z., Yin, J., Chen, Q., Zhou, J., and He, L. “Boosting Conversational Question Answering with Fine-Grained Retrieval-Augmentation and Self-Check”. In: *Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval*. SIGIR '24. 2024, pp. 2301–2305.
 - [42] Yu, S., Liu, Z., Xiong, C., Feng, T., and Liu, Z. “Few-Shot Conversational Dense Retrieval”. In: *Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval*. SIGIR '21. 2021.
 - [43] Zheng, L. et al. “Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena”. In: *Thirty-seventh Conference on Neural Information Processing Systems Datasets and Benchmarks Track*. 2023.

